

Transformer Diffusion 与 Flow Matching

数学原理与生成建模讲义

12 章基础课程 1 章论文精读 图解与分步习题

从上下文建模到概率分布的演化

从基础微积分、线性代数与概率论出发，通过连续小问逐步推导 Attention、变分下界、去噪回归与连续概率流，建立 Diffusion 和 Flow Matching 的完整联系。

第一阶段 Part 1 至 Part 2

Transformer 与语言建模

第二阶段 Part 3 至 Part 9

潜变量模型 扩散推导 Score Matching 与条件生成

第三阶段 Part 10 至 Part 12

概率流 ODE Flow Matching 与 Rectified Flow

论文精读 Part 13

Calvin Luo 扩散模型的统一视角

适用读者 掌握线性代数 概率论与基础微积分的学习者

2026 年 9 月

目录

阅读方法与课程路线.....	3
全书符号约定.....	5
Part 1 Attention 的数学核心.....	6
Part 2 完整 Transformer 与语言模型.....	11
Part 3 生成模型 隐变量 ELBO 与 VAE.....	18
Part 4 从层次 VAE 到扩散前向过程.....	24
Part 5 扩散的逆过程与变分下界.....	30
Part 6 从高斯配方到噪声 MSE.....	37
Part 7 噪声日程 SNR 与三种预测方式.....	45
Part 8 Score Matching 与基于分数的生成模型.....	52
Part 9 条件扩散与无分类器引导.....	60
Part 10 连续时间 ODE 与概率流.....	65
Part 11 Flow Matching 核心理论.....	71
Part 12 条件 FM OT 与 Rectified Flow.....	77
Part 13 从统一视角重读扩散模型.....	83
附录 A 必要的数学工具.....	94
附录 B 从加噪到速度场的可计算例子.....	97
附录 C 综合自测与参考解答.....	99
参考文献与阅读定位.....	101

阅读方法与课程路线

这份讲义解释三个彼此衔接的问题：Transformer 如何把上下文变成预测，Diffusion 如何把生成任务转化为去噪回归，以及 Flow Matching 如何直接学习把噪声分布送到数据分布的速度场。学习的重点是把概率模型、训练目标和采样算法逐一对应起来。Part 13 精读 Calvin Luo 的

《Understanding Diffusion Models: A Unified Perspective》，将前面分章推导的 VAE、扩散、噪声预测与 score 放回同一条概率推理链。

读完后，你应能从注意力矩阵的维度检查开始，独立推导 VAE 的 ELBO、DDPM 的高斯后验与噪声预测损失，解释 score 和概率流 ODE，并写出线性路径 Flow Matching 的训练与采样步骤。

Transformer 是一种网络架构；扩散与流匹配规定的是概率路径或训练方法。二者可以组合，不能按同一层次简单替换。

先修知识与学习方式

本讲义只要求最基础的微积分、线性代数与概率论：会求导和简单积分，会做向量点积与矩阵乘法，知道均值、方差、条件概率和一维正态分布。不要求预先学过机器学习、变分推断、随机过程、偏微分方程或最优传输。梯度、条件期望、KL 散度等工具会在使用时解释；忘记基础恒等式时，可先看附录 A 的“起步工具卡”。

每一章末尾都有三组推导练习，每组拆成连续的小问。前一问的结果就是后一问的起点，帮助你从基本运算逐步搭出核心公式。所有题目先列出，随后单独给出分层提示与参考解答；建议先独立写一步，卡住时只看提示，最后再核对解答中的中间步骤。无需一次做完整章，可把一组题作为一次学习单元。

建议按“看定义—算例题—遮住正文做章末练习—核对解答—口头解释公式”学习。每行草稿都写清楚：哪些量固定、对哪个变量求导、在哪个分布下取期望，以及等号用了哪条基础规则。Part 3 至 Part 6 是概率推导主线；Part 8 至 Part 12 还需反复检查时间方向。

正文图解围绕公式展开：热力图展示注意力的逐行归一化，流程图对应训练与采样步骤，曲线图展示概率密度、后验均值与速度。每幅教学图均给出约定和可复算参数。Part 13 可在读完 Part 3 至 Part 9 后学习，用原论文的统一视角整理已学推导；Part 10 至 Part 12 再将这组关系延伸到连续概率流和 Flow Matching。

哪些需要推，哪些作为工具使用？ Attention、ELBO、高斯后验、噪声 MSE、score 与速度关系，都安排了逐步推导。Part 10 中的 Fokker–Planck 方程与反向 SDE 是带适用条件的工具结论；本讲义解释其各项含义，并引导你从给定方程推出概率流 ODE，不要求用尚未学过的随机分析证明这些定理。OT 的存在性与一般收敛理论也不作为基础习题要求。

部分	主题	学完应能完成的任务
1	Attention 的数学核心	算出注意力权重并检查所有维度
2	Transformer 与 LLM	写出一个解码器块及移位语言建模损失
3	潜变量 ELBO 与 VAE	从 Jensen 不等式推导变分下界
4	HVAE 与前向扩散	由逐步加噪推出任意时刻的条件分布
5	逆过程与扩散 ELBO	区分后验拟合项 解码项和先验项
6	高斯推导与 MSE	配方求后验并推出噪声损失权重
7	噪声日程与三种预测	互换噪声 数据和 v 预测
8	Score Matching	说明去噪监督为何能学习边缘 score
9	条件扩散与 CFG	解释条件注入和引导系数的含义
10	连续时间与概率流	从 Fokker Planck 方程得到概率流 ODE
11	Flow Matching	证明条件回归和边缘速度回归的联系
12	条件 FM OT 与 Rectified Flow	比较路径 耦合 再整流和采样方法
13	扩散模型统一视角论文精读	推导 Tweedie 关系与 SNR 权重 统一数据 噪声和 score 预测

三条时间轴

离散扩散用 t ，连续扩散用 τ ，流匹配用 s 。扩散的前向过程从数据走向噪声；本讲义的 FM 时间从噪声走向数据。比较同一条边缘分布路径时才令 $s=1-\tau$ ，速度还必须随之变号。

$$\begin{aligned}
 & \text{DDPM: } x_0 \text{ data} \xrightarrow{t:0 \rightarrow T} x_T \text{ noise,} \\
 & \text{Diffusion: } x_0 \text{ data} \xrightarrow{\tau:0 \rightarrow 1} x_1 \text{ noise,} \\
 & \text{FM: } z \text{ noise} \xrightarrow{s:0 \rightarrow 1} y \text{ data.}
 \end{aligned}$$

这里的箭头表示建模时定义的路径方向。扩散采样通常沿 $T \rightarrow 0$ 或 $\tau:1 \rightarrow 0$ 运行；FM 采样沿 $s:0 \rightarrow 1$ 运行。

全书符号约定

同一公式中的样本默认是 d 维列向量；Attention 章节为了表示一批 token，将各 token 按行放进矩阵。 $\|x\|^2 = x^\top x$ 。概率密度在连续空间中不等于单点概率。期望符号下省略的随机变量由相邻文字明确说明。

符号	含义
p_{data}	数据分布 训练时可采样但一般不知道密度
p_θ	由参数 θ 定义的生成模型
q 或 q_ϕ	固定前向过程 或参数为 ϕ 的变分分布
x_0, x_t, x_T	DDPM 的干净数据 第 t 步状态和终端状态
β_t, α_t	单步噪声方差及 $\alpha_t = 1 - \beta_t$
$\bar{\alpha}_t$	从第 1 步到第 t 步的 α 累乘
a_t, b_t	$a_t = \sqrt{\bar{\alpha}_t}$ 与 $b_t = \sqrt{1 - \bar{\alpha}_t}$
$\tilde{\beta}_t$	精确条件后验 $q(x_{t-1} x_t, x_0)$ 的方差
r_t^2	模型逆转移的方差 与 b_t^2 含义不同
$\epsilon, \epsilon_\theta$	标准高斯噪声与网络的噪声预测
v_t	扩散的 v 预测目标 $a_t \epsilon - b_t x_0$
$s_\theta(x, \tau)$	score 网络 近似 $\nabla_x \log p_\tau(x)$
z, y, X_s	FM 的噪声端点 数据端点和插值状态
u_s, u_θ	目标边缘速度场与网络预测的速度场
$c, \emptyset$	外部条件与空条件
$N(m, \Sigma)$	均值为 m 协方差为 Σ 的高斯分布

读公式时的两个区分。 ϵ 是一次训练中实际采样的噪声；最优网络通常输出 $E[\epsilon|x_t, t]$ ，并不要求从单个 x_t 唯一还原那次噪声。同样，FM 的单个配对标签 $y - z$ 与所有经过当前位置的配对平均速度 $u_s(x)$ 是不同对象。

全文适用范围。 本讲义主要讨论连续欧氏空间上的高斯扩散与确定性 ODE 生成。涉及密度求导、交换积分与微分或 ODE 唯一性时，默认相应的可积性、光滑性及边界条件成立；在退化端点使用极限或数值截断。理论最优场、有限网络拟合和有限步求解器三个层次会分别说明。

Part 1 Attention 的数学核心

1.1 学习目标与问题背景

本章结束后，你应能从单个查询写出注意力，再推广到矩阵形式；核对每次乘法的维度；解释缩放、掩码与多头的作用；手算一个小型注意力层。先暂时放下“理解语言”这样的宏观说法，关注一个具体问题：序列中某个位置应该从其他位置读取多少信息？

例如，“小明把书交给小红，因为她要复习”中的“她”需要参考前文。固定的平均会把所有词混在一起，固定的邻域又可能漏掉远处的信息。Attention 根据当前输入计算权重，让不同位置读取不同内容。它的基本操作是“匹配查询与键，再加权汇总值”。这是 Transformer 的核心模块。^[1]

1.2 从一个查询到矩阵运算

设查询向量 $q_i \in \mathbb{R}^{d_k}$ 表示位置 i 想找什么；键向量 $k_j \in \mathbb{R}^{d_k}$ 表示位置 j 能被怎样检索；值向量 $v_j \in \mathbb{R}^{d_v}$ 表示真正被读取的内容。这里 i, j 是位置索引， d_k, d_v 是正整数。先给每个候选位置一个标量分数：

$$e_{ij} = \frac{q_i^\top k_j}{\sqrt{d_k}}.$$

接着把一行分数转换成非负、和为一的权重，再求值向量的加权平均：

$$A_{ij} = \frac{\exp(e_{ij})}{\sum_{r=1}^{n_k} \exp(e_{ir})}, o_i = \sum_{j=1}^{n_k} A_{ij} v_j.$$

注意分母固定查询 i ，遍历所有键。不同查询各自分配一份总量为一的注意力，没有要求每个键获得的总权重等于一。因此 A 通常既不对称，也不是双随机矩阵。输出 o_i 在该头的值向量凸包内；后续输出投影和残差会打破对整个网络输出的这种限制。

把向量转置后按行堆叠，有 $Q \in \mathbb{R}^{n_q \times d_k}$ 、 $K \in \mathbb{R}^{n_k \times d_k}$ 、 $V \in \mathbb{R}^{n_v \times d_v}$ 。于是：

$$\begin{aligned} S &= Q K^\top / \sqrt{d_k} \in \mathbb{R}^{n_q \times n_k}, \\ A &= \text{softmax}_{\text{row}}(S), \\ O &= A V \in \mathbb{R}^{n_q \times d_v}. \end{aligned}$$

自注意力的三者来自同一输入，通常 $n_q = n_k = n$ ；交叉注意力的查询来自目标序列，键和值来自另一序列，长度可以不同。名称里的“自”描述信息来源，并不意味着只看当前位置。

查询、键和值为何要分开？考虑一个小型数据库：键可以编码“这条信息属于哪类”，值可以存储“真正需要带走的内容”。同一个词在匹配阶段需要突出语法属性，在汇总阶段却可能需要传

递语义属性。三套可学习投影允许网络分别选择这些方向。若把三者强制设为相同，仍能定义一种注意力，但减少了模型调节匹配方式与输出内容的自由度。

点积也不是自动归一化的余弦相似度。增大查询或键的长度会改变分数，进而改变权重的尖锐程度；除以维度平方根不等于把向量长度归一化。因而“点积越大表示越相关”是相对于当前学到的表示而言，不能据此比较两个任意网络中权重的绝对语义。

1.3 为什么除以维度的平方根

作一个初始化阶段的近似： q_i 与 k_j 的各坐标相互独立，均值为零、方差为一，并且不同坐标的乘积不相关。则每项 $q_{ir}k_{jr}$ 均值为零、方差为一，因此：

$$\text{Var}(q_i^\top k_j) = \sum_{r=1}^{d_k} \text{Var}(q_{ir}k_{jr}) = d_k.$$

除以 $\sqrt{d_k}$ 后，分数方差回到一的量级。若不缩放，大维度时分数差通常更大，softmax 容易接近“一项为一、其余为零”。对一行概率 a 与分数 e ，有：

$$\frac{\partial a_j}{\partial e_r} = a_j(\delta_{jr} - a_r).$$

当概率接近饱和时，许多导数很小，训练更难调整权重。缩放提供稳定的初始尺度，却不保证训练后的每个分数都服从标准正态。查询和键可能相关，同一位置的自匹配尤其不必满足上述独立假设。把这一解释当成尺度分析，不能把假设误写成模型永远满足的定理。

softmax 还有一个实用不变性：给一行所有分数加同一常数，结果不变。实现时常先减去该行最大值，再取指数，以避免溢出。这不改变数学结果。


1.4 掩码决定允许读取的信息

在 softmax 前加掩码 M ：

$$A = \text{softmax}_{\text{row}}(QK^\top / \sqrt{d_k} + M).$$

允许的位置设 $M_{ij}=0$ ，禁止的位置设为 $-\infty$ 。因果自注意力要求 $j \leq i$ 才能被读取，所以矩阵的严格上三角被屏蔽。填充掩码则禁止读取为凑齐长度加入的 padding token。两种掩码服务于不同约束，可以同时使用。

为何不能在 softmax 后简单把未来位置乘零？这样剩余权重一般不再和为一，改变了输出尺度；除非重新归一化，否则不是同一操作。还要确保每个有效查询至少有一个可读取位置，否则全为 $-\infty$ 的一行没有定义良好的 softmax。填充查询自身的输出通常还要在后续损失或计算中忽略。



教学例: 先对每行做 softmax, 再用该行对 V 加权。

图 1.1 同一组查询和键在加掩码前后的注意力权重

图 1.1 教学例取 $Q = \sqrt{2}I_2$ 、 $K = I_2$ 、 $V = (2, 6)^\top$ 和 $d_k = 2$, 所以缩放分数为 I_2 。每一行先做 softmax, 再对 V 加权。因果掩码将第一行读取未来位置的权重置为零; 第二行仍可读取两个位置。图中的权重与输出保留三位小数, 可与本章习题 C 对照计算。

1.5 多头与参数形状

设输入 $X \in \mathbb{R}^{n \times d}$, 共有 h 个头。第 r 个头使用独立投影:

$$\begin{aligned} Q_r &= X W_r^Q, K_r = X W_r^K, V_r = X W_r^V, \\ W_r^Q, W_r^K &\in \mathbb{R}^{d \times d_k}, W_r^V \in \mathbb{R}^{d \times d_v}, \\ H_r &= \text{Attention}(Q_r, K_r, V_r) \in \mathbb{R}^{n \times d_v}. \end{aligned}$$

各头沿特征维拼接, 再投影回残差通道宽度:

$$\text{MHA}(X) = \text{Concat}(H_1, \dots, H_h) W^O, W^O \in \mathbb{R}^{h d_v \times d}.$$

常取 $d_k = d_v = d/h$, 所以 h 必须整除 d 。多个头可形成不同的读取模式, 但训练目标并不保证某个头专门负责语法或指代。也不要将多头理解为将同一注意力结果复制多份: 各头的投影与权重矩阵均可不同。

对普通稠密注意力, 单层匹配与汇总约需 $O(n^2 d)$ 运算, 投影另需 $O(n d^2)$; 直接保存所有头的注意力矩阵需 $O(h n^2)$ 空间。批量维只是把这些计算并行复制, 不改变单个样本的数学定义。

从训练角度看, 注意力权重通常没有人工标签。下游损失对输出求导, 梯度经过加权汇总、softmax 和点积, 最后更新投影矩阵。若某个值有助于降低预测误差, 训练可以调整匹配使其被更

多读取；也可以直接改变值向量本身，让已有权重读到更合适的内容。因此观察权重变化只是观察了学习过程的一部分。

实现时可以按“投影、拆头、匹配、掩码、归一化、汇总、拼接、输出投影”的顺序核对。拆头和拼接只重排张量，不是额外的概率操作。最好在每一步写下位置维与特征维的名称，而不只记住一串数字；很多能运行却计算错误的程序，问题正出在两个同样大小的维度被误交换。

1.6 小例题与解答

取单个查询 $q=(1,0)^T$ ，两个键 $k_1=(1,0)^T$ 、 $k_2=(0,1)^T$ ，两个标量值 $v_1=2, v_2=6$ ，故 $d_k=2, d_v=1$ 。计算输出，并比较屏蔽第二个键后的结果。

解：分数为 $(1/\sqrt{2}, 0) \approx (0.7071, 0)$ 。权重为：

$$A_1 = \frac{e^{0.7071}}{e^{0.7071} + 1} \approx 0.6698, A_2 \approx 0.3302.$$

所以使用未舍入权重时 $o \approx 3.3210$ 。若第二个键被掩码屏蔽，其分数变成 $-\infty$ ，权重变成 $(1, 0)$ ，输出恰为 2。这也说明注意力倾向第一个值，并不意味着硬性选择它。

1.7 易错点与章末推导练习

最常见的维度错误是写成 $Q^T K$ ，得到特征间矩阵而不是位置间矩阵；最常见的概率错误是沿列做 softmax；最常见的概念错误是把注意力权重直接当成可靠的因果解释。权重是网络内部的一步计算，还要结合值向量、投影和后续层理解。

以下三组练习先完整列出。每次只使用已知条件和上一小问的结果；卡住时先看对应提示，再看解答。

练习 1A 从标量乘积推出点积缩放。 已知 $q_1, \dots, q_d, k_1, \dots, k_d$ 相互独立，均值为零、方差为一。目标是找出点积的自然尺度。可用 $\text{Var}(R) = E[R^2] - E[R]^2$ ，以及独立时 $E[AB] = E[A]E[B]$ 。

1. 先只看一个坐标，计算 $E[q_r k_r]$ 与 $E[(q_r k_r)^2]$ ；说明第二个期望为什么不是零。
2. 定义标量 $S = \sum_{r=1}^d q_r k_r$ ，利用期望的线性性求 $E[S]$ 。
3. 将 S^2 展开成平方项和不同坐标的交叉项。逐类计算期望，推出 $\text{Var}(S)$ 。
4. 分别计算 $S/\sqrt{d}$ 与 S/d 的方差。为什么前者更适合保持不同维度下相近的分数尺度？
5. 若各坐标方差改为 σ_q^2, σ_k^2 ，其余假设不变，重复上述步骤求点积标准差；说明失去独立性后哪一步不能直接沿用。

练习 1B 从商法则推出 softmax 导数。 对 m 个标量分数 $e_1, \dots, e_m$ ，定义 $D = \sum_j \exp(e_j)$ 、 $a_j = \exp(e_j)/D$ 。目标是求每个分数如何影响整行权重。可用指数求导、商法则和链式法则； δ_{jr} 在 $j=r$ 时为一，否则为零。

1. 固定索引 r ，分别求 $\partial D / \partial e_r$ 与 $\partial \exp(e_j) / \partial e_r$ 。
2. 用商法则求 $\partial a_j / \partial e_r$ ，再把结果中的指数比值替换成 a_j, a_r 。
3. 将上一问对所有 j 求和，证明和为零。把它与 $\sum_j a_j = 1$ 联系起来。
4. 给所有分数加同一个常数 c ，约去公共因子，证明权重不变；据此解释减去最大分数为何能保持结果。
5. 取 $m=2$ 、 $(e_1, e_2) = (\log 3, 0)$ ，求权重和由四个偏导组成的 2×2 雅可比矩阵。再让 $e_1 - e_2 \rightarrow +\infty$ ，说明导数为何趋近零。

练习 1C 从两个位置组装矩阵注意力。 已知

$$Q = \begin{pmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{2} \end{pmatrix}, K = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, V = \begin{pmatrix} 2 \\ 6 \end{pmatrix}, d_k = 2.$$

目标是从逐项点积得到 $O = \text{softmax}_{\text{row}}(QK^\top / \sqrt{d_k})V$ 。可用矩阵乘法定义 $(AB)_{ij} = \sum_r A_{ir} B_{rj}$ 。

1. 手算第一个查询与两个键的缩放点积，再写出完整分数矩阵 S ，标明形状。
2. 对两行分别归一化，写出注意力矩阵 A ；这里保留 $\exp(1)$ 即可。
3. 先按标量加权和求两个输出，再验证矩阵乘积 AV 得到同样结果。输出是否落在 $[2, 6]$ 内？
4. 加上因果掩码，使位置一不能读取位置二，重新求输出。若只把原 A_{12} 置零而不重新归一化，会得到什么错误结果？
5. 转向一般多头：输入改为 $X \in \mathbb{R}^{2 \times 8}$ ，两头均取 $d_k = d_v = 4$ 。依次推导单头投影、注意力矩阵、输出、拼接结果和 W^O 的形状，检查残差相加是否可行。

1.8 分层提示与参考解答

1A 提示。 先计算一个乘积的二阶矩；展开平方时不要漏掉交叉项。

1. 独立性给出 $E[q_r k_r] = 0$ ；而 $E[q_r^2 k_r^2] = E[q_r^2] E[k_r^2] = 1$ 。零均值不表示平方的均值为零。
2. $E[S] = \sum_r E[q_r k_r] = 0$ ，线性性本身不要求独立。
3. 展开为 $S^2 = \sum_r (q_r k_r)^2 + 2 \sum_{r < j} q_r k_r q_j k_j$ 。交叉项期望因独立性为零，故 $E[S^2] = d$ ，方差为 d 。
4. 由 $\text{Var}(cS) = c^2 \text{Var}(S)$ ，两种方差分别为 1 与 $1/d$ ；后一种会随维度增大而收缩。
5. 每项二阶矩变为 $\sigma_q^2 \sigma_k^2$ ，所以标准差为 $\sqrt{d} \sigma_q \sigma_k$ 。失去独立性后，乘积期望的分解或交叉项为零都不再自动成立。

1B 提示。 将分母平方保留到最后，再认出其中的 softmax 权重。

1. $\partial D / \partial e_r = \exp(e_r)$ ，且 $\partial \exp(e_j) / \partial e_r = \delta_{jr} \exp(e_j)$ 。

2. 商法则给出

$$\frac{\partial a_j}{\partial e_r} = \frac{\delta_{jr} \exp(e_j) D - \exp(e_j) \exp(e_r)}{D^2} = a_j (\delta_{jr} - a_r).$$

3. 对 j 求和得 $a_r - a_r \sum_j a_j = 0$ ，与常数一的导数为零一致。

4. 分子、分母同乘 $\exp(c)$ ，约去后权重不变。取 $c = -\max_j e_j$ 可使所有指数不超过一。

5. 权重为 $(3/4, 1/4)$ ，雅可比为 $\frac{3}{16} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$ 。两类概率趋于 $(1, 0)$ 时，四个导数的共同幅度 $a_1 a_2$ 趋于零。

1C 提示。 一行对应一个查询，列对应可读取的位置；掩码后要重新分配该行的全部权重。

1. 第一个查询分数为 $(1, 0)$ ，完整 S 为 2×2 单位矩阵。

2. 令 $c = \exp(1)$ ，则 $A = \frac{1}{c+1} \begin{pmatrix} c & 1 \\ 1 & c \end{pmatrix}$ ，每行之和为一。

3. $o_1 = (2c+6)/(c+1) \approx 3.0758$ ， $o_2 = (2+6c)/(c+1) \approx 4.9242$ 。矩阵乘法正是这两个加权和，两者都在区间内。

4. 第一行权重变成 $(1, 0)$ ，故 $o_1 = 2$ ，第二行不变。仅置零会得到 $2c/(c+1) \approx 1.4621$ ，因为剩余权重之和小于一。

5. 各 W^Q, W^K, W^V 为 8×4 ；投影后为 2×4 ，注意力为 2×2 ，单头输出为 2×4 。拼接得到 2×8 ，乘 8×8 的 W^O 后仍为 2×8 ，才能与 X 相加。

Part 2 完整 Transformer 与语言模型

2.1 学习目标与架构边界

本章把 Attention 放回完整网络。你应能追踪 token 到预测概率的全过程，写出 pre-LN 残差块，解释位置编码、teacher forcing 与 KV cache，并分清架构和训练目标。

Transformer 是组织神经网络计算的架构。自回归语言建模是对联合概率的一种分解及训练任务；两者可以结合，但不能画等号。相似的注意力模块也可用于图像分类、扩散去噪和速度场预测。原始 Transformer 使用编码器—解码器结构，本章主要采用只有解码器的因果模型讲解文本生成。

[1]

三种常见结构可以从信息可见性来区分。编码器允许输入位置互相读取，适合构造整段输入的表达；只有解码器的因果结构根据已有前缀续写；编码器—解码器结构先表示输入，再让目标位置

通过交叉注意力读取编码结果。例如翻译时，目标前缀需要因果限制，而已经给定的源句通常可以被完整读取。选择哪种结构取决于任务中哪些信息在预测时已知。

2.2 从 token 到带位置的表示

分词器把文本转成离散编号 $w_1, \dots, w_n$ 。token 可能是字、子词或其他片段，并不总是一个自然语言单词。设词表大小为 V ，嵌入表 $E \in \mathbb{R}^{V \times d}$ ；查表得到每个位置的向量。采用加性位置编码时：

$$X_i^{(0)} = E[w_i] + P_i \in \mathbb{R}^d.$$

不加位置信息、不使用依赖位置的掩码时，自注意力对位置置换具有等变性：重新排列输入只会相应排列输出，不能单凭集合内容区分“人咬狗”和“狗咬人”。因果掩码引入了前缀结构，但实际模型通常仍显式提供位置机制。

一个具体选择是正弦位置编码，令 $r = 0, \dots, d/2 - 1$ ：

$$P_{i,2r} = \sin(i / 10000^{2r/d}), P_{i,2r+1} = \cos(i / 10000^{2r/d}).$$

不同通道具有不同波长，既能表示细小位置差，也能表示较长跨度。也可以学习位置嵌入，或在查询、键上施加旋转位置变换。后者不是把同一个位置向量简单加到输入上。这里的重点是确定一种完整且自洽的位置机制，不能在公式里漏掉位置却假定网络已经知道顺序。


2.3 一个完整的 pre-LN 残差块

设第 ℓ 层输入为 $X^{(\ell)} \in \mathbb{R}^{n \times d}$ 。为突出主干，暂略去 dropout。本讲义采用先归一化再计算子层的 pre-LN 写法：

$$\begin{aligned} U^{(\ell)} &= X^{(\ell)} + \text{MHA}_{\text{causal}}(L N_1(X^{(\ell)})), \\ X^{(\ell+1)} &= U^{(\ell)} + \text{FFN}(L N_2(U^{(\ell)})). \end{aligned}$$

两个相加分支必须同为 $n \times d$ 。残差提供保留已有表示与传递梯度的通路；注意力负责位置之间的信息交互，FFN 负责每个位置内部的非线性变换。这种分工只描述计算结构，并不保证每层学到可直接命名的概念。

pre-LN 残差块：先归一化，再计算子层



依次执行两行；每次相加的两端均为 $n \times d$ 。图中省略 dropout。

图 2.1 两次残差相加组成一个 pre-LN Transformer 块

图 2.1 沿上行先计算注意力残差，得到 $U^{(\ell)}$ ，再沿下行计算 FFN 残差。两条绕行箭头分别携带各子层输入，相加处的两个张量形状均为 $n \times d$ 。LayerNorm 位于子层之前；图中省略 dropout。本图描述本节采用的 pre-LN 结构。

LayerNorm 对单个位置的 d 个通道计算均值 μ 和方差 v ：

$$LN(x) = \gamma \odot \frac{x - \mu \mathbf{1}}{\sqrt{v + \epsilon_{LN}}} + \delta.$$

其中 $\gamma, \delta \in \mathbb{R}^d$ 可学习， $\epsilon_{LN} > 0$ 是数值稳定常数。它通常不沿序列长度或 batch 维归一化。

RMSNorm 等替代机制也可用于同一残差框架，但定义不同，不能直接混写。

最基本的 FFN 为：

$$FFN(x) = \phi(xW_1 + b_1)W_2 + b_2, W_1 \in \mathbb{R}^{d \times d_{ff}}, W_2 \in \mathbb{R}^{d_{ff} \times d}.$$

ϕ 可以是 ReLU 或 GELU 等非线性函数；同一层所有位置共享这组参数。若删除非线性，两次线性变换仍可合并成一次线性变换，扩大中间维度便失去主要表达意义。原始论文使用 post-LN，即子层输出与残差相加后再归一化；本章选择 pre-LN，不应将这两个公式都标成原论文的唯一结构。

2.4 自回归概率与错位训练

将文本末尾的结束符也视作 token，概率链式法则给出：

$$p_{\theta}(w_1, \dots, w_n) = \prod_{i=1}^n p_{\theta}(w_i | w_{<i}).$$

因此最大似然训练对应负对数概率求和。训练时构造输入 $(BOS, w_1, \dots, w_{n-1})$ ，目标为 $(w_1, \dots, w_n)$ 。在这个索引约定下，位置 i 的隐藏表示只看到目标 w_i 之前的真实 token，最终输出：

$$\begin{aligned} h_i &= L N_{final}(X_i^{(L)}), \\ \ell_i &= h_i W_{vocab} + b_{vocab} \in \mathbb{R}^V, \\ L_{LM} &= -\frac{1}{n} \sum_{i=1}^n \log \text{softmax}(\ell_i)_{w_i}. \end{aligned}$$

$W_{vocab} \in \mathbb{R}^{d \times V}$ ，可与嵌入表转置共享权重。这里的 softmax 沿词表维进行，和上一章沿键位置的 softmax 完成不同任务。

Teacher forcing 指训练时提供真实历史，而非每一步先采样模型自己的 token。因果掩码允许所有位置的训练预测并行计算，同时禁止目标泄漏。推理时未来 token 未知，必须先生成一个 token，再将其加入上下文继续生成。训练的并行性不意味着自回归采样也能一次得到整段文本。若 batch 中有 padding，平均损失的分母应取有效目标数量，而非填充后的总长度。

一个训练小批次的完整流程是：分词并构造错位的输入与目标，计算有效位置掩码，完成所有层的前向传播，对目标编号取对数概率，汇总损失，再反向传播并更新参数。优化器改变的是共享网络参数，并不是为每个训练位置单独存一份答案。评估时则要使用未参与训练的文本，才能估计模型对新样本的概率拟合能力。

推理时，网络输出概率之后还需要决定如何选 token。取最大概率是贪心解码；按分布抽样可以产生不同续写。若使用温度，将 logits 除以正标量温度后再归一化，温度较小通常使分布更尖锐。这一步改变采样策略，不修改模型权重，也不能修复训练中目标泄漏等结构错误。

2.5 KV cache 为什么成立

在确定性推理与因果掩码下，给前缀末尾追加 token 不会改变旧位置的隐藏状态；旧位置仍只能读取其原来的前缀。因此每层可缓存旧 token 的键和值，新一步只计算新增位置的查询、键、值，并让新查询读取缓存。

令当前上下文长度为 n ，总宽度为 d ，普通多头配置满足 $h d_k = h d_v = d$ 。每层缓存大约保存 $2nd$ 个数，空间为 $O(nd)$ ；新 token 的注意力匹配与汇总需 $O(nd)$ 运算，投影和 FFN 仍约为 $O(d^2 + d d_{ff})$ 。所以单步成本不是常数，缓存也没有把训练时的全部注意力成本消除。

若从短前缀逐个生成至长度 N ，每次都重新计算完整前缀的朴素注意力累计约为 $O(N^3d)$ ；缓存后新增查询的累计注意力约为 $O(N^2d)$ 。这一比较只统计注意力部分，忽略提示词预填充、层数、词表投影和具体硬件效率。理解适用条件比记住一个笼统的“线性复杂度”更可靠。

2.6 小例题与解答

训练文本是“我爱学习”，并在末尾加结束符。若四个正确目标的预测概率依次为 0.5, 0.25, 0.8, 0.4，写出输入、目标与平均交叉熵。

解：输入为“BOS 我爱学习”，目标为“我爱学习 EOS”。四个位置分别预测自己的下一个 token，总概率为 $0.5 \times 0.25 \times 0.8 \times 0.4 = 0.04$ 。使用自然对数时：

$$L_{LM} = -\frac{1}{4} \log 0.04 \approx 0.8047.$$

对应困惑度为 $\exp(0.8047) \approx 2.236$ 。它反映平均对数概率，不等于“每个位置恰有 2.236 个候选词”。若让第二个位置直接看到目标“爱”，模型便可以抄答案，较低训练损失也不再说明学会了合法的下一 token 预测。

2.7 易错点与章末推导练习

检查网络时先问四件事：残差分支形状是否相同，位置信息在哪里进入，目标是否正确错位，归一化究竟沿哪一维。语言模型产生高概率文本，也不自动保证事实正确；最大似然约束的是训练分布上的概率拟合。

练习 2A 从条件概率到语言模型损失。 已知序列中的 token 为 $w_1, \dots, w_n$ ，BOS 是固定起始符。目标是自行推出联合概率、负对数似然与错位目标。可用 $P(A, B) = P(A)P(B|A)$ 、 $\log(ab) = \log a + \log b$ ；以下参与取对数的概率均为正。

1. 从 $p(w_1, w_2, w_3) = p(w_1, w_2)p(w_3|w_1, w_2)$ 出发，再分解前一个因子，写出三个条件概率的乘积。
2. 假设已经得到前 $n-1$ 个 token 的乘积式，再乘最后一个条件概率，推出长度为 n 的链式分解。
3. 对上一问取负对数，并除以目标数量 n ，得到平均负对数似然。为什么最大化联合概率等价于最小化这个损失？
4. 三个正确目标的条件概率分别为 $1/2, 1/4, 4/5$ ，求联合概率、总负对数似然和平均损失；指出三者不是同一个量。
5. 为三个目标构造输入序列、目标序列和因果可见范围。说明第 i 个输出为什么只能依赖 $w_{<i}$ ，以及使用真实前缀为何仍能同时计算三个损失。

练习 2B 从两个通道到 pre-LN 残差块。 先取行向量 $x=(1,3)$ ，令 $\gamma=(1,1)$ 、 $\delta=(0,0)$ ，稳定常数 $\varepsilon>0$ 。目标是理解归一化与残差的每一步形状。可用均值、方差定义和矩阵乘法的形状规则；这里方差的分子为通道数 d ，不使用 $d-1$ 。

1. 求 x 的通道均值 μ 、通道方差 v ，再算归一化向量 $\hat{x}=(x-\mu\mathbf{1})/\sqrt{v+\varepsilon}$ 。
2. 对一般 d 维向量证明 $\hat{x}$ 的通道均值为零，通道方差为 $v/(v+\varepsilon)$ 。为什么不能在有限 ε 下说它严格等于一？
3. 令 $X\in\mathbb{R}^{n\times d}$ ，逐行归一化后形状是否变化？写出 $U=X+\text{MHA}(\text{LN}_1(X))$ ，倒推出注意力输出必须具有的形状。
4. 设 FFN 中间宽度为 d_{ff} ，从输入 $n\times d$ 开始，逐次写出乘 W_1 、加 b_1 、激活、乘 W_2 、加 b_2 后的形状，并确定参数形状。
5. 将两条残差支路连接成完整 pre-LN 块。假设注意力已使用因果掩码，逐位置 LN 与 FFN 会不会引入未来信息？依据它们读取的坐标作答。

练习 2C 从一个目标推出交叉熵梯度。 设词表有 V 个 token，logits 为 $\ell_1,\dots,\ell_V$ ，概率为 $a_j=\exp(\ell_j)/\sum_r\exp(\ell_r)$ 。正确编号为 k ，目标向量 t 满足 $t_k=1$ 、其余为零。目标是推导用于反向传播的梯度；可用对数求导和链式法则。

1. 从单个目标损失 $L=-\log a_k$ 出发，改写为一个 logits 线性项加一个对数求和项。
2. 对任意 ℓ_j 求偏导，分别处理两个项，推出 $\partial L/\partial \ell_j$ 。
3. 把所有偏导组装成向量，证明各分量之和为零；说明这如何呼应给所有 logits 加常数不改变概率。
4. 取 $V=3$ 、所有 logits 为零、正确编号 $k=2$ ，计算梯度。做一次小步梯度下降时，哪个 logit 上升，哪些下降？
5. 若 $\ell_j=\sum_{i=1}^d h_i W_{ij}+b_j$ ，其中 h 是该位置的隐藏表示，用链式法则分别求 $\partial L/\partial W_{ij}$ 与 $\partial L/\partial h_i$ 。再说明多个位置平均损失的梯度如何汇总。

2.8 分层提示与参考解答

2A 提示。 每次先把最后一个 token 从联合事件中拆出来；不要把 token 独立性当成已知条件。

1. 继续分解 $p(w_1, w_2)$ ，得 $p(w_1)p(w_2|w_1)p(w_3|w_1, w_2)$ ，条件中保留所有前缀。
2. 用归纳假设替换 $p(w_{<n})$ ，得 $p(w_{1:n})=\prod_{i=1}^n p(w_i|w_{<i})$ ；空前缀由 BOS 表示。
3. 对数把乘积变为求和，因此平均损失为 $-n^{-1}\sum_i \log p(w_i|w_{<i})$ 。对数单调递增，负号反转优化方向，除以固定正数不改变最优点。

4. 联合概率为 0.1，总负对数似然为 $\log 10 \approx 2.3026$ ，平均为 $\log 10 / 3 \approx 0.7675$ 。
5. 输入为 (BOS, w_1, w_2) ，目标为 (w_1, w_2, w_3) ；输入位置 i 可看位置 1 至 i ，其中只有 BOS 和 $w_{<i}$ 。真实前缀已全部给出，掩码阻止越界读取，所以可并行计算，仍没有看到自己的目标。

2B 提示。 先验证两维数值，再把“两个数相加”换成“对 d 个通道求和”。

1. $\mu=2$ ， $v=[(-1)^2+1^2]/2=1$ ，故 $\hat{x}=(-1,1)/\sqrt{1+\varepsilon}$ 。
2. 由于 $\sum_i (x_i - \mu) = 0$ ，归一化后的均值为零。再平均其平方，得

$$\frac{1}{d} \sum_i \hat{x}_i^2 = \frac{d^{-1} \sum_i (x_i - \mu)^2}{v + \varepsilon} = \frac{v}{v + \varepsilon}.$$

3. LN 只改数值不改形状，输出仍为 $n \times d$ 。相加要求两支同形，所以 MHA 必须投影回 $n \times d$ ， U 也同形。
4. $W_1:d \times d_{ff}$ 、 $b_1:d_{ff}$ ，前三次操作结果都是 $n \times d_{ff}$ ； $W_2:d_{ff} \times d$ 、 $b_2:d$ ，后两次结果都是 $n \times d$ 。偏置沿位置维广播。
5. 再写 $X^{next} = U + FFN(LN_2(U))$ ，两次相加均合法。LN 读取本位置通道，FFN 也只变换本位置，因此不会添加未来依赖。

2C 提示。 先把对数中的分式拆开，比先求整个 softmax 雅可比再相乘更省步骤。

1. 令 $D = \sum_r \exp(\ell_r)$ ，则 $L = -\ell_k + \log D$ 。
2. 第一项导数为 $-t_j$ ；第二项用链式法则得到 $\exp(\ell_j)/D = a_j$ ，故偏导为 $a_j - t_j$ 。
3. $\nabla_{\ell} L = a - t$ ，分量和为 $\sum_j a_j - \sum_j t_j = 1 - 1 = 0$ 。沿全一向量移动 logits 时损失的方向导数因此为零。
4. 概率为 $(1/3, 1/3, 1/3)$ ，梯度为 $(1/3, -2/3, 1/3)$ 。梯度下降减去梯度，所以正确 logit 上升，另外两个下降。
5. 因为 $\partial \ell_j / \partial W_{ij} = h_i$ ，而 h_i 影响所有 logits，得到

$$\frac{\partial L}{\partial W_{ij}} = h_i(a_j - t_j), \frac{\partial L}{\partial h_i} = \sum_j W_{ij}(a_j - t_j).$$

对多个有效位置的平均损失求导，就是对各位置的梯度求和后除以有效位置数；共享参数会接收所有位置的贡献。

Part 3 生成模型 隐变量 ELBO 与 VAE

本章可与 Luo 论文第 2 至第 5 页合读：先理解 ELBO 的两个表达式，再看 VAE 怎样用重参数化优化它。Part 13 将把这些推导串回扩散模型。[15]

3.1 学习目标与生成问题

本章的任务是理解“训练一个会采样的概率模型”究竟优化什么。你能独立推导 ELBO，解释它与真实对数似然的差距，计算高斯 KL，并理解重参数化为什么允许梯度传到编码器。这些步骤会直接复用于扩散模型。

设观测数据 $x \in \mathbb{R}^D$ 来自未知分布 p_{data} 。最大似然希望提高真实样本在模型下的概率密度，即最大化 $E_{p_{data}} \log p_{\theta}(x)$ 。连续变量的密度可以大于一，因此对数密度也可以为正；它不是单点事件的概率。

隐变量模型引入未观测的 $z \in \mathbb{R}^m$ ：先采样 $z \sim p(z)$ ，再采样 $x \sim p_{\theta}(x|z)$ 。例如， z 可以承载手写数字的笔画粗细或倾斜等变化，但仅靠无监督目标通常无法保证每一维都对应清晰语义。模型边缘密度为：

$$p_{\theta}(x) = \int p(z) p_{\theta}(x|z) dz.$$

网络使条件分布灵活，却通常让这个积分难以精确计算。VAE 通过可学习的近似后验与可微采样来优化一个可计算下界。[2]

3.2 从 Jensen 不等式推导 ELBO

为一个固定样本 x 引入概率密度 $q_{\phi}(z|x)$ 。它是编码器给出的近似后验，和生成过程的先验 $p(z)$ 不同。假设需要积分的区域被 q_{ϕ} 的支持覆盖，且以下期望存在。在积分内乘除同一个密度：

$$\begin{aligned} \log p_{\theta}(x) &= \log \int q_{\phi}(z|x) \frac{p_{\theta}(x,z)}{q_{\phi}(z|x)} dz \\ &= \log E_{q_{\phi}(z|x)} \left[\frac{p_{\theta}(x,z)}{q_{\phi}(z|x)} \right] \\ &\geq E_{q_{\phi}(z|x)} [\log p_{\theta}(x,z) - \log q_{\phi}(z|x)] \equiv L_{ELBO}(x). \end{aligned}$$

不等号来自对数的凹性：对数放在期望外面不小于放在里面。把 $p_{\theta}(x,z) = p(z) p_{\theta}(x|z)$ 代入，得到可解释的两部分：

$$L_{ELBO}(x) = E_{q_{\phi}(z|x)} \log p_{\theta}(x|z) - D_{KL}(q_{\phi}(z|x) \| p(z)).$$

第一项要求从编码得到的隐变量解释数据；第二项限制编码分布偏离先验。训练最大化 ELBO，或最小化其相反数。这里的“重建项”是条件对数似然；只有指定观测分布后，它才可能变成平方误差或交叉熵。

3.3 下界差距究竟是什么

利用贝叶斯公式 $p_\theta(z|x) = p_\theta(x, z) / p_\theta(x)$ ，直接展开后验 KL：

$$\begin{aligned} D_{KL}(q_\phi(z|x) \| p_\theta(z|x)) &= E_q[\log q_\phi(z|x) - \log p_\theta(x, z) + \log p_\theta(x)] \\ &= \log p_\theta(x) - L_{ELBO}(x). \end{aligned}$$

KL 非负，因此再次得到下界。等号成立当且仅当近似后验与真实后验几乎处处相等。这个恒等式还揭示两种改进来源：固定生成模型时，提高 ELBO 是缩小推断差距；同时更新生成模型与编码器时，真实似然与差距都会变化，不能声称每一次 ELBO 上升都意味着真实似然严格上升。

注意 ELBO 中容易计算的 KL 比较 $q_\phi(z|x)$ 与先验；差距中的 KL 比较它与真实后验。后者正因为需要难算的 $p_\theta(x)$ ，才通常不能直接拿来训练。两个 KL 的第二个分布不同，是阅读 VAE 推导时最值得标出的区别。

为何要用一个编码器处理所有样本，而不是给每个样本单独优化后验？共享编码器把“看到数据后怎样推断隐变量”学成一个函数，新样本到来时一次前向计算即可得到近似后验，称为摊销推断。这节省了逐样本优化的成本，但函数族和训练能力有限，可能使推断分布无法达到每个样本各自最好的近似。

ELBO 的期望是对隐变量而言，数据集目标还要在样本之间取平均。二者是两层不同的平均。实际训练抽一批数据，再为每个样本抽一份或数份噪声，以估计重建期望；可解析计算的先验 KL 通常直接计算。增加隐变量采样次数主要降低估计方差，并不自动弥补近似后验族本身缺乏表达能力的问题。

3.4 高斯 KL 的来源与公式

令 $q = N(\mu_q, \Sigma_q)$ 、 $p = N(\mu_p, \Sigma_p)$ ，均为 m 维且协方差正定。把两份高斯对数密度相减，常数 $m \log(2\pi)$ 抵消。随后用恒等式：

$$E_q[(z - \mu_p)(z - \mu_p)^\top] = \Sigma_q + (\mu_q - \mu_p)(\mu_q - \mu_p)^\top.$$

二次型的期望因此变成迹与均值差两项，而自身标准化二次型的期望为 m 。最终得到：

$$\begin{aligned} D_{KL}(q \| p) &= \frac{1}{2} [\text{tr}(\Sigma_p^{-1} \Sigma_q) + (\mu_p - \mu_q)^\top \Sigma_p^{-1} (\mu_p - \mu_q) \\ &\quad - m + \log \frac{\det \Sigma_p}{\det \Sigma_q}]. \end{aligned}$$

对常用先验 $p(z) = N(0, I)$ 与对角编码器 $q_\phi(z|x) = N(\mu, \text{diag}(\sigma^2))$ ，公式简化为：

$$D_{KL}(q_\phi \| p) = \frac{1}{2} \sum_{j=1}^m (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2).$$

均值偏离零或方差偏离一都会被惩罚。网络通常输出 $r_j = \log \sigma_j^2$ ，再令 $\sigma_j = \exp(r_j/2)$ ，保证方差为正。对数方差不是标准差，误把 $\exp(r_j)$ 作为采样标准差会改变整个模型。

3.5 重参数化与观测模型

如果把“从参数依赖的分布中抽样”当成不可微黑箱，就难以对编码器求梯度。把同一随机变量写成：

$$\epsilon \sim N(0, I), z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon.$$

随机性现在来自与参数无关的 ϵ ；固定一次噪声后， z 是参数的可微函数。在满足求导与期望交换条件时，对期望的梯度可用这一确定性路径上的梯度作蒙特卡洛估计。它没有消除采样随机性，也不等于把 z 直接设成均值。

例如选择 $p_\theta(x|z) = N(f_\theta(z), \sigma_x^2 I)$ ，且 σ_x^2 为固定标量，则：


$$-\log p_\theta(x|z) = \frac{\|x - f_\theta(z)\|^2}{2\sigma_x^2} + \frac{D}{2} \log(2\pi\sigma_x^2).$$

于是负 ELBO 是有明确系数的重建 MSE 加先验 KL。若学习 σ_x ，后面的对数项不能随意删除；若数据采用 Bernoulli 观测模型，重建项则是二元交叉熵。训练时从编码器采样，生成时从先验采样；先验匹配使这两条路径有机会衔接。过强的解码器也可能忽略 z ，形成后验坍缩，此时 KL 很小不代表生成建模已经成功。

还应检查损失的归一化方式。高斯负对数似然先对所有观测维求和，先验 KL 则对所有隐变量维求和，之后可以共同对 batch 求平均。如果重建误差被额外除以像素数，而 KL 保持原值，二者相对权重便发生改变。这个改动可以作为模型设计选择，但不能再不加说明地称为同一个观测模型下的原始 ELBO。

生成一张新样本时，完整概率过程包含两次采样：先抽隐变量，再从观测条件分布抽样。展示解码器均值也很常见，但它代表条件均值图，而非完整生成分布的随机样本。把这个差别记清楚，后续讨论扩散最后一步的均值预测与随机采样时就更容易理解。

VAE：训练推断隐变量，生成从先验出发



训练目标中的 KL：对比先验

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_q \log p_\theta(x|z) - D_{\text{KL}}(q_\phi \| p(z))$$

下界差距中的 KL：对比真实后验

$$\log p_\theta(x) - \mathcal{L}_{\text{ELBO}} = D_{\text{KL}}(q_\phi \| p_\theta(z|x))$$

图 3.1 VAE 的训练路线、生成路线与 ELBO

图 3.1 训练时，编码器根据已知 x 产生近似后验，再利用重参数化采样 z ；解码器给出用于评价观测 x 的条件分布。生成时先从先验抽 z ，再从解码器给出的分布抽新样本。图中 q_ϕ 简写 $q_\phi(z|x)$ 。ELBO 内的 KL 比较近似后验与先验，ELBO 和真实对数似然的差则比较近似后验与真实后验，二者不可混同。

3.6 小例题与解答

在一维中设 $q(z|x) = \mathcal{N}(1, 4)$ ， $p(z) = \mathcal{N}(0, 1)$ 。求 KL，并在噪声 $\epsilon = -0.5$ 时给出重参数化样本。若某次重建负对数似然估计为 2，负 ELBO 的对应估计是多少？

解： $\mu=1, \sigma=2$ ，因此：

$$D_{\text{KL}} = 1/2(1+4-1-\log 4) \approx 1.3069.$$

样本为 $z=1+2(-0.5)=0$ 。把解析 KL 与该次重建项相加，负 ELBO 估计为 3.3069。一次重建采样只给出随机估计，不是重建期望的精确值。

3.7 易错点与章末推导练习

ELBO 的最大化方向、两个不同的 KL、方差和标准差，以及生成时使用先验，构成这一章的四个检查点。确定性自编码器只有编码与重建映射，不能仅凭结构类似就推导出相同的概率模型与 ELBO。

练习 3A 一步一步构造 ELBO 与差距。 固定一个观测 x ，记 $q(z)=q_\phi(z|x)$ ，其积分为一，并覆盖所需积分区域。目标是把难算的边缘似然变成可估计的下界。可用 Jensen 不等式 $\log E[R] \geq E[\log R]$ 、 $p_\theta(x, z)=p(z)p_\theta(x|z)$ 、Bayes 公式和 KL 定义；Jensen 的起步证明见附录 A0。假设相关密度为正、所需期望存在。

1. 令 $R(z)=p_\theta(x, z)/q(z)$ ，把 $E_q[R]$ 写成积分并约去 q ，说明结果为何恰是 $p_\theta(x)$ 。
2. 对 R 使用给定的 Jensen 不等式，把右边的对数比值拆开，定义所得下界 $L_{ELBO}(x)$ 。
3. 将联合密度分解代入下界，再把与先验有关的两个对数项合并成 KL。明确这个 KL 的两个分布分别是什么。
4. 用 $p_\theta(z|x)=p_\theta(x, z)/p_\theta(x)$ 展开 $D_{KL}(q\|p_\theta(z|x))$ ，推出它等于对数似然与下界的差。
5. 若 q 恰为真实后验，求 $R(z)$ 并说明 Jensen 为何取等号。若真实对数似然为 -5 、下界为 -7 ，求差距；解释这里的 KL 为什么不是第 3 小问中的先验 KL。

练习 3B 从一维高斯推出对角高斯 KL。 已知 $q=N(\mu_q, \sigma_q^2)$ 、 $p=N(\mu_p, \sigma_p^2)$ ，两方差为正。目标是先在一维完成积分，再推广到独立坐标。可用

$$\log N(z; \mu, \sigma^2) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(z-\mu)^2}{2\sigma^2}.$$

1. 写出 $\log q(z) - \log p(z)$ ，约去共同的 $\log(2\pi)$ 项，保留两个二次项与方差比的对数。
2. 在 $z - \mu_p$ 中加减 μ_q ，展开平方，利用 $E_q[z - \mu_q] = 0$ 求 $E_q[(z - \mu_p)^2]$ 。
3. 对第 1 小问取 q 下的期望，使用第 2 小问和 $E_q[(z - \mu_q)^2] = \sigma_q^2$ ，整理出一维 KL；检验 $q=p$ 时为零。
4. 特化到 $p=N(0, 1)$ ，然后代入 $\mu_q=1, \sigma_q=2$ ，算出数值；注意代入的是标准差还是方差。
5. 若 m 个坐标在 q 和标准正态先验中都独立，将联合密度写成坐标密度的乘积，推出总 KL 是各坐标 KL 之和。再用 $r_j = \log \sigma_j^2$ 改写结果。

练习 3C 沿采样路径亲手求梯度。 先考虑标量编码器，参数为均值 μ 与对数方差 r ，令 $z = \mu + \exp(r/2)\epsilon$ 、 $\epsilon \sim N(0, 1)$ 。固定观测 x 与解码器系数 w ，重建损失取 $\ell(z) = \frac{1}{2}(x - wz)^2$ 。

目标是看见梯度如何穿过随机采样；可用链式法则、 $E[\epsilon] = 0$ 、 $E[\epsilon^2] = 1$ 。

1. 求 z 的均值和方差，解释为什么采样系数是 $\exp(r/2)$ ，而不是 $\exp(r)$ 。
2. 暂时固定一次采到的 ϵ ，求 $\partial z / \partial \mu$ 与 $\partial z / \partial r$ 。

3. 先求 $d\ell/dz$ ，再通过上一问求 $\partial\ell/\partial\mu$ 与 $\partial\ell/\partial r$ ，不要跳过中间导数。
4. 加入先验 KL，得到单样本随机损失 $J = \ell + \frac{1}{2}(\mu^2 + \exp(r) - 1 - r)$ 。分别写出它对 μ, r 的导数，区分重建项与 KL 的贡献。
5. 直接展开 $E_\epsilon[\ell]$ ，证明把每次噪声都设为零会漏掉哪一项。说明重参数化与“只使用编码均值”为什么不同。

3.8 分层提示与参考解答

3A 提示。 第一次 KL 比较编码器与先验；用 Bayes 公式后出现的第二次 KL 才比较真实后验。

1. $E_q[R] = \int q(z) p_\theta(x, z) / q(z) dz = \int p_\theta(x, z) dz = p_\theta(x)$ 。
2. Jensen 给出 $\log p_\theta(x) \geq E_q[\log p_\theta(x, z) - \log q(z)]$ ，右边就是 ELBO。
3. 展开联合对数后， $E_q[\log p(z) - \log q(z)] = -D_{KL}(q \parallel p(z))$ ，因此

$$L_{ELBO}(x) = E_q \log p_\theta(x|z) - D_{KL}(q \parallel p(z)).$$

4. 先将后验对数写成 $\log p_\theta(x, z) - \log p_\theta(x)$ 。后一项与 z 无关，可移出期望，得到

$$\begin{aligned} D_{KL}(q \parallel p_\theta(z|x)) &= E_q[\log q - \log p_\theta(x, z)] + \log p_\theta(x) \\ &= \log p_\theta(x) - L_{ELBO}(x). \end{aligned}$$

5. 此时 $R(z) = p_\theta(x)$ 是常数，对数放在期望内外相同。数值差距为 2；它比较 q 与真实后验，而第 3 小问比较 q 与先验，两者不能混称。

3B 提示。 先算二次项的期望，不必直接计算高斯积分。多维推广只需要乘积取对数变求和。

1. 相减得 $\frac{1}{2} \log(\sigma_p^2 / \sigma_q^2) + (z - \mu_p)^2 / (2\sigma_p^2) - (z - \mu_q)^2 / (2\sigma_q^2)$ 。
2. 写成 $z - \mu_p = (z - \mu_q) + (\mu_q - \mu_p)$ ；交叉项期望为零，故结果是 $\sigma_q^2 + (\mu_q - \mu_p)^2$ 。
3. 代入期望并整理，得到

$$D_{KL}(q \parallel p) = \frac{1}{2} \left[\log \frac{\sigma_p^2}{\sigma_q^2} + \frac{\sigma_q^2 + (\mu_q - \mu_p)^2}{\sigma_p^2} - 1 \right].$$

同均值、同方差时，对数为零，方差比为一，恰好与末项抵消。

4. 标准先验下结果为 $\frac{1}{2}(\mu_q^2 + \sigma_q^2 - 1 - \log \sigma_q^2)$ 。代入标准差 2，方差为 4，得 $\frac{1}{2}(1 + 4 - 1 - \log 4) \approx 1.3069$ 。
5. $\log(q/p) = \sum_j \log(q_j/p_j)$ ，期望的线性性给出 KL 求和。由于 $\sigma_j^2 = \exp(r_j)$ ，结果为 $\frac{1}{2} \sum_j [\mu_j^2 + \exp(r_j) - 1 - r_j]$ 。

3C 提示。 求路径梯度时固定噪声；计算总体重建期望时再把噪声平均掉，这两个操作作用不同。

1. $E[z] = \mu$, $\text{Var}(z) = \exp(r)$ 。若采样系数误用 $\exp(r)$ ，方差会变成 $\exp(2r)$ 。
2. $\partial z / \partial \mu = 1$, $\partial z / \partial r = \frac{1}{2} \exp(r/2) \epsilon$ 。
3. $d\ell/dz = w(wz - x)$ ，所以 $\partial \ell / \partial \mu = w(wz - x)$ ，而 $\partial \ell / \partial r$ 再乘 $\frac{1}{2} \exp(r/2) \epsilon$ 。
4. 加上解析 KL 的梯度，得

$$\begin{aligned} \frac{\partial J}{\partial \mu} &= w(wz - x) + \mu, \\ \frac{\partial J}{\partial r} &= \frac{1}{2} w(wz - x) \exp(r/2) \epsilon + \frac{1}{2} (\exp(r) - 1). \end{aligned}$$

5. 将 $x - wz = (x - w\mu) - w \exp(r/2) \epsilon$ 平方，交叉项期望为零，得到
 $E[\ell] = \frac{1}{2} [(x - w\mu)^2 + w^2 \exp(r)]$ 。固定零噪声漏掉后一项，也漏掉其梯度；重参数化保留随机性，并未把后验换成一个点。

Part 4 从层次 VAE 到扩散前向过程

论文第 5 至第 7 页从 Markov 层次 VAE 引出扩散模型，第 11 页式 (61) 至式 (70) 推出任意噪声层级的条件高斯。本章把递推过程拆成可手算的两步与归纳证明。[15]

4.1 学习目标与层次视角

本章把单个隐变量扩展为一串隐变量，并推导 DDPM 最常用的前向采样公式。你能解释扩散为什么属于隐变量生成模型，区分“固定的破坏过程”和“需要学习的生成过程”，并从一步高斯转移推出任意时刻的边缘条件分布。

在一类链式层次 VAE 中，观测为 $x_0 \in \mathbb{R}^D$ ，隐变量为 $x_1, \dots, x_T$ ，生成模型可写作：

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t).$$

这里 $x_{0:T}$ 表示整条链。生成从最高层隐变量开始，逐层落回数据。一般层次模型可以学习复杂的推断分布，各层维数也不必相同。DDPM 选择一种更具体的构造：各层维度相同，把推断方向固定为逐渐加噪的马尔可夫链。层次 VAE 是理解这种选择的视角，并不表示任意 HVAE 都会自动变成扩散模型。

逐步破坏数据结构、再学习逆向恢复的生成思路见早期扩散工作；本讲义采用 DDPM 的符号和高斯前向设定。[4] [3]

4.2 一步前向转移及其尺度

约定离散时间 $t=0$ 为数据, $t=T$ 为噪声端。选定标量噪声日程 $0 < \beta_t < 1$, 定义 $\alpha_t = 1 - \beta_t$, 并令:

$$q(x_t | x_{t-1}) = N(\sqrt{\alpha_t} x_{t-1}, \beta_t I).$$

等价的采样式为:

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \epsilon_t \stackrel{iid}{\sim} N(0, I).$$

所有 x_t, ϵ_t 都是 D 维向量, I 是 $D \times D$ 单位矩阵; 噪声彼此独立, 并与 x_0 独立。马尔可夫性表示: 给定 x_{t-1} 后, 生成下一步不再需要更早的状态。

为什么既加噪又乘 $\sqrt{\alpha_t}$? 若 x_{t-1} 的均值为零、协方差为 I , 则新状态的协方差为 $\alpha_t I + \beta_t I = I$ 。这样标准高斯是前向转移的平稳分布, 信号逐渐衰减而整体尺度不会无限膨胀。“方差保持”不表示任意初始数据的方差始终精确不变; 这个等式有明确的单位协方差前提。

4.3 展开两步 看见可合并的高斯噪声

先从两步计算开始:

$$\begin{aligned} x_1 &= \sqrt{\alpha_1} x_0 + \sqrt{\beta_1} \epsilon_1, \\ x_2 &= \sqrt{\alpha_2 \alpha_1} x_0 + \sqrt{\alpha_2 \beta_1} \epsilon_1 + \sqrt{\beta_2} \epsilon_2. \end{aligned}$$

后两项是独立高斯的线性组合, 均值为零, 协方差等于系数平方之和乘 I 。其方差系数为:

$$\alpha_2 \beta_1 + \beta_2 = \alpha_2 (1 - \alpha_1) + (1 - \alpha_2) = 1 - \alpha_1 \alpha_2.$$

因此可以把合并后的噪声写成 $\sqrt{1 - \alpha_1 \alpha_2} \epsilon$, 其中 $\epsilon \sim N(0, I)$ 。这里是分布等价: 新的 ϵ 表示前两份噪声的标准化组合, 不必等于其中任何一份。

这个小计算给出一般模式。定义累计保留率:

$$\bar{\alpha}_t = \prod_{r=1}^t \alpha_r, \bar{\alpha}_0 = 1.$$

注意 α_t 描述单步, $\bar{\alpha}_t$ 描述从数据到第 t 步的累计效果; 两者混淆后, 信号强度与训练目标都会出错。

4.4 用归纳法得到任意时刻的分布

假设已经知道:

$$x_{t-1} | x_0 \sim N(\sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1}) I).$$

再应用一步线性高斯转移，条件均值乘上 $\sqrt{\alpha_t}$ ，条件协方差乘上 α_t 后再加 $\beta_t I$ 。因此：

$$\begin{aligned} E[x_t|x_0] &= \sqrt{\alpha_t \bar{\alpha}_{t-1}} x_0 = \sqrt{\bar{\alpha}_t} x_0, \\ \text{Cov}(x_t|x_0) &= [\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t] I \\ &= (1 - \bar{\alpha}_t) I. \end{aligned}$$

初始一步已成立，归纳完成。核心结果为：

$$q(x_t|x_0) = N(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I).$$

令 $a_t = \sqrt{\bar{\alpha}_t}$ 、 $b_t = \sqrt{1 - \bar{\alpha}_t}$ ，便得到重参数化形式：

$$x_t = a_t x_0 + b_t \epsilon, \epsilon \sim N(0, I), a_t^2 + b_t^2 = 1.$$

这使训练能直接随机抽一个 t ，一次构造对应噪声等级的数据，无需先模拟前面的 $t-1$ 步。训练计算因此不必随前向链长度线性增长。若需要联合模拟一整条马尔可夫轨迹，则仍要维护正确的跨时刻相关性；给所有时刻随意共用同一份 ϵ 只保证各自的边缘公式，并不生成原来那条马尔可夫链的联合分布。

同样的推导还能得到跳过若干前向步骤的转移。给定两个整数时刻 $0 \leq r < t$ ，这段过程的累计保留率等于 $\alpha_{r+1} \cdots \alpha_t = \bar{\alpha}_t / \bar{\alpha}_r$ ，因此：

$$q(x_t|x_r) = N\left(\sqrt{\frac{\bar{\alpha}_t}{\bar{\alpha}_r}} x_r, \left(1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_r}\right) I\right).$$

这份条件分布不需要知道更早的 x_0 ，因为马尔可夫性已经把早期历史压缩进当前状态。它也提供一个检查闭式公式的方法：先从数据跳到中间时刻，再从中间跳到终点，合并高斯后的均值和方差应与直接跳到终点一致。后续加速采样会利用相近的时刻关系，但前向可以跳步，不自动意味着学得的逆向模型也可以无误差地任意跳步。

4.5 条件高斯不等于数据边缘高斯

固定一张图像 x_0 后， $q(x_t|x_0)$ 是高斯。但把所有数据样本混合后的分布是：


$$q_t(x_t) = \int p_{data}(x_0) q(x_t|x_0) dx_0,$$

它在中间时刻一般不是高斯。若原始均值为 μ_0 、协方差为 Σ_0 ，由全期望与全协方差公式可得：

$$E[x_t] = a_t \mu_0, \text{Cov}(x_t) = a_t^2 \Sigma_0 + b_t^2 I.$$

这描述了整体均值逐渐向零、协方差逐渐向单位阵移动，但匹配前两阶矩并不等于完整分布已经匹配。

前向扩散：混合分布逐渐接近高斯



实线：解析边缘密度 淡色：两个成分 虚线：标准高斯

$x_t = a_t x_0 + b_t \epsilon$, $a_t^2 + b_t^2 = 1$; 末端 $a_t = 0.05$ 仍保留少量信号。

图 4.1 一维双峰混合分布在三个噪声水平下的解析密度

图 4.1 教学数据为两个等权高斯的混合。加噪后，各成分均值变为 $\pm 2a_t$ ，方差变为 $0.35^2 a_t^2 + b_t^2$ 。淡色曲线各含一半概率质量，深色实线是二者之和；右图虚线为标准正态。这里绘制的是三个噪声水平的边缘密度，末图 $a_t = 0.05$ 仍保留少量信号。图 8.1 将继续展示同类分布的 score。

只有当 $\bar{\alpha}_T$ 足够小、数据尺度适当时，终点才接近标准高斯；有限步的 $\bar{\alpha}_T > 0$ 一般意味着残留信号。对固定 x_0 ，Part 3 的公式给出更具体的尺度检查：

$$D_{KL}(q(x_T|x_0) \| N(0, I)) = \frac{1}{2} [\bar{\alpha}_T \|x_0\|^2 - D\bar{\alpha}_T - D \log(1 - \bar{\alpha}_T)].$$

因此不能仅凭“ T 很大”就宣布终点噪声充分，日程累计效果、数据维度和尺度同样重要。生成时从标准高斯先验起步，终点失配会成为误差来源之一。

直觉上，每一步都在把关于原样本的证据变弱。一个具体样本的轮廓可能仍可辨认，但从同样的噪声状态出发，已经可能对应许多不同的原始样本。恢复任务因此是根据数据分布判断哪些解释合理，而不是在不知道噪声实现值时逐项做确定性减法。训练中我们知道干净样本，因而能够构造监督目标；生成中没有这个样本，只能依靠学到的分布信息。

本章出现的重参数化与 VAE 有共同的代数结构，目的却有所不同：VAE 用它让梯度通过依赖参数的编码分布；固定日程的 DDPM 前向用它快速构造任意噪声等级的训练输入。前向没有要学习的编码器参数，并不妨碍去噪网络利用这些随机输入接受训练。

实际使用闭式公式时，日程数组、累计乘积数组以及输入张量的广播维度必须一致。可先用一维小例题核对数值，再扩展到图像张量；对每个像素使用同一标量日程，不意味着所有像素共用同一个噪声数值。

4.6 小例题与解答

取标量数据 $x_0=2$ ，两步噪声方差都为 0.1。求 $q(x_2|x_0)$ ，并用合并噪声 $\epsilon=-1$ 采一个样本。

解： $\alpha_1=\alpha_2=0.9$ ， $\bar{\alpha}_2=0.81$ ，所以均值为 $\sqrt{0.81} \times 2=1.8$ ，方差为 0.19：

$$q(x_2|x_0=2)=N(1.8, 0.19), x_2=1.8-\sqrt{0.19} \approx 1.3641.$$

若逐步展开，累计噪声方差为 $0.9 \times 0.1 + 0.1 = 0.19$ ，与直接采样一致。不能把累计方差写成 0.2，因为第一步噪声在第二步也被缩放了。这里方差为 0.19，标准差为 $\sqrt{0.19}$ ，两者再次需要分开。

4.7 易错点与章末推导练习

DDPM 前向过程中的 q 是我们选定的扰动机制，逆向生成模型 p_θ 才负责学习如何恢复数据分布。固定前向过程并不意味着学习任务简单到不需要网络：在生成时，模型看不到干净的 x_0 ，需从带噪观测推断合理的过去状态。下一章将推导这种逆向学习的概率目标。

练习 4A 从两次加噪走到任意时刻。 先固定标量数据 x_0 ，设 $\alpha_t=1-\beta_t$ 、 $0<\beta_t<1$ ，每步独立抽取 $\epsilon_t \sim N(0,1)$ 。目标是从 $x_t=\sqrt{\alpha_t}x_{t-1}+\sqrt{\beta_t}\epsilon_t$ 推出闭式分布。可用独立变量的方差相加，以及独立高斯的线性组合仍是高斯。

1. 分别写出 x_1 与 x_2 的递推式，把前者代入后者，整理成数据项、第一步噪声项和第二步噪声项。
2. 固定 x_0 后，逐项求 x_2 的均值和方差；明确噪声系数何时要平方，以及交叉项为何消失。
3. 用 $\beta_i=1-\alpha_i$ 将累计噪声方差化简为 $1-\alpha_1\alpha_2$ ，据此写出 $q(x_2|x_0)$ 。
4. 定义 $\bar{\alpha}_t=\prod_{r=1}^t \alpha_r$ 。假设第 $t-1$ 步的条件均值和方差已是 $\sqrt{\bar{\alpha}_{t-1}}x_0$ 与 $1-\bar{\alpha}_{t-1}$ ，逐步求第 t 步的两者，完成归纳。
5. 将标量噪声换成独立的 D 维标准高斯向量，写出条件均值向量、协方差矩阵与一次重参数化采样式。说明其中的总噪声为何不等于最后一步新抽的噪声。

练习 4B 从固定样本到整个数据分布。 已知标量数据 X_0 的均值为 μ_0 、方差为 v_0 ，它与 $\epsilon \sim N(0,1)$ 独立；设 $X_t=aX_0+b\epsilon$ ， a, b 为固定系数。目标是区分条件方差与边缘方差。可用 $\text{Cov}(A, B)=E[(A-EA)(B-EB)]$ 和期望线性性。

1. 给定 $X_0=x_0$ ，求 X_t 的条件均值和条件方差。此时哪些量是常数，哪些量仍随机？
2. 不再固定 X_0 ，直接对 $aX_0+b\epsilon$ 取期望，求整个数据分布下的均值。

3. 写出 $X_t - E[X_t]$ 并展开平方，分别计算两个平方项与交叉项的期望，求边缘方差。
4. 用协方差定义求 $\text{Cov}(X_t, X_0)$ 。若 X_0 为标准正态且 $a^2 + b^2 = 1$ ， X_t 虽也为标准正态，是否与 X_0 独立？
5. 推广到均值向量 μ_0 、协方差 Σ_0 的 D 维数据，噪声协方差为 I 。用外积展开求 $\text{Cov}(X_t)$ 和 $\text{Cov}(X_t, X_0)$ ；解释这些矩公式为何不能单独证明边缘高斯性。

练习 4C 为什么训练只需抽一个时间。 前向日程固定。定义一次可计算的噪声损失为 ℓ_t ，在数据和噪声上取平均后记为 $M_t(\theta) = E[\ell_t]$ ；本练习的 M_t 专指噪声 MSE，不是完整 ELBO。目标是推导随机抽时的目标与权重。可用离散期望 $E[f(K)] = \sum_t P(K=t)f(t)$ 。

1. 给定 x_0 与任意 t ，从一个标准高斯 ϵ 直接构造 x_t ，写出公式并说明它为何具有所需条件分布，不必运行前面所有步骤。
2. 写出以 $\epsilon_\theta(x_t, t)$ 为预测的 ℓ_t 。如果误用另一份独立噪声 ξ 作标签，求给定 x_t, t 后标签的条件均值，说明模型会被训练去预测什么。
3. 随机时间 K 独立于数据和噪声，且在 $1, \dots, T$ 上均匀。先按 K 分情况，再求期望，证明 $E[\ell_K] = T^{-1} \sum_t M_t$ 。
4. 希望优化固定权重目标 $S = \sum_t w_t M_t$ ，而 $P(K=t) = \pi_t > 0$ 。构造只用一个 ℓ_K 的无偏估计，先验证一般 π_t ，再化简到均匀抽时。
5. 取 $T=2$ 、 $M_1=2, M_2=8$ ，抽时概率为 $(3/4, 1/4)$ 。求不校正时的期望，并构造针对等权平均目标 $(M_1 + M_2)/2$ 的校正；算出其期望验证结果。

4.8 分层提示与参考解答

4A 提示。 第一步噪声也会在第二步被缩放；归纳时只追踪均值和方差，再使用高斯封闭性。

1. 代入后得到

$$x_2 = \sqrt{\alpha_2 \alpha_1} x_0 + \sqrt{\alpha_2 \beta_1} \epsilon_1 + \sqrt{\beta_2} \epsilon_2.$$

2. 数据项固定，噪声均值为零，所以条件均值是 $\sqrt{\alpha_2 \alpha_1} x_0$ 。两份独立噪声的方差分别是 $\alpha_2 \beta_1$ 和 β_2 ，交叉项期望为零，方差相加。
3. $\alpha_2 \beta_1 + \beta_2 = \alpha_2(1 - \alpha_1) + 1 - \alpha_2 = 1 - \alpha_1 \alpha_2$ 。故条件分布为 $N(\sqrt{\alpha_1 \alpha_2} x_0, 1 - \alpha_1 \alpha_2)$ 。
4. 均值乘 $\sqrt{\alpha_t}$ 后为 $\sqrt{\alpha_t} x_0$ ；方差更新为 $\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t = 1 - \bar{\alpha}_t$ 。第一步也成立，因此归纳完成。
5. 每个噪声坐标独立，标量方差变为其系数乘 I ，因此

$$q(x_t | x_0) = N(\sqrt{\alpha_t} x_0, (1 - \bar{\alpha}_t) I),$$

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \epsilon \sim N(0, I).$$

总噪声是之前所有噪声的标准化加权组合；它与最后一步噪声同为标准高斯，并不意味着是同一个随机变量。

4B 提示。 条件于数据时不把数据的方差加进去；取消条件后，数据波动也贡献方差。

1. x_0 是常数，只有 ϵ 随机，故条件均值为 $a x_0$ 、条件方差为 b^2 。
2. 直接取期望得 $E[X_t] = a \mu_0 + b E[\epsilon] = a \mu_0$ 。
3. 中心化后为 $a(X_0 - \mu_0) + b\epsilon$ 。平方项期望为 $a^2 v_0$ 与 b^2 ，交叉项因独立和零均值为零，边缘方差为 $a^2 v_0 + b^2$ 。
4. 与 $X_0 - \mu_0$ 相乘取期望，得到 $a v_0$ 。标准正态情形下它等于 a ；只要 $a \neq 0$ 就不独立，因为独立且有二阶矩的变量协方差必为零。若 $a=0$ ，则 $X_t = b\epsilon$ ，此时由噪声独立性可知它与数据独立。
5. 用同样步骤展开中心化外积，两项交叉矩阵为零，得到 $\text{Cov}(X_t) = a^2 \Sigma_0 + b^2 I$ 与 $\text{Cov}(X_t, X_0) = a \Sigma_0$ 。不同分布可有相同均值、协方差；高斯性还需要分布结构，不能只看两个矩。

4C 提示。 先明确每个时间的损失期望，再用“抽到该时间的概率”作加权。无偏校正要把这份抽样概率除回去。

1. 取 $x_t = a_t x_0 + b_t \epsilon$ ，其中 $a_t = \sqrt{\bar{\alpha}_t}$ 、 $b_t = \sqrt{1 - \bar{\alpha}_t}$ 。高斯仿射变换的均值和协方差与 4A 结果相同，因此无需生成前面状态。
2. $\ell_t = \|\epsilon - \epsilon_\theta(x_t, t)\|^2$ ，标签必须是构造输入时的噪声。独立标签满足 $E[\xi | x_t, t] = 0$ ，平方回归最优函数便成为零，丢失去噪信息。
3. 先对数据和噪声平均，再对抽时平均，得 $E[\ell_K] = \sum_t T^{-1} E[\ell_t] = T^{-1} \sum_t M_t$ 。
4. 构造 $\hat{S} = w_K \ell_K / \pi_K$ 。于是

$$E[\hat{S}] = \sum_t \pi_t \frac{w_t}{\pi_t} M_t = \sum_t w_t M_t = S.$$

均匀抽时时它化为 $T w_K \ell_K$ ；权重与抽时分布都需固定且已知。

5. 未校正期望为 $\frac{3}{4} \times 2 + \frac{1}{4} \times 8 = 3.5$ ，而等权目标为 5。令 $w_1 = w_2 = 1/2$ ，使用 $\ell_K / (2\pi_K)$ ；
两种时间下的条件期望分别为 $4/3$ 和 16 ，再平均为 $\frac{3}{4} \times \frac{4}{3} + \frac{1}{4} \times 16 = 5$ 。

Part 5 扩散的逆过程与变分下界

论文第 8 至第 10 页讨论扩散 ELBO。本章采用式 (58) 的后验拟合形式，使每项损失都能对应一个可计算的条件分布。[15]

5.1 这一关要解决什么问题

前向过程已经把复杂数据变成了接近标准高斯的噪声。生成时，我们希望从噪声出发，逐步产生有结构的数据。困难在于：加噪的规则由我们指定，去噪的规则却取决于整个数据分布。已知一张照片怎样变模糊，并不意味着仅凭模糊照片就能唯一还原原图。

本章把“学习去噪”写成概率模型，再把难以直接计算的数据似然拆成可以训练的局部任务。学完后，应能分清三个对象：人为定义的前向链 q 、待学习的生成链 p_θ ，以及训练时借助干净样本计算的后验。后者是训练信号，并不是生成时额外提供给网络的输入。

沿用 $x_0 \sim p_{data}$ 、 $t=0$ 为数据端、 $t=T$ 为噪声端。定义 $\alpha_t = 1 - \beta_t$ 、 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，并令 $a_t = \sqrt{\alpha_t}$ 、 $b_t = \sqrt{1 - \bar{\alpha}_t}$ 。前向过程为

$$\begin{aligned} q(x_{1:T}|x_0) &= \prod_{t=1}^T q(x_t|x_{t-1}), \\ q(x_t|x_{t-1}) &= N(\sqrt{\alpha_t}x_{t-1}, \beta_t I), \\ q(x_t|x_0) &= N(a_t x_0, b_t^2 I). \end{aligned}$$

5.2 为什么逆过程需要神经网络

真实逆转移可以由贝叶斯公式表示为

$$q(x_{t-1}|x_t) = \frac{q(x_t|x_{t-1})q_{t-1}(x_{t-1})}{q_t(x_t)}.$$

这里 q_t 是对数据与此前噪声全部积分后得到的边缘密度。公式虽然简洁，却涉及未知的数据分布。因此，直接代入高斯前向核并不能把这个真实逆转移算出来。

引入生成模型

$$\begin{aligned} p_\theta(x_{0:T}) &= p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t), \\ p(x_T) &= N(0, I), \\ p_\theta(x_{t-1}|x_t) &= N(\mu_\theta(x_t, t), r_t^2 I), t \geq 2. \end{aligned}$$

同一个网络接收状态与时间，输出各噪声级别对应的均值；本章先取预设的正方差 r_t^2 。最后一步另定义解码器 $p_\theta(x_0|x_1)$ ：连续数据可用高斯密度，离散像素则可以使用离散化高斯概率。两者的似然含义不同，不能混用数值。

选择高斯逆核是一种模型假设。小步长下，它具有合理的局部近似依据，但有限步长时，真实 $q(x_{t-1}|x_t)$ 一般不是高斯。多步神经网络变换仍能组合出复杂的最终数据分布；单步简单并不等于最终分布简单。[3]

5.3 为什么多给一个 x_0 就能得到精确答案

训练时知道原始样本。于是可以考虑

$$q(x_{t-1}|x_t, x_0) \propto q(x_t|x_{t-1})q(x_{t-1}|x_0).$$

右侧两个因子关于 x_{t-1} 都是高斯形式，因此当 $t \geq 2$ 且各步噪声方差为正时，这个条件后验是精确高斯。下一章将通过配方求出它的均值与方差。

不要删除条件中的 x_0 。二者的关系是

$$q(x_{t-1}|x_t) = \int q(x_{t-1}|x_t, x_0)q(x_0|x_t)dx_0.$$

这是按干净样本后验加权的高斯混合，可以有多个峰。训练时，网络只看 x_t, t ，而目标后验利用 x_0 计算。许多样本共同训练后，网络学到的是给定当前状态时应该怎样移动，而不是某一张训练图的私人逆路径。

5.4 从 Jensen 不等式推到负 ELBO

生成模型的数据密度需要积分掉所有隐变量： $p_\theta(x_0) = \int p_\theta(x_{0:T})dx_{1:T}$ 。对固定 x_0 ，乘除前向分布，再使用对数的凹性：

$$\begin{aligned} \log p_\theta(x_0) &= \log E_{q(x_{1:T}|x_0)} \left[\frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} \right] \\ &\geq E_q[\log p_\theta(x_{0:T}) - \log q(x_{1:T}|x_0)]. \end{aligned}$$

右侧称为 ELBO，记为 $E_\theta(x_0)$ ；训练通常最小化其相反数 $L_{vb}(x_0) = -E_\theta(x_0)$ 。因此负 ELBO 是负对数似然的上界，而不是下界。两者差距恰好为

$$L_{vb}(x_0) + \log p_\theta(x_0) = D_{KL}(q(x_{1:T}|x_0) \| p_\theta(x_{1:T}|x_0)).$$

当变分后验与模型后验一致时界才取等。固定前向过程并不意味着这个差距自动为零。

5.5 三类损失怎样从整条链出现

条件于 x_0 ，前向路径还可以反向分解：

$$q(x_{1:T}|x_0) = q(x_T|x_0) \prod_{t=2}^T q(x_{t-1}|x_t, x_0).$$

把它代入负 ELBO，并把不相关变量积分掉，得到

$$\begin{aligned} L_{vb}(x_0) &= D_{KL}(q(x_T|x_0) \| p(x_T)) \\ &+ \sum_{t=2}^T E_{q(x_t|x_0)} D_{KL}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t)) \\ &\quad - E_{q(x_1|x_0)} \log p_\theta(x_0|x_1). \end{aligned}$$

第一行是**终端先验匹配** L_T ，检查前向链终点是否接近用于生成的高斯先验。第二行是**中间去噪匹配**，每一项约束一个逆转移。第三行是**数据解码** L_0 ，衡量最后一步重建干净数据的概率。这一分解是 DDPM 训练目标的基础。[3]

若数据维数为 d ，终端项还可以显式算出：

$$L_T(x_0) = \frac{1}{2} \left[a_T^2 \|x_0\|^2 + d(b_T^2 - 1 - \log b_T^2) \right].$$

在固定 schedule 与固定先验下，它不依赖 θ ，因此不会给去噪网络提供梯度，但计算完整似然界时仍要保留。让 a_T 足够小，会减轻从标准高斯开始生成时的终点分布不匹配。这里衡量的是给定各个 x_0 的条件终端分布，不能悄悄替换成一个边缘 KL。

为什么最后一项不写成同样的高斯 KL？因为给定 x_0 后， $q(x_0|x_1, x_0)$ 是点质量，方差为零。它不能直接套用两个非退化连续高斯之间的 KL 公式。因此 $t=1$ 必须作为解码项单列。

还要看清这些期望在哪里取样。训练一个中间项时，先从数据分布取得原图，再从它的前向条件分布抽取含噪状态；无需运行当前模型的逆链，也无需知道模型对该状态赋予多少概率。前向过程提供可重复生成的监督题目，网络负责作答。对于整个数据分布，还需在上述单样本负 ELBO 外再取一次关于原图的平均，才能得到实际优化的总体目标；有限数据训练则用样本平均近似。

这一安排让训练高效，却也说明为什么小的局部损失并不自动保证任意采样器都可靠。训练见到的是前向链产生的状态，生成过程中遇到的状态来自模型自己的逆链。前面一步的误差可能让后面一步的输入偏离常见训练区域。因此，逆核拟合、终端先验匹配以及采样时采用哪条更新规则，需要共同考察。

三步扩散：每一项损失对应链上的一个位置




图 5.1 三步扩散链与负 ELBO 的各项

图 5.1 将 $T=3$ 的损失放回链上。图中的 $p_{\theta,t} = p_{\theta}(x_{t-1}|x_t)$ ；后验拟合项需按前向过程取期望。末端先验项对比 $q(x_3|x_0)$ 与 $p(x_3)$ ，与最后一段逆向转移是两个不同对象。

5.6 例题 看懂一个三步模型的账单

题目。对某个样本，假设 $T=3$ 。终端 KL 为 0.02， $t=3$ 与 $t=2$ 的期望后验 KL 分别为 0.30、0.60，解码负对数似然为 1.20。求负 ELBO，并说明可以推出怎样的似然结论。若训练忽略终端常数，数值还等于完整负 ELBO 吗？

解答。四项相加得到 $L_{vb}=2.12$ ，所以 $\log p_\theta(x_0) \geq -2.12$ 。如果使用自然对数，单位是 nat。忽略终端常数后得到 2.10，其网络梯度相同，但这个数已经不是完整的负 ELBO，不能直接作为原先的似然界报告。若 x_0 是连续变量，密度可以大于一，解码负对数密度也可以为负；这里的数值只是一组便于计算的示例。

5.7 常见误区

误区。“所有涉及扩散的条件分布都是高斯”混淆了给定 x_0 的条件核与数据混合后的边缘逆核。“训练需要知道 x_0 ，所以生成也需要原图”则混淆了监督标签与模型输入。还有一种容易忽略的错误：把最小化负 ELBO 说成最大化似然的完全等价操作；两者之间仍有变分差距。

5.8 章末推导练习

本章按“一个隐变量—三步链—一般链”推进。先完成三组题目，再看后面的提示。所有密度取正且相关积分有限；连续变量的期望就是用密度作权重的积分。多变量积分可逐个计算，本练习允许交换积分顺序。

题组 5A 从一个密度比得到 Jensen 下界

已知与目标。固定标量观测 x_0 ，标量隐变量为 z ，联合密度为 $p_\theta(x_0, z)$ ，另取归一化密度 $q(z|x_0)$ 。从似然积分推导 ELBO。可用 $E_q f = \int q f dz$ 、 $\log E_q R \geq E_q \log R$ 、贝叶斯公式与 $D_{KL}(q||p) = E_q \log(q/p)$ 。对数严格凹，Jensen 取等要求 R 在有概率的位置为常数。

1. 在 $p_\theta(x_0) = \int p_\theta(x_0, z) dz$ 中乘除 $q(z|x_0)$ ，求 $R(z)$ ，使似然等于 $E_q R$ 。
2. 对上式取对数并使用给定的 Jensen 不等式。把右端的对数比拆成两个对数，命名为 $E_\theta(x_0)$ 。
3. 定义 $L = -E_\theta(x_0)$ 。逐项乘以负号，说明它与 $-\log p_\theta(x_0)$ 的不等号方向。
4. 将 $p_\theta(x_0, z) = p_\theta(z|x_0)p_\theta(x_0)$ 代回下界，整理出 $\log p_\theta(x_0) - E_\theta(x_0)$ 。
5. 这个差距在何时为零？说明固定的 q 为什么不保证自动取等。

题组 5B 三步链里的望远镜消项

已知与目标。 固定 x_0 ，考虑三个标量隐变量 x_1, x_2, x_3 。记 $f_t = q(x_t | x_{t-1})$ 、 $h_t = q(x_t | x_0)$ ，以及 $k_t = q(x_{t-1} | x_t, x_0)$ 。目标是展开后亲眼看到中间项消失。可用前向马尔可夫条件、贝叶斯公式、 $\log(ab) = \log a + \log b$ 。这里“马尔可夫”只表示下一步给定当前状态后，无需再看更早状态。

1. 分别对 $t=2, 3$ 写出条件于 x_0 的贝叶斯公式，证明 $f_t = k_t h_t / h_{t-1}$ 。
2. 写出 $\log f_1 + \log f_2 + \log f_3$ ，注意 $f_1 = h_1$ 。代入上一问，标出所有相消项。
3. 令 $g_t = p_\theta(x_{t-1} | x_t)$ 。从 $p_\theta(x_{0:3}) = p(x_3) g_3 g_2 g_1$ 出发，写出前向密度与模型联合密度之比的对数。
4. 用第二问将第三问分成终端项、两个中间对数比和一个解码项，检查解码项的符号。
5. 对前向联合分布取期望，把两个中间对数比分别写成“先固定 x_t 计算 KL，再对 x_t 平均”的形式。

题组 5C 推广到任意步数并检查边界

已知与目标。 现在 $x_t \in \mathbb{R}^d$ ，有 T 步；沿用上一组记号。可用逐变量积分以及 $\int q(y|x) dy = 1$ 。目标是自行重建完整负 ELBO，而不是背诵三项名称。

1. 用归纳或直接消项，求 $\sum_{t=1}^T \log f_t$ ；指出标量改成向量后哪条代数规则仍然成立。
2. 将结果代入 $\log q(x_{1:T} | x_0) - \log p_\theta(x_{0:T})$ ，列出三个类别。
3. 只看第 t 个中间项，按 $q(x_t | x_0) q(x_{t-1} | x_t, x_0)$ 积分，说明其他状态为什么可被积分掉。
4. 写出完整 $L_{vb}(x_0)$ 。指出在固定 schedule 下哪项对网络参数没有梯度；若学习 schedule，这个结论怎样变化？
5. 尝试将中间项延长到 $t=1$ ：给定 x_0 后， x_0 还有随机性吗？据此说明为什么必须保留解码负对数似然。

5.9 分层提示与参考解答

题组 5A

第一层提示。 积分里人为插入 $q/q=1$ 。

第二层提示。 将模型联合密度拆成“模型后验乘数据密度”，后一个因子与 z 无关。

1. 取 $R(z) = p_\theta(x_0, z) / q(z | x_0)$ 。于是

$$\int p_\theta(x_0, z) dz = \int q(z | x_0) R(z) dz = E_q R.$$

2. 对这个正随机量应用凹函数不等式:

$$\log p_{\theta}(x_0) \geq E_q[\log p_{\theta}(x_0, z) - \log q(z|x_0)] = E_{\theta}(x_0).$$

3. 乘负号会翻转不等号, 故 $-\log p_{\theta}(x_0) \leq -E_{\theta}(x_0) = L$; 这是负对数似然的上界。

4. 代入贝叶斯分解, 并把常数移出期望:

$$\begin{aligned} E_{\theta}(x_0) &= \log p_{\theta}(x_0) + E_q \log \frac{p_{\theta}(z|x_0)}{q(z|x_0)}, \\ \log p_{\theta}(x_0) - E_{\theta}(x_0) &= D_{KL}(q(z|x_0) \| p_{\theta}(z|x_0)). \end{aligned}$$

5. 取等时 R 为常数, 且 $E_q R = p_{\theta}(x_0)$, 所以 $p_{\theta}(x_0, z)/q(z|x_0) = p_{\theta}(x_0)$ 。移项即得到 $q(z|x_0) = p_{\theta}(z|x_0)$ (忽略零概率位置)。预先固定 q 并没有强制这个条件成立。

题组 5B

第一层提示。 每个 h_t 一次出现在分子, 一次出现在下一步的分母。

第二层提示。 最开始的 h_1 也会消去, 留下 h_3 ; 模型最后一步的 g_1 没有对应的普通后验密度。

1. 条件贝叶斯公式给出 $k_t = f_t h_{t-1} / h_t$, 移项即 $f_t = k_t h_t / h_{t-1}$, 分别取 $t=2, 3$ 即可。

2. 完整写开:

$$\begin{aligned} \sum_{t=1}^3 \log f_t &= \log h_1 + \log k_2 + \log h_2 - \log h_1 \\ &\quad + \log k_3 + \log h_3 - \log h_2 \\ &= \log h_3 + \log k_2 + \log k_3. \end{aligned}$$

3. 所求对数比为 $\sum_{t=1}^3 \log f_t - \log p(x_3) - \sum_{t=1}^3 \log g_t$ 。

4. 代入消项结果并重新配对:

$$\log \frac{h_3}{p(x_3)} + \log \frac{k_3}{g_3} + \log \frac{k_2}{g_2} - \log g_1.$$

解码密度在模型联合密度中, 所以符号是负。

5. 固定 x_t , 内层积分为 $\int k_t \log(k_t/g_t) dx_{t-1}$, 这正是 KL。外层按 h_t 平均, 得到 $E_{h_t} D_{KL}(k_t \| g_t)$, 分别取 $t=2, 3$ 。

题组 5C

第一层提示。 不需要再做一次高维高斯积分, 只需使用密度归一化。

第二层提示。 期望的被积式若只涉及相邻两个状态, 其他状态先积分, 便得到这两个状态的联合边缘。

1. 首尾相消给出 $\sum_{t=1}^T \log f_t = \log h_T + \sum_{t=2}^T \log k_t$ 。向量密度同样满足乘法、贝叶斯公式与对数加法，所以推导不变。
2. 对数比变成

$$\log \frac{h_T}{p(x_T)} + \sum_{t=2}^T \log \frac{k_t}{g_t} - \log g_1.$$

3. 先积分不在对数比中出现的状态，得到相邻状态的边缘；再按条件密度分解：

$$\int h_t(x_t) \left[\int k_t \log \frac{k_t}{g_t} d x_{t-1} \right] d x_t.$$

这不是把其他变量“设成零”，而是把其所有可能取值平均掉。

4. 因而

$$L_{vb}(x_0) = D_{KL}(h_T \| p(x_T)) + \sum_{t=2}^T E_{h_t} D_{KL}(k_t \| g_t) - E_{h_1} \log g_1.$$

第一项只含固定前向分布与先验，对 θ 无梯度；学习 schedule 会改变 h_T ，不能再对这些参数将它当作常数。

5. 此时目标就是已知的 x_0 ，条件方差为零，是点质量。非退化高斯 KL 公式不适用；原密度比推导仍留下 $-E_{h_1} \log p_\theta(x_0|x_1)$ ，故将它单列即可。

Part 6 从高斯配方到噪声 MSE

论文第 12 至第 15 页依次推导条件后验、数据预测损失和噪声预测损失。本章展开其中的高斯配方与系数化简；Part 13 再把数据损失权重改写成 SNR 差分。[15]

6.1 为什么这一章值得亲手推一遍

扩散训练代码往往只有几行：取样本、加噪、预测噪声、计算均方误差。要理解这些代码，需要补上两座桥：先把真实条件后验算出来，再把高斯分布之间的匹配变成预测误差。这样，网络预测噪声就不再是凭经验选择的黑箱技巧。

以下取 $t \geq 2$ 、 $0 < \beta_t < 1$ ，并假设模型逆方差 r_t^2 是与网络参数无关的已知正数。记 $y = x_{t-1}$ ，给定的观测为 x_t, x_0 。当讨论连续解码器或可学习方差时，会分别说明变化，避免把这些情形混在同一个 MSE 结论里。

6.2 配方 把关于 y 的二次项收集起来

贝叶斯公式中，与 y 无关的归一化常数可以先忽略：

$$q(y|x_t, x_0) \propto \exp\left[-\frac{1}{2}R(y)\right],$$

$$R(y) = \frac{\|x_t - \sqrt{\alpha_t}y\|^2}{\beta_t} + \frac{\|y - \sqrt{\alpha_{t-1}}x_0\|^2}{1 - \alpha_{t-1}}.$$

展开平方，把指数写成 $-1/2(A\|y\|^2 - 2h^T y + C)$ ，其中 C 不依赖 y 。对应系数为

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \alpha_{t-1}}$$

$$= \frac{1 - \alpha_t}{\beta_t(1 - \alpha_{t-1})},$$

$$h = \frac{\sqrt{\alpha_t}}{\beta_t}x_t + \frac{\sqrt{\alpha_{t-1}}}{1 - \alpha_{t-1}}x_0.$$

第二个等号使用 $\alpha_t = \alpha_t \alpha_{t-1}$ 和 $\alpha_t + \beta_t = 1$ 。再利用

$$A\|y\|^2 - 2h^T y = A\|y - A^{-1}h\|^2 - A^{-1}\|h\|^2,$$

就可以直接读出高斯的协方差为 $A^{-1}I$ 、均值为 $A^{-1}h$ ：

$$q(x_{t-1}|x_t, x_0) = N(\tilde{\mu}_t, \tilde{\beta}_t I),$$


$$\tilde{\beta}_t = \frac{1 - \alpha_{t-1}}{1 - \alpha_t} \beta_t,$$

$$\tilde{\mu}_t = \frac{\sqrt{\alpha_{t-1}}\beta_t}{1 - \alpha_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \alpha_{t-1})}{1 - \alpha_t}x_t.$$

这说明后验把来自 x_0 的先验信息与来自 x_t 的观测信息结合起来。权重不必相加为一，因为前向过程包含 $\sqrt{\alpha_t}$ 的缩放；把它机械理解成普通凸平均会丢掉这一点。[3]

高斯配方：两份精度相加

教学例： $m_0 = -1, A_0 = 2; \quad m_1 = 1, A_1 = 4$



$$A = A_0 + A_1 = 6, \quad \tilde{\beta}_t = A^{-1} = 1/6$$

$$\tilde{\mu}_t = (A_0 m_0 + A_1 m_1) / A = 1/3; \text{ 精度越大, 曲线越窄。}$$

图 6.1 先验因子与观测因子相乘得到更集中的后验

图 6.1 令待推断变量 $y = x_{t-1}$ 。两份信息的中心分别为 -1 和 1 ，精度分别为 2 和 4 ；相乘并归一化后，后验精度为 6 ，均值为 $1/3$ 。在扩散公式中， $m_0 = \sqrt{\bar{\alpha}_{t-1}} x_0$ 、 $m_1 = x_t / \sqrt{\alpha_t}$ ， $A_0 = (1 - \bar{\alpha}_{t-1})^{-1}$ 和 $A_1 = \alpha_t / \beta_t$ 。橙色因子按 y 归一化只为比较形状；原式 $q(x_t | y)$ 是关于 x_t 的条件密度。

6.3 两个高斯的 KL 为什么变成均值 MSE

对于维数为 d 的各向同性高斯，上章中间项的 KL 是

$$\begin{aligned} D_{KL}(N(\tilde{\mu}_t, \tilde{\beta}_t I) \| N(\mu_\theta, r_t^2 I)) \\ = \frac{\|\tilde{\mu}_t - \mu_\theta\|^2}{2r_t^2} + \frac{d}{2} \left[\frac{\tilde{\beta}_t}{r_t^2} - 1 + \log \frac{r_t^2}{\tilde{\beta}_t} \right]. \end{aligned}$$

当 r_t^2 固定时，第二项不依赖 θ ，优化就变成按逆方差加权的均值回归。同样大小的均值误差，在模型宣称不确定性较小时会受到更大惩罚。如果 r_t^2 也由网络预测，方差项和对数项就不能删去；单独最小化噪声 MSE 无法完整训练逆方差。[5]

这里每个训练样本给出的 $\tilde{\mu}_t$ 可能不同。MSE 回归的最优函数是 $E[\tilde{\mu}_t | x_t]$ 。因此，不能把单次监督目标等同于模型在无限数据下应输出的确定结果。

6.4 代入重参数化 得到噪声预测

利用 $x_t = a_t x_0 + b_t \epsilon$ ，其中 $\epsilon \sim N(0, I)$ ，先解出 $x_0 = (x_t - b_t \epsilon) / a_t$ ，再代入后验均值并整理：

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{b_t} \epsilon \right).$$

于是可令网络输出 $\epsilon_\theta(x_t, t)$ ，通过已知系数构造逆均值：

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{b_t} \epsilon_\theta(x_t, t) \right).$$

两式相减时 x_t 消去，得到 $\tilde{\mu}_t - \mu_\theta = -\beta_t(\epsilon - \epsilon_\theta) / (\sqrt{\alpha_t} b_t)$ 。因此每个 $t \geq 2$ 的 ELBO 均值项是

$$L_{t-1} = E_{x_0, \epsilon} \left[w_t \|\epsilon - \epsilon_\theta(a_t x_0 + b_t \epsilon, t)\|^2 \right] + C_t, \\ w_t = \frac{\beta_t^2}{2r_t^2 \alpha_t (1 - \bar{\alpha}_t)}.$$

C_t 是对网络参数而言的常数。这是高斯 KL 到噪声 MSE 的完整系数；平方中的 b_t 会变成 $1 - \bar{\alpha}_t$ ，漏掉它会改变时间权重。

常用简化目标是

$$L_{simple} = E_{t, x_0, \epsilon} \|\epsilon - \epsilon_\theta(a_t x_0 + b_t \epsilon, t)\|^2, t \sim Unif\{1, \dots, T\}.$$

这里还对 $x_0 \sim p_{data}$ 、 $\epsilon \sim N(0, I)$ 取期望。它删除了原来的时间权重，并用同样的回归形式处理第一步，因此不再是原始负 ELBO 的数值表达。即使无限容量模型在每个时间上的回归最优解相同，有限容量网络共享参数后，训练重点与结果仍可能改变。若希望无偏估计原来的中间项之和，均匀抽取 $t \in \{2, \dots, T\}$ 时应乘以 $(T-1)w_t$ ，而不是直接删去权重。[3]

6.5 第一时间步与训练 采样算法

令 $\bar{\alpha}_0 = 1$ ，形式上的后验方差给出 $\tilde{\beta}_1 = 0$ ；这表示给定 x_0 后目标就是确定的 x_0 ，不能代入非退化高斯 KL。若选择连续高斯解码器 $N(\mu_\theta(x_1, 1), r_1^2 I)$ ，其负对数密度仍能单独写成

$$L_0 = E \left[\frac{\|x_0 - \mu_\theta(x_1, 1)\|^2}{2r_1^2} \right] + \frac{d}{2} \log(2\pi r_1^2).$$

代入噪声参数化时，其均值项权重为 $\beta_1 / (2r_1^2 \alpha_1)$ 。离散化高斯解码器需要对像素区间积分，不能把这条连续密度公式称为精确的离散像素似然。

使用简化目标训练。 每次更新依次进行四步：抽取一批 x_0 ；为每个样本独立抽取时间 t 与标准噪声 ϵ ；直接计算 $x_t = a_t x_0 + b_t \epsilon$ ；计算噪声 MSE 并更新参数。无需先模拟 1 到 t 的整段前向链，因为其条件边缘有闭式采样公式。随机时间必须输入模型，同一个噪声图在不同噪声级别对应不同任务。

理解这套算法时，可以把训练批次看成一叠难度不同的题目。每张原图抽到独立时间后，信号与噪声系数都要按该样本的时间索引读取。对图像张量而言，这两个系数在空间位置与颜色通道上广播；网络预测值的形状必须与加入的噪声相同。标签是这次构造含噪输入时实际使用的那份噪声，而不是再抽一份独立噪声。后一种错误会破坏输入与目标之间的统计联系，使模型倾向于预测零。

计算均方误差还有一个容易隐藏的约定：数学中的平方范数对所有坐标求和，软件中的“均方”常常先除以坐标数量。如果维数固定，这给简化训练目标乘了一个正常数，可以通过学习率尺度理解；若报告完整似然界，就必须恢复维数因子与被省略的常数，不能把日志中的平均像素 MSE 当作负对数似然。比较不同分辨率模型时，尤其要说明损失是每样本、每坐标还是整个批次的总和。

按模型祖先采样。先抽取 $x_T \sim N(0, I)$ 。对 $t = T, T-1, \dots, 2$ ，计算逆均值，并独立抽取 $z_t \sim N(0, I)$ ，然后令 $x_{t-1} = \mu_\theta(x_t, t) + r_t z_t$ 。最后从已定义的解码器 $p_\theta(x_0 | x_1)$ 抽样。图像展示时也常直接输出最后的均值；这是一种输出约定，应与严格从连续解码器抽样区别开来。

训练中只需随机访问一个时间，采样中却要按时间顺序使用网络多次，这是两种计算成本不同的原因。也不能随意从上述采样循环中删掉一半时间索引，却继续使用原先单步的系数：从一个时间直接跳到更早时间，对应的是另一个转移问题，需要重新推导更新规则或使用匹配该跨度的采样器。后文的连续时间视角会把这种差异解释为不同的数值积分方案。

6.6 例题 手算一个条件后验

题目。一维情况下， $\beta_1 = 0.1$ 、 $\beta_2 = 0.2$ ，给定 $x_0 = 1$ 、 $x_2 = 0.5$ 。求 $q(x_1 | x_2, x_0)$ 。若 $r_2^2 = \tilde{\beta}_2$ ，噪声 MSE 的权重是多少？

解答。 $\bar{\alpha}_1 = 0.9$ 、 $\alpha_2 = 0.8$ 、 $\bar{\alpha}_2 = 0.72$ 。因此

$$\begin{aligned}\tilde{\beta}_2 &= \frac{0.1}{0.28} \times 0.2 = \frac{1}{14}, \\ \tilde{\mu}_2 &= \frac{\sqrt{0.9} \times 0.2}{0.28} + \frac{\sqrt{0.8} \times 0.1}{0.28} \times 0.5 \approx 0.83735, \\ w_2 &= \frac{0.2^2}{2(1/14) \times 0.8 \times 0.28} = 1.25.\end{aligned}$$

所以后验是 $N(0.83735, 1/14)$ 。注意第二个参数是方差而不是标准差；采样时应乘 $\sqrt{1/14}$ 。

6.7 常见误区

误区。模型逆噪声 $r_t z_t$ 、前向单步噪声 $\sqrt{\beta_t} z_t$ 、累积前向噪声 $b_t \epsilon$ 是三个对象，不能共用一个未定义的“sigma”。预测噪声也不是把随机种子恢复出来：平方损失的最佳预测通常是条件均值，第 8 章会解释它为什么恰好给出 score。

6.8 章末推导练习

先做一维平方展开，再把独立坐标的结果相加。为减少下标负担，第一组暂记 $\alpha = \alpha_t$ 、 $\beta = \beta_t$ 、 $\gamma = \bar{\alpha}_{t-1}$ ，于是 $\alpha + \beta = 1$ 、 $\bar{\alpha}_t = \alpha \gamma$ 。本组取 $t \geq 2$ 且 $0 < \beta, \gamma < 1$ ，避免出现零方差。

题组 6A 从二次多项式认出后验高斯

已知与目标。 固定标量 x_0, x_t ，令 $y = x_{t-1}$ ，已知后验密度正比于 $\exp[-R(y)/2]$ ，其中

$$R(y) = \frac{(x_t - \sqrt{\alpha} y)^2}{\beta} + \frac{(y - \sqrt{\gamma} x_0)^2}{1 - \gamma}.$$

目标是求后验均值与方差。可用 $(u - v)^2 = u^2 - 2uv + v^2$ ，以及高斯密度指数 $-(y - m)^2/(2c)$ 中 m 是均值、 c 是方差。

1. 分别展开两个平方，只收集 y^2 、 y 和与 y 无关的项。将结果写成 $Ay^2 - 2By + C$ 。
2. 把 A 通分，利用 $\alpha + \beta = 1$ 化成一个分式，并确认它为正。
3. 在 $Ay^2 - 2By$ 中加减同一个常数，把它写成 $A(y - B/A)^2$ 加一个与 y 无关的量。
4. 将上式放回密度指数，读出均值 m 与方差 c 。为什么常数项只影响归一化？
5. 分别把 A, B 代入 m, c ，恢复原下标；再说明各坐标条件独立时，向量后验的协方差为什么是 cI 。

题组 6B 从高斯对数密度算出 KL

已知与目标。 一维 $Q = N(m, c)$ 、 $P = N(h, r^2)$ ，其中 $c, r^2 > 0$ 。可用

$$\log N(y; m, c) = -\frac{1}{2} \log(2\pi c) - \frac{(y - m)^2}{2c},$$

以及 $E_Q(y - m) = 0$ 、 $E_Q(y - m)^2 = c$ 。目标是从定义积分，而非直接引用高斯 KL 公式。

1. 写出 $\log Q(y) - \log P(y)$ ，把对数常数与两个平方分开。
2. 将 $y - h = (y - m) + (m - h)$ 平方并取 Q 下期望。哪个交叉项消失，为什么？
3. 对第一问的每一项取期望，推导 $D_{KL}(Q \| P)$ 。
4. 令 $h = \mu_\theta$ ，而 c, r^2 固定。圈出与参数有关的项；若 r^2 也学习，还有哪些项必须保留？
5. 对 d 个独立坐标相加，将 $\sum_i (m_i - h_i)^2$ 写成平方范数，恢复本章向量高斯 KL。

题组 6C 从后验均值推到噪声损失权重

已知与目标。 使用第一组求出的后验均值。已知 $x_t = a_t x_0 + b_t \epsilon$ 、 $a_t^2 = \bar{\alpha}_t$ 、 $b_t^2 = 1 - \bar{\alpha}_t$ 。先在标量上推导，再把平方换成坐标平方和。目标是得到原始均值损失的精确时间权重，并识别两个不能省略的边界说明。

1. 从加噪等式解出 x_0 ；说明此步要求哪个系数非零。
2. 将它代入 $\tilde{\mu}_t$ ，分别收集 x_t 与 ϵ 的系数，推导噪声形式的后验均值。
3. 把上一问中的 ϵ 换成 $\epsilon_\theta(x_t, t)$ 定义 μ_θ ，然后计算 $\tilde{\mu}_t - \mu_\theta$ 。
4. 将这个差的平方代入第二组 KL 的均值项，求 w_t ；再说明向量情形的结果。
5. 若均匀抽取 $t \in \{2, \dots, T\}$ ，怎样无偏估计各时间均值项之和？若改用不带 w_t 的 MSE，是否等于原来的目标？
6. 令 $t=1$ ，检查后验方差，再从连续高斯解码负对数密度求噪声 MSE 权重。

6.9 分层提示与参考解答

题组 6A

第一层提示。 y 的一次系数要与 $-2B$ 比较，别漏负号。

第二层提示。 配方后，高斯方差等于二次系数的倒数，而非二次系数本身。

1. 逐项展开后，

$$\begin{aligned} A &= \frac{\alpha}{\beta} + \frac{1}{1-\gamma}, \\ B &= \frac{\sqrt{\alpha} x_t}{\beta} + \frac{\sqrt{\gamma} x_0}{1-\gamma}, \\ C &= \frac{x_t^2}{\beta} + \frac{\gamma x_0^2}{1-\gamma}. \end{aligned}$$

2. 通分得到 $A = [\alpha(1-\gamma) + \beta] / [\beta(1-\gamma)]$ 。分子为 $1 - \alpha\gamma$ ，分母为正，故 $A = (1 - \alpha\gamma) / [\beta(1-\gamma)] > 0$ 。
3. 平方展开的逆操作给出

$$A y^2 - 2B y + C = A(y - B/A)^2 + C - B^2/A.$$

4. 后两项不含 y ，指数化后只给密度乘一个固定系数，归一化时消去。因此 $m = B/A$ 、 $c = 1/A$ 。
5. 代入并恢复下标：

$$\begin{aligned} c &= \tilde{\beta}_t = \frac{\beta_t(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}, \\ m &= \tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t. \end{aligned}$$

各坐标方差同为 c ，不同坐标协方差为零，所以协方差矩阵是 cI 。

题组 6B

第一层提示。KL 对 Q 取平均，不是对 P 。

第二层提示。展开后的交叉项正比于 $E_Q(y-m)$ 。

1. 常数中的 2π 相消，得到

$$\log \frac{Q}{P} = \frac{1}{2} \log \frac{r^2}{c} - \frac{(y-m)^2}{2c} + \frac{(y-h)^2}{2r^2}.$$

2. 先平方再平均：

$$E_Q(y-h)^2 = c + 2(m-h)E_Q(y-m) + (m-h)^2 = c + (m-h)^2.$$

3. 逐项代回：

$$D_{KL}(Q\|P) = \frac{(m-h)^2}{2r^2} + \frac{1}{2} \left(\frac{c}{r^2} - 1 + \log \frac{r^2}{c} \right).$$

4. 固定方差时只有 $(m-\mu_\theta)^2/(2r^2)$ 随网络变化。若学习 r^2 ，它还出现在分母、 c/r^2 与 $\log r^2$ 中，不能删除这些方差项。

5. 联合密度为坐标密度之积，取对数变成求和，所以

$$D_{KL}(Q\|P) = \frac{\|m-h\|^2}{2r^2} + \frac{d}{2} \left(\frac{c}{r^2} - 1 + \log \frac{r^2}{c} \right).$$

取 $m = \tilde{\mu}_t, c = \tilde{\beta}_t, h = \mu_\theta$ 即回到正文。

题组 6C

第一层提示。用 $a_t = \sqrt{\alpha_t} \sqrt{\bar{\alpha}_{t-1}}$ 消去平方根比值。

第二层提示。从均值差到 MSE，整个系数都要平方。

1. 移项并除以 a_t ，得到 $x_0 = (x_t - b_t \epsilon) / a_t$ ，要求 $a_t \neq 0$ 。
2. 代入后，噪声系数为 $-\beta_t / (\sqrt{\alpha_t} b_t)$ ；数据状态的系数通分为

$$\frac{\beta_t + \alpha_t(1 - \bar{\alpha}_{t-1})}{\sqrt{\alpha_t}(1 - \bar{\alpha}_t)} = \frac{1}{\sqrt{\alpha_t}}.$$

因而 $\tilde{\mu}_t = (x_t - \beta_t \epsilon / b_t) / \sqrt{\alpha_t}$ 。

3. 两个均值中的 x_t 相消：

$$\tilde{\mu}_t - \mu_\theta = -\frac{\beta_t}{\sqrt{\alpha_t} b_t} (\epsilon - \epsilon_\theta).$$

4. 平方后再除以 $2r_t^2$ ，

$$w_t = \frac{\beta_t^2}{2r_t^2 \alpha_t b_t^2} = \frac{\beta_t^2}{2r_t^2 \alpha_t (1 - \bar{\alpha}_t)}.$$

向量的每个坐标系数相同，故平方和同样乘 w_t 。

5. 令 $\ell_t = w_t \|\epsilon - \epsilon_\theta\|^2$ ，则 $E_t[(T-1)\ell_t] = \sum_{t=2}^T \ell_t$ 。删除随时间变化的 w_t 会重新加权各任务，不能再称为原来的均值目标。

6. 因 $\bar{\alpha}_0 = 1$, $\tilde{\beta}_1 = 0$ ，不能使用上面的非退化高斯 KL。解码负对数密度的均值项为 $(x_0 - \mu_\theta)^2 / (2r_1^2)$ ；代入 $b_1^2 = \beta_1$ 得到

$$x_0 - \mu_\theta = \sqrt{\frac{\beta_1}{\alpha_1}}(\epsilon_\theta - \epsilon), w_1 = \frac{\beta_1}{2r_1^2 \alpha_1}.$$

这一步针对连续解码密度；离散像素概率还需对区间积分。

Part 7 噪声日程 SNR 与三种预测方式

论文第 14 页用 SNR 重写去噪损失，并讨论可学习日程；其细推见 Part 13。本章的三种预测是数据、噪声和 v ，论文第 15 至第 17 页的三种解释则是数据、噪声和 score，阅读时应区分。[15]

7.1 同一条扩散链的三种读法

噪声日程（noise schedule）决定信息怎样沿时间丢失。它不只是一个生成随机数的参数表：在均匀抽取时间的训练中，日程同时决定模型会多频繁地遇见哪些难度的去噪任务。本章把单步噪声、累积信号和信噪比连接起来，再比较预测噪声、干净数据与 v 的差异。

β_t 描述第 t 步注入的噪声方差； $\bar{\alpha}_t$ 描述到第 t 步后保留的信号系数平方； $b_t^2 = 1 - \bar{\alpha}_t$ 描述给定 x_0 时的累计噪声方差。它们的关系是

$$\begin{aligned}\bar{\alpha}_t &= \bar{\alpha}_{t-1}(1 - \beta_t), \\ \beta_t &= 1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}, \\ x_t &= a_t x_0 + b_t \epsilon.\end{aligned}$$

因此不能把 β_t 当作 x_t 的总噪声量。即使每步只加很小的噪声，很多步累积起来也会大幅削弱信号。若各步 β_t 都很小，利用 $\log(1 - \beta_t) \approx -\beta_t$ 得到

$$\bar{\alpha}_t \approx \exp\left(-\sum_{i=1}^t \beta_i\right).$$

这也解释了为什么线性增加 β_t 并不会让 $\bar{\alpha}_t$ 线性下降。看 schedule 时，最好同时画出累计系数或 log-SNR，而不只看单步噪声曲线。

7 2 SNR 衡量当前还剩多少信号

扩散中常用的 schedule 信噪比定义为

$$SNR_t = \frac{a_t^2}{b_t^2} = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}, \lambda_t = \log SNR_t.$$

如果每个数据坐标的方差已标准化为一，且数据与噪声独立， SNR_t 就是该坐标的信号方差与噪声方差之比。若坐标数据方差是 c ，实际方差比为 $c SNR_t$ 。因此归一化方式会改变模型感受到的去噪难度；“variance preserving”也不能理解成任意数据在所有时间的边缘协方差都自动等于 I 。

高 SNR 时， x_t 接近数据；低 SNR 时，它接近噪声。同样数量的离散时间点，可以密集落在高 SNR 区域，也可以覆盖更均衡的噪声范围。仅说“训练了一千个时间步”，不足以描述这些训练任务怎样分布。log-SNR 方便同时观察多个数量级，但在理想纯数据端与纯噪声端会分别趋于正无穷和负无穷；实现时通常采用有限端点或单独处理端点。

7 3 线性与 cosine 日程

一种简单选择是让 β_t 从较小值线性增大。它易于实现，但因为累计关系是乘法，后段可能很早就接近纯噪声。另一种做法是先指定希望得到的累计信号曲线，再倒推出 β_t 。

Improved DDPM 提出的 cosine 日程可写为

$$\begin{aligned} F(t) &= \cos^2\left(\frac{t/T + \rho}{1 + \rho} \frac{\pi}{2}\right), \\ \bar{\alpha}_t^{target} &= \frac{F(t)}{F(0)}, \\ \beta_t &= \min\left(1 - \frac{\bar{\alpha}_t^{target}}{\bar{\alpha}_{t-1}^{target}}, 0.999\right). \end{aligned}$$

原论文采用小偏移量 $\rho = 0.008$ ；这里用 ρ 避免与后文 Flow Matching 的时间 s 冲突。分母保证初始累计系数为一；末步裁剪避免出现 $\beta_t = 1$ 的奇异转移。实际加噪应使用裁剪后 β_t 重新累乘得到的 $\bar{\alpha}_t$ ，而不是一边用裁剪后的单步参数、一边坚持未裁剪的目标累计系数。[5]

日程没有脱离数据尺度、目标函数和采样器的普遍最优选择。比较两个方案时，至少要保持这些条件可解释，否则观察到的差异可能来自训练任务重分配，而不只是某条曲线的形状。




图 7.1 信号与噪声系数如何改变对数信噪比

图 7.1 使用教学路径 $a(\tau) = \cos(\pi\tau/2)$ 、 $b(\tau) = \sin(\pi\tau/2)$ ，只绘制内部时间点。它帮助观察 SNR，不能直接当成带偏移与离散裁剪的完整余弦日程；可计算公式见附录 B1。

7 4 预测噪声与预测干净数据怎样互换

给定 $x_t = a_t x_0 + b_t \epsilon$ ，如果网络预测 $\hat{\epsilon}$ ，可以恢复一个干净数据估计；如果网络预测 $\hat{x}_0$ ，也能构造噪声估计：

$$\hat{x}_0 = \frac{x_t - b_t \hat{\epsilon}}{a_t}, \hat{\epsilon} = \frac{x_t - a_t \hat{x}_0}{b_t}.$$

这些公式要求分母非零。前者在 a_t 很小时会放大噪声预测误差，后者在 b_t 很小时会放大干净数据预测误差。代数可互换不等于数值条件相同，也不意味着三个网络使用相同的无权重 MSE 会得到同样的训练结果。

这里的帽子表示估计值，而非必然的真实样本。对于同一个含噪输入，可能存在许多合理原图；仅凭公式并不能把这种统计不确定性消除。

7 5 v 参数化 对数据与噪声做一次旋转

在 $a_t^2 + b_t^2 = 1$ 的约定下，定义

$$v_t = a_t \epsilon - b_t x_0.$$

把它和 x_t 放在一起，可以看到一个二维旋转作用在每个坐标的“数据—噪声”对上：

$$\begin{pmatrix} x_t \\ v_t \end{pmatrix} = \begin{pmatrix} a_t & b_t \\ -b_t & a_t \end{pmatrix} \begin{pmatrix} x_0 \\ \epsilon \end{pmatrix}.$$

矩阵的逆就是转置，所以得到不需要除以 a_t 或 b_t 的恢复式：

$$\hat{x}_0 = a_t x_t - b_t \hat{v}, \hat{\epsilon} = b_t x_t + a_t \hat{v}.$$

v 参数化见 Progressive Distillation。[6] 若令 $a = \cos \phi$ 、 $b = \sin \phi$ ，固定一对 (x_0, ϵ) ，则沿这条插值轨迹有 $dx_\phi/d\phi = v_\phi$ 。它是对角度 ϕ 的导数。若改用连续扩散时间 τ ，则 $dx_t/d\tau = \phi'(\tau)v_\tau$ ；若再

反转时间，符号也会随之变化。后文 Flow Matching 学习的速度统一记为 u ，不能把这里的 v 不经时间与路径转换就直接等同于 u 。

逆变换避免除以很小的系数，有利于理解其数值特性，但不保证消除模型误差。例如在纯噪声端 $a=0, b=1$ ，目标 $v = -x_0$ 仍取决于不可从独立噪声唯一确定的原数据。




图 7.2 数据与噪声的一次正交换坐标

图 7.2 取 $a=0.8, b=0.6$ 。黑色向量表示一对标量 (x_0, ϵ) ，两条彩色方向分别是单位基 (a, b) 与 $(-b, a)$ 。向这两条轴投影，得到的坐标正是 x_t 与 v_t 。同样的关系适用于数据的每个坐标。

7.6 三个 MSE 对同一种误差的权重不同

为了公平比较，先固定同一个输入 x_t ，并要求三个预测由上述转换保持一致。记 $\Delta x = \hat{x}_0 - x_0$ 、 $\Delta \epsilon = \hat{\epsilon} - \epsilon$ 、 $\Delta v = \hat{v} - v$ 。对于内部时间点，

$$\begin{aligned}\Delta \epsilon &= -\frac{a_t}{b_t} \Delta x, \\ \Delta v &= -\frac{1}{b_t} \Delta x, \\ \|\Delta \epsilon\|^2 &= SN R_t \|\Delta x\|^2, \\ \|\Delta v\|^2 &= (1 + SN R_t) \|\Delta x\|^2.\end{aligned}$$

于是，无权重噪声 MSE 等价于按 SNR 加权的数据 MSE；无权重 v MSE 等价于按 $1 + SN R$ 加权的数据 MSE。这是指定一致预测之后的精确代数关系，而不是三个独立网络天然具有一致输出的保证。

若希望更换预测变量后仍优化同一个目标，必须同步调整时间权重。例如原来的 $w_t \|\Delta \epsilon\|^2$ ，改成 v 输出后应写成 $w_t a_t^2 \|\Delta v\|^2$ 。此外，抽取时间的概率也参与最终加权：以概率 π_t 抽取时间却不作补偿，优化的是由 π_t 改写后的目标。

这也提供了读训练曲线的办法。在很低的信噪比下，输入本来就接近加入的噪声，预测噪声可能相当准确；但把这个预测转换成原图时，需要除以很小的信号系数，原图估计仍可能很差。反过

来，在高信噪比下，直接复制输入已经是不错的原图估计，却未必能够准确分辨那一点细微随机噪声。因此，“哪个时间的损失更小”必须先说明预测变量，再换算到共同尺度。若要诊断模型，可以按信噪比区间观察误差，明确区分输入本来容易解释与网络确实学会恢复数据这两种情况。这些诊断也应采用一致的数据归一化方式。

7.7 例题与常见误区

例题。 设 $a=0.6, b=0.8, x_0=2, \epsilon=-1$ 。求 x_t, v ，再由它们恢复原来的数据与噪声。若一致转换的噪声预测误差为 0.1，对应的数据 MSE 是多少？

解答。 $x_t=0.6 \times 2 + 0.8 \times (-1)=0.4$ ， $v=0.6 \times (-1) - 0.8 \times 2=-2.2$ 。逆变换给出 $\hat{x}_0=0.6 \times 0.4 - 0.8 \times (-2.2)=2$ ， $\hat{\epsilon}=0.8 \times 0.4 + 0.6 \times (-2.2)=-1$ 。此时 $SNR=0.36/0.64=0.5625$ ，所以数据 MSE 为 $0.01/0.5625 \approx 0.01778$ 。只比较两个损失的裸数值，会把单位与时间尺度差异误判成预测能力差异。

误区。 “cosine 就是把 β_t 取成余弦”忽略了它首先定义的是累计信号曲线。“改成 v prediction 就变成 Flow Matching”忽略了路径、时间参数与训练目标。“所有参数化都只是重命名”则忽略了数值条件与损失加权。

7.8 章末推导练习

三组练习依次回答“噪声有多大”“两种输出怎样互换”“旋转为什么改变损失权重”。先固定某个时间，省略下标，最后再恢复时间变化。不确定方差或矩阵乘法时，可先回看附录 A0。

题组 7A 从标量方差得到 SNR

已知与目标。 X_0, ϵ 独立，均值均为零， $\text{Var}(X_0)=c>0$ 、 $\text{Var}(\epsilon)=1$ 。令 $X=aX_0+b\epsilon$ ， $a^2+b^2=1$ ；本组先取 $a, b>0$ 。可用 $\text{Var}(kU)=k^2\text{Var}(U)$ 、独立变量协方差为零，以及方差求和公式。目标是区分实际方差比和只由日程决定的比值。

1. 单独考虑信号 $S=aX_0$ ，计算它的均值、方差；不要把系数 a 直接当作方差。
2. 令噪声 $N=b\epsilon$ ，计算其方差及 $\text{Cov}(S, N)$ 。
3. 从 $\text{Var}(S+N)$ 算出 X 的方差。为什么只有在 $c=1$ 等适当条件下，方差才始终等于一？
4. 用信号方差除以噪声方差。再令 $c=1, a^2=\bar{\alpha}$ ，推导 SNR 及由 SNR 反求 $\bar{\alpha}$ 的公式。
5. 已知 $a_t^2=(1-\beta_t)a_{t-1}^2$ 、 $a_0=1$ 。连续代入两三次，再写一般乘积；据此说明一般 $t \geq 2$ 时，单个 $\bar{\alpha}_t$ 为什么不足以确定 β_t 。

题组 7B 从一次方程得到预测误差关系

已知与目标。 固定同一观测 $x = ax_0 + b\epsilon$ ，先取标量且 $a, b > 0$ 。带帽子的是网络估计值。三种误差比较都必须针对同一个 x ，不能偷偷改变输入。可用移项、除法、平方和。目标是推导输出转换与噪声 MSE 对数据误差的权重。

1. 把已知关系视为关于 x_0 的一次方程，解出 x_0 。
2. 用预测值 $\hat{\epsilon}$ 替换 ϵ ，构造 $\hat{x}_0$ 。计算 $\hat{x}_0 - x_0$ ，判断 a 很小时误差怎样放大。
3. 反过来，从 $\hat{x}_0$ 构造 $\hat{\epsilon}$ 。与真实等式相减，求 $\Delta\epsilon$ 与 Δx 的关系，其中 $\Delta x = \hat{x}_0 - x_0$ 。
4. 将第三问平方，再对向量的每个坐标相加，证明两种平方损失之间的 SNR 因子。
5. 若原目标是 $w_t \|\Delta\epsilon\|^2$ ，改为预测 x_0 时该乘什么权重？在 $a=0$ 或 $b=0$ 处，分别哪条除法不再合法？

题组 7C 从旋转矩阵得到 v 与损失权重

已知与目标。 定义 $v = a\epsilon - bx_0$ ，仍有 $a^2 + b^2 = 1$ 。可用二阶矩阵乘法，以及 $\sin' = \cos$ 、 $\cos' = -\sin$ 和链式法则。目标是自己推导逆变换，再辨认 v 对哪个变量求导。

1. 写出把 (x_0, ϵ) 变为 (x, v) 的二阶矩阵 R ，逐项计算 $R^T R$ 。
2. 用上一问的 R^T 恢复 x_0, ϵ ，分别写出公式。是否需要除以 a 或 b ？
3. 用 $\hat{v}$ 构造一致的 $\hat{x}_0, \hat{\epsilon}$ ；分别减去真实值，求 $\Delta x, \Delta\epsilon$ 与 Δv 的关系。
4. 把上一问平方并对坐标求和，推导无权重 v MSE 对数据 MSE 的因子，以及把噪声加权目标改成 v 输出时的正确权重。
5. 令 $a = \cos\phi, b = \sin\phi$ ，固定 x_0, ϵ ，求 $dx/d\phi$ 。若 $\phi = \phi(\tau)$ ，再求 $dx/d\tau$ ，说明为什么不能不经转换就把 v 当作任意时间下的速度。

7.9 分层提示与参考解答

题组 7A

第一层提示。 随机变量乘常数，其方差乘常数的平方。

第二层提示。 标准化数据对应 $c=1$ ；先保留 c ，就能看出假设的作用。

1. $ES = aEX_0 = 0$ ，而 $\text{Var}(S) = ES^2 = a^2c$ 。
2. 同理 $\text{Var}(N) = b^2$ 。独立性给出 $E[SN] = abEX_0E\epsilon = 0$ ，故协方差为零。
3. 代入求和公式得 $\text{Var}(X) = a^2c + b^2 = 1 + a^2(c-1)$ 。若 $c=1$ ，它恒为一；若 $c \neq 1$ ，一般随 a 改变。

4. 实际方差比为 $a^2 c / b^2$; 标准化后

$$SNR = \frac{\bar{\alpha}}{1 - \bar{\alpha}}.$$

移项得 $SNR(1 - \bar{\alpha}) = \bar{\alpha}$, 因此 $\bar{\alpha} = SNR / (1 + SNR)$ 。

5. 两次代入得到 $a_t^2 = (1 - \beta_2)(1 - \beta_1)$, 一般为

$$\bar{\alpha}_t = a_t^2 = \prod_{i=1}^t (1 - \beta_i), \beta_t = 1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}.$$

一般 $t \geq 2$ 时, 反求当前单步噪声还需要前一步累计系数; 首步已知 $\bar{\alpha}_0 = 1$, 则可直接求 $\beta_1 = 1 - \bar{\alpha}_1$ 。

题组 7B

第一层提示。 相减时, 观测 x 是相同的, 因而消去。

第二层提示。 先求误差的比例, 再平方; 不要把原系数直接当作 MSE 权重。

1. 先减去噪声, 再除以信号系数: $x - b\epsilon = ax_0$, 故 $x_0 = (x - b\epsilon) / a$ 。
2. 令 $\hat{x}_0 = (x - b\hat{\epsilon}) / a$, 相减得 $\Delta x = -(b/a)(\hat{\epsilon} - \epsilon)$ 。因此相同噪声误差会被 b/a 放大。
3. 反向构造 $\hat{\epsilon} = (x - a\hat{x}_0) / b$, 再减去 $(x - ax_0) / b$, 得到 $\Delta\epsilon = -(a/b)\Delta x$ 。
4. 每个坐标满足 $(\Delta\epsilon_i)^2 = (a^2/b^2)(\Delta x_i)^2$ 。求和便有

$$\|\Delta\epsilon\|^2 = \frac{a^2}{b^2} \|\Delta x\|^2 = SNR \|\Delta x\|^2.$$

5. 因而数据输出应使用 $w_t SNR_t$, 才能表示同一个目标。 $a=0$ 时不能用噪声估计除以 a 恢复原图; $b=0$ 时不能用原图估计除以 b 恢复噪声。端点要另行处理。

题组 7C

第一层提示。 矩阵乘积的对角元素是 $a^2 + b^2$, 非对角元素互相抵消。

第二层提示。 预测误差相减时, x 再次消去, 只剩预测 v 的误差。

1. 直接按定义写成

$$R = \begin{pmatrix} a & b \\ -b & a \end{pmatrix}, R^T R = \begin{pmatrix} a^2 + b^2 & ab - ab \\ ab - ab & a^2 + b^2 \end{pmatrix} = I.$$

2. 由 $R^{-1} = R^T$ 得 $x_0 = ax - bv$ 、 $\epsilon = bx + av$; 全程不必除以 a, b 。
3. 同一个 x 下, $\hat{x}_0 = ax - b\hat{v}$ 、 $\hat{\epsilon} = bx + a\hat{v}$, 所以 $\Delta x = -b\Delta v$ 、 $\Delta\epsilon = a\Delta v$ 。

4. 对内部时间 $b > 0$,

$$\begin{aligned}\|\Delta v\|^2 &= \frac{1}{b^2} \|\Delta x\|^2 = (1 + SNR) \|\Delta x\|^2, \\ w_t \|\Delta \epsilon\|^2 &= w_t a_t^2 \|\Delta v\|^2.\end{aligned}$$

第一个等号后的因子来自 $1/b^2 = (a^2 + b^2)/b^2$ 。

5. 逐项求导:

$$\frac{dx}{d\phi} = -\sin\phi x_0 + \cos\phi \epsilon = v, \quad \frac{dx}{d\tau} = \phi'(\tau) v.$$

因而 v 是角度参数下的导数; 换时间需乘链式系数。若路径本身改变, 矩阵与系数也要重推。例如 $(1-s)^2 + s^2$ 通常不等于一, 直线路径不能直接沿用本题旋转公式。

Part 8 Score Matching 与基于分数的生成模型

论文第 16 至第 20 页通过 Tweedie 关系、能量模型与 Langevin 采样连接扩散和 score。本章先建立去噪 score matching 的基础, 再由 Part 13 推出 Tweedie 的积分形式。[15]

8.1 Score 是密度变化的方向

前两章从似然界解释了噪声预测。本章换一个视角: 网络学到一个向量场, 告诉我们当前位置附近, 概率密度朝哪个方向增加得最快。这个向量场是 score。它为条件生成、逆 SDE 和概率流 ODE 提供共同语言。

对光滑正密度 $p(x)$, 定义

$$s_p(x) = \nabla_x \log p(x) = \frac{\nabla_x p(x)}{p(x)}.$$

若只学过一元导数, 可以先把“偏导数”理解为固定其他坐标、只对当前坐标求导; 把这些偏导数按坐标排列成向量, 就是梯度。

这里对数据坐标 x 求梯度, 与统计学中常见的“对模型参数求导的 score”应加以区分。score 与 x 维数相同, 是向量而不是样本质量分数。沿小位移 δ 有 $\log p(x+\delta) \approx \log p(x) + s_p(x)^T \delta$, 所以它描述局部相对密度变化, 不直接给出当前位置的概率。

例如 $p = N(m, c^2 I)$ 时, $s_p(x) = -(x-m)/c^2$: 远离均值时指回均值, 方差较小时作用更强。若模型写成 $p_\theta(x) = \exp[-E_\theta(x)]/Z_\theta$, 则

$$\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x).$$

因为归一化常数 Z_θ 不依赖 x , 对 x 求导后消失。由此产生一个诱人的想法: 学习 score, 或许可以绕过难以计算的密度归一化常数。[7]




图 8.1 同一加噪路径的概率密度与 score

图 8.1 的数据为两个一维高斯的等权混合，均值为 -2 和 2 ，各分量标准差为 0.35 。随噪声增加，双峰逐渐合并；右图画的是对数密度对位置的导数。score 为零只说明该处导数为零，也可能位于两个峰之间的局部低谷。图的解析表达式与时间系数见附录 B1。

8.2 不知道真实 score 怎样做 score matching

理想的平方距离目标是

$$J(\theta) = \frac{1}{2} E_{x \sim p} \|s_\theta(x) - \nabla_x \log p(x)\|^2.$$

但我们只有样本，并不知道 $\nabla \log p$ 。先展开平方：

$$J(\theta) = \frac{1}{2} E_p \|s_\theta\|^2 - \int s_\theta(x)^T \nabla p(x) dx + C,$$

其中 $C = 1/2 E_p \|\nabla \log p\|^2$ 与 θ 无关。对第 i 个坐标分部积分，

$$\begin{aligned} - \int s_{\theta,i}(x) \partial_i p(x) dx &= - \int \partial_i [p(x) s_{\theta,i}(x)] dx \\ &+ \int p(x) \partial_i s_{\theta,i}(x) dx. \end{aligned}$$

若边界项消失，就得到只需数据样本的目标

$$J(\theta) = E_p \left[\frac{1}{2} \|s_\theta(x)\|^2 + \nabla_x \cdot s_\theta(x) \right] + C.$$

这里 $\nabla \cdot s_\theta = \sum_i \partial_i s_{\theta,i}$ 是散度，即向量场对输入的 Jacobian 的迹。这就是经典 score matching 的核心转换。[7]

推导有条件：密度与模型向量场应足够可微，相关期望有限，并且无穷远处的边界积分为零。一个常用的充分条件是各坐标方向上的 $p(x) s_{\theta,i}(x)$ 充分衰减。有限区域有边界时不能自动删去这一项；原始数据若位于低维流形或只是经验点质量，也不能假定它有光滑密度。

这也是加噪的概念价值：它不仅制造待去除的干扰，还把离散样本周围铺成连续的概率质量。不同噪声级别描述的是不同平滑尺度上的数据结构。网络必须接收噪声级别，否则同一坐标处来自不同平滑密度的目标向量可能互相冲突。

虽然不知道的真实 score 消失了，散度在高维问题中仍有计算代价。接下来使用人为加噪，同时获得平滑密度和易计算的监督目标。

8.3 去噪 score matching 的目标来自哪里

对任意 $t > 0$ 且 $b_t > 0$ ，高斯扰动核为 $q(x_t|x_0) = N(a_t x_0, b_t^2 I)$ 。它关于含噪坐标的条件 score 可以直接求导：

$$\begin{aligned}\nabla_{x_t} \log q(x_t|x_0) &= -\frac{x_t - a_t x_0}{b_t^2} \\ &= -\frac{\epsilon}{b_t}.\end{aligned}$$

这里 x_0 在求导时保持固定。训练时我们既知道 x_0 ，也知道实际加入的噪声，因此目标向量完全可算。去噪 score matching (DSM) 使用

$$J_{DSM}(\theta) = \frac{1}{2} E_{t, x_0, \epsilon} \left[\omega_t \left\| s_\theta(a_t x_0 + b_t \epsilon, t) + \frac{\epsilon}{b_t} \right\|^2 \right], \omega_t > 0.$$

ω_t 是人为选择的时间权重。若直接输出向量场，这个目标不需要在损失中计算网络对输入的散度。DSM 与平滑后边缘密度的 score matching 有等价的优化目标；这一联系由 Vincent 的原论文建立，后续多噪声级别模型据此学习整条噪声路径。[8][9]

需要解释的关键还在后面：我们监督的是“给定原图”的条件 score，生成时需要的却是整个含噪数据分布 $q_t(x)$ 的边缘 score，为什么它们不会学错对象？

8.4 条件 score 的平均恰好是边缘 score

含噪边缘分布为

$$q_t(x) = \int q(x|x_0) p_{data}(x_0) dx_0.$$

在可以交换求导与积分、且 $q_t(x) > 0$ 的条件下，

$$\begin{aligned}\nabla_x \log q_t(x) &= \frac{\int \nabla_x q(x|x_0) p_{data}(x_0) dx_0}{q_t(x)} \\ &= \int \nabla_x \log q(x|x_0) \frac{q(x|x_0) p_{data}(x_0)}{q_t(x)} dx_0 \\ &= E[\nabla_x \log q(x|x_0) | x_t = x].\end{aligned}$$

最后一行利用贝叶斯公式。若原数据没有普通密度，第一行也可以理解为对数据概率测度积分；正方差高斯扰动仍可产生平滑边缘。真正需要检查的是求导与积分交换等正则条件。

平方损失的基本分解如下，其中 $m(X) = E[Y|X]$ ：

$$E\|f(X) - Y\|^2 = E\|f(X) - m(X)\|^2 + E\|Y - m(X)\|^2.$$

交叉项由于条件均值为零而消失。第二项不依赖 f ，所以最佳回归函数就是条件期望。把 $X = x_t$ 、 $Y = \nabla_{x_t} \log q(x_t|x_0)$ 代入，得到 DSM 的理想最优解

$$s_\theta^*(x, t) = \nabla_x \log q_t(x).$$

这不是说每个训练标签都等于边缘 score，而是说同一含噪状态对应的不同标签，经过后验加权平均后恰好得到它。这个“局部可算标签，经条件平均得到全局对象”的思想，后文还会在 Flow Matching 中再次出现。

8.5 噪声预测 score 与最优去噪器是同一组信息

对噪声 MSE，同样使用条件期望性质：

$$\epsilon^*(x, t) = E[\epsilon | x_t = x], \nabla_x \log q_t(x) = -\frac{\epsilon^*(x, t)}{b_t}.$$

所以网络不需要恢复每一次真正抽到的噪声，只需学会其条件平均，就足够构造正确的边缘 score。对任意噪声预测网络，也可以定义 $s_\theta(x, t) = -\epsilon_\theta(x, t)/b_t$ ；这是参数化转换，在最优学习条件下才等于真实边缘 score。

进一步对 $x_t = a_t x_0 + b_t \epsilon$ 取条件期望，得到最优均方去噪器

$$E[x_0 | x_t = x] = \frac{x + b_t^2 \nabla_x \log q_t(x)}{a_t}, a_t > 0.$$

这个式子把“沿密度梯度修正”与“预测干净数据”连起来，但它给出的是后验均值，不是从后验抽出的完整样本。多峰后验的均值可能处在两个合理解之间，解释了为什么一次均值去噪并不能替代完整生成过程。

若取 $s_\theta = -\epsilon_\theta/b_t$ ，DSM 中的平方误差变成 $\|\epsilon_\theta - \epsilon\|^2/b_t^2$ 。因此选择 $\omega_t = b_t^2$ 就得到与无权重噪声 MSE 成比例的目标；其他时间权重会重新分配噪声级别的训练力度。这也呼应了上一章参数化与权重必须一起讨论的结论。

8.6 有了 score 怎样产生样本

在固定的平滑密度 q_t 上，Langevin 更新具有形式

$$x^{k+1} = x^k + \eta s_\theta(x^k, t) + \sqrt{2\eta} z_k, z_k \sim N(0, I).$$

其中 k 是采样迭代序号，不是扩散时间。梯度项引导状态沿密度增加方向移动，随机项维持分布的扩散与探索。只做梯度上升会倾向于聚集在局部峰附近，不能保持目标分布的概率质量。

在真实 score 与适当条件下，相应连续 Langevin 动力学以 q_t 为不变分布；有限步长的离散更新一般有偏差，也需要足够混合时间。多噪声尺度生成可以由容易初始化的高噪声分布开始，再逐级降低噪声。另一条更系统的路径是学习连续时间 score，构造逆 SDE 或概率流 ODE；第 10 章将解释它们如何沿整条密度路径运行。[9]

8.7 例题与常见误区

例题。 设一维 x_0, ϵ 独立且都服从 $N(0, 1)$ ， $a=0.6, b=0.8$ 。求含噪边缘 score、最优噪声预测，并求噪声 MSE 最小可能达到的值。

解答。 因 $a^2 + b^2 = 1$ ， $x_t \sim N(0, 1)$ ，边缘 score 为 $-x$ 。又有 $\text{Cov}(\epsilon, x_t) = b$ ，所以 $\epsilon^*(x) = 0.8x$ ，满足 $-\epsilon^*/b = -x$ 。联合高斯的条件方差为 $\text{Var}(\epsilon|x_t) = 1 - b^2 = 0.36$ 。因此最优噪声 MSE 仍为 0.36，不可能降到零。非零训练损失可以包含不可约的条件不确定性，不能全部解释成网络能力不足。

误区。 条件 score $-\epsilon/b_t$ 是带有随机性的训练标签；边缘 score 是只依赖 x_t, t 的确定函数。score 指向局部密度增加的方向，却不是“离最近训练样本的最短方向”。纯数据端 $b_0=0$ 的除法没有定义，不能无条件把正噪声时间的公式代到该端点。

8.8 章末推导练习

本章先做一维普通导数，最后再把各坐标的结果放到一起。条件期望可暂理解为“固定观测以后，按剩余可能值的条件概率重新求平均”，不需要随机过程知识；基础规则见附录 A0。

题组 8A 从对数导数得到 score

已知与目标。 $p(x) > 0$ 且可微，定义 $s_p(x) = (\log p(x))'$ 。可用链式法则、 $\log u$ 的导数 $1/u$ 、一阶近似 $f(x+\delta) \approx f(x) + f'(x)\delta$ 。目标是算出高斯 score，并理解它不是概率值。

1. 对 $\log p(x)$ 使用链式法则，写出它与 $p'(x)$ 的关系。
2. 若 $p = N(m, c^2)$ ，先写对数密度，再对 x 求导；均值和方差在这里都是常数。
3. 将正密度乘以常数 C ，求对数导数；再对 $p_\theta = e^{-E_\theta}/Z_\theta$ 求导。这里 C, Z_θ 均与 x 无关。
4. 用一阶近似表示 $\log p(x+\delta) - \log p(x)$ 。若 score 为正，正的小位移意味着什么？
5. 若向量的各坐标独立且都具有方差 c^2 ，先把联合对数密度写成求和，再求每个偏导，组成向量 score。

题组 8B 用分部积分消去未知数据 score

已知与目标。 一维数据密度为 p ，模型输出为 s_θ 。令 $J = 1/2 \int p(s_\theta - p'/p)^2 dx$ 。假设这些函数可微、下列平方及导数积分有限，并有 $p(x)s_\theta(x) \rightarrow 0$ 当 $x \rightarrow \pm\infty$ 。可用

$$\int_A^B s p' dx = [ps]_A^B - \int_A^B p s' dx.$$

目标是从含未知 p'/p 的距离，得到只需数据样本与模型导数的目标。

1. 展开目标中的平方，把与 θ 无关的一项记作 C ；指出哪个交叉项还含未知的真实 score。
2. 在交叉项中约去 p ，把它改写成含 p' 的积分。
3. 暂时只在有限区间 $[A, B]$ 积分，使用给定规则，并保留边界项及其符号。
4. 令 $A \rightarrow -\infty, B \rightarrow +\infty$ ，利用给定边界条件；把剩下的积分重新写成期望，得到 score matching 目标。
5. 逐坐标重复第三、四问并求和，写出散度项。边界项非零时，哪一步失效？

题组 8C 从高斯条件 score 到边缘 score

已知与目标。 一维 $X = aX_0 + b\epsilon$ ， $b > 0$ ， $\epsilon \sim N(0, 1)$ 且与 X_0 独立。设原数据有密度 p_0 ，记 $K(x, x_0) = N(x; ax_0, b^2)$ 、 $q_t(x) = \int K p_0 dx_0$ 。目标是证明可算的条件标签为何能学到边缘 score。

可用规则。 贝叶斯公式；条件平均的线性；以及求导移入积分。平方回归假定 $E[Y^2] < \infty$ 。在本题中假定导数连续，且在所考察 x 的邻域， $|\partial_x K| p_0$ 被某个可积函数 $G(x_0)$ 上界控制，因此允许求导与积分交换。只知道可微，并不足以在任意问题里这样交换。

1. 保持 x_0 不变，对 $\log K(x, x_0)$ 求导，再代入 $x = ax_0 + b\epsilon$ 。
2. 先求 $q_t'(x)$ ，再除以 $q_t(x)$ ；使用 $K' = K(\log K)'$ 将结果写成一个加权平均。
3. 证明权重 $K(x, x_0)p_0(x_0)/q_t(x)$ 积分为一，用贝叶斯公式解释它，并将第二问改写为条件期望。
4. 固定输入 $X = x$ ，令 $m(x) = E[Y|X = x]$ 。把 $f(x) - Y$ 拆成两项，平方并取条件平均，证明最优平方回归输出为 $m(x)$ 。
5. 分别取 $Y = (\log K)'$ 和 $Y = \epsilon$ ，结合第三、四问，推导最优 score 与噪声预测的关系。
6. 将任意模型参数化为 $s_\theta = -\epsilon_\theta/b$ ，展开 DSM 平方误差；选择怎样的时间权重会得到无权重噪声 MSE？说明同样推导怎样用于向量。

8.9 分层提示与参考解答

题组 8A

第一层提示。对 x 求导, m, c, C, Z_θ 都保持不变。

第二层提示。独立坐标的密度相乘, 取对数后就能逐坐标求导。

1. 链式法则给出 $s_p(x) = p'(x)/p(x)$, 因此它衡量密度的相对变化率。
2. 从

$$\log p(x) = -\frac{1}{2} \log(2\pi c^2) - \frac{(x-m)^2}{2c^2}$$

求导, 第一项为零, 第二项导数为 $-(x-m)/c^2$ 。

3. $\log[Cp] = \log C + \log p$, 常数导数为零。故乘正常数不改变 score; 同理

$$\partial_x \log p_\theta = \partial_x [-E_\theta - \log Z_\theta] = -\partial_x E_\theta.$$

4. 对数密度差近似为 $s_p(x)\delta$ 。当二者都为正时, 附近密度增加; 这没有告诉我们 $p(x)$ 本身有多大。
5. 联合对数密度为常数减去 $\sum_i (x_i - m_i)^2 / (2c^2)$ 。对第 i 坐标求导得 $-(x_i - m_i)/c^2$; 合在一起为 $s_p(x) = -(x - m)/c^2$ 。

题组 8B

第一层提示。展开时交叉项里的二来自平方公式, 会与外面的二分之一相消。

第二层提示。对 $-\int s_\theta p'$ 分部积分, 所以边界项前有负号。

1. 展开得到

$$J = \frac{1}{2} \int p s_\theta^2 dx - \int p s_\theta \frac{p'}{p} dx + C,$$
$$C = \frac{1}{2} \int p \left(\frac{p'}{p} \right)^2 dx.$$

C 只涉及数据分布; 中间项仍与模型及未知数据 score 同时有关。

2. 因 $p > 0$, 中间项约分为 $-\int s_\theta p' dx$ 。
3. 保留有限区间边界:

$$-\int_A^B s_\theta p' dx = -[p s_\theta]_A^B + \int_A^B p s_\theta' dx.$$

4. 给定衰减条件使方括号趋于零。因此

$$J = \int p \left(\frac{1}{2} s_\theta^2 + s_\theta' \right) dx + C = E_p \left[\frac{1}{2} s_\theta^2 + s_\theta' \right] + C.$$

5. 对每个坐标只在该方向分部积分，其余坐标视为固定再积分；允许换序且各方向边界项为零时，

$$J = E_p \left[\frac{1}{2} \|s_\theta\|^2 + \sum_i \partial_i s_{\theta,i} \right] + C.$$

求和项就是散度。若边界项不为零，第四问不能删除它，原式要保留边界修正。

题组 8C

第一层提示。 条件 score 的导数只作用于含噪位置 x 。

第二层提示。 将边缘密度导数写成平均以后，认出权重是“看到 $X=x$ 后原图的后验密度”。

1. 对高斯对数密度求导：

$$\partial_x \log K = -\frac{x - a x_0}{b^2} = -\frac{\epsilon}{b}.$$

2. 按给定规则移动导数，再用链式法则：

$$\begin{aligned} q_t'(x) &= \int (\partial_x K) p_0 dx_0, \\ \frac{q_t'(x)}{q_t(x)} &= \int (\partial_x \log K) \frac{K p_0}{q_t(x)} dx_0. \end{aligned}$$

3. 权重的积分是 $\int K p_0 dx_0 / q_t(x) = 1$ 。分子是 (X, X_0) 的联合密度，除以观测边缘即为 $q(x_0|x)$ 。因此

$$\partial_x \log q_t(x) = E[\partial_x \log K(X, X_0) | X=x].$$

4. 固定 x 后 f, m 都是常数。用 $f - Y = (f - m) + (m - Y)$ 展开：

$$E[(f - Y)^2 | X=x] = (f - m)^2 + E[(m - Y)^2 | X=x],$$

因交叉项为 $2(f - m)(m - E[Y | X=x]) = 0$ 。第二项与 f 无关，第一项在 $f = m$ 时最小。

5. 条件标签回归的最优值是它的条件平均，故

$$s^*(x, t) = \partial_x \log q_t(x), \epsilon^*(x, t) = E[\epsilon | X=x].$$

将第一问放进第三问并取出常数 $-1/b$ ，得到 $s^* = -\epsilon^*/b$ 。单次噪声标签可以不同于这个平均。

6. 两个负号相减后，

$$\left(s_\theta + \frac{\epsilon}{b}\right)^2 = \frac{(\epsilon_\theta - \epsilon)^2}{b^2}.$$

因而取 $\omega_t = b_t^2$ ，即可抵消分母，得到与噪声 MSE 成比例的目标。向量高斯按坐标求导，平方改为各坐标平方和；条件平均也逐坐标进行，系数关系不变。

Part 9 条件扩散与无分类器引导

论文第 20 至第 22 页讲解条件生成、分类器引导与无分类器引导。本章沿用同一 Bayes 推导，并补充引导系数、训练中的条件丢弃及分布解释的适用边界。[15]

9.1 从生成一个样本到生成符合条件的样本

前面学习的是数据分布 $p_{data}(x_0)$ 。如果训练集还提供类别、文本、低分辨率图像或其他信息 c ，目标就变成条件分布 $p_{data}(x_0|c)$ 。条件决定希望生成什么，随机初始噪声则保留同一条件下的多样性。因此，“一段提示词对应唯一图像”不是条件生成模型的数学设定。本章用 p_t 表示真实前向边缘，即 Part 8 的 q_t ；它与生成模型 p_θ 不同。

最直接的做法保持前向加噪不变，只让去噪器读取条件：

$$\begin{aligned}x_t &= a_t x_0 + b_t \epsilon, \epsilon \sim N(0, I), \\a_t &= \sqrt{\bar{\alpha}_t}, b_t = \sqrt{1 - \bar{\alpha}_t}, \\L_{cond} &= E[\|\epsilon - \epsilon_\theta(x_t, t, c)\|^2].\end{aligned}$$

期望包括训练样本对 (x_0, c) 、时间和噪声。平方误差的最优解仍是条件期望，现在多知道了 c ： $\epsilon_\theta^*(x_t, t, c) = E[\epsilon | x_t, c]$ 。相应的条件 score 是

$$s_c(x_t, t) = \nabla_{x_t} \log p_t(x_t | c) = -\frac{E[\epsilon | x_t, c]}{b_t}, b_t > 0.$$

条件进入网络的途径可以是：把类别嵌入加到时间嵌入中；用条件产生归一化层的缩放和平移；让图像 token 以 cross-attention 读取文本 token；或把对齐的条件图像沿通道拼接。Part 1 的 attention 因而成为生成网络中“当前位置该读取哪段条件”的计算工具。这些是网络结构选择，不改变上面的概率目标。

这里还有一个值得明确的建模假设：前向噪声在给定干净样本后不额外依赖条件，即条件信息通过数据分布进入带噪边缘。训练中应当使用真实配对的数据和条件。若把图像与随机无关的文本配对，网络最优解就会学会忽略文本，增加引导尺度也无法补回没有学到的关联。若条件本身也需要加噪，则应重新写清联合过程，而不能仍把它视为固定不变的外部信息。

9.2 Bayes 公式为什么给出 classifier guidance

令 $s_0(x_t, t) = \nabla_{x_t} \log p_t(x_t)$ ，下标 0 在这里表示无条件分支，并非时间 $t=0$ 。对 Bayes 公式取对数，再对带噪样本求梯度：

$$\begin{aligned}\log p_t(x_t | c) &= \log p_t(x_t) + \log p_t(c | x_t) - \log p(c), \\s_c(x_t, t) &= s_0(x_t, t) + \nabla_{x_t} \log p_t(c | x_t).\end{aligned}$$

其中 $p(c)$ 与 x_t 无关，所以梯度为零。这个分解读：无条件 score 维持数据的合理性，分类器梯度增加当前样本属于目标条件的倾向。classifier guidance 使用额外分类器 $p_\phi(c|x_t, t)$ ，把梯度加到无条件 score 上，再交给反向采样器。[11]

分类器必须见过与采样匹配的噪声级别。只在干净图像上训练的分类器面对高噪声 x_t ，其梯度未必有正确的统计意义。“分类器能识别干净图片”不能推出“分类器能指导整个去噪过程”。在噪声预测参数化下，带尺度 g 的同一操作为

$$\hat{\epsilon} = \epsilon_\theta(x_t, t) - g b_t \nabla_{x_t} \log p_\phi(c|x_t, t).$$

负号来自 $s = -\epsilon/b_t$ 。不能把 score 空间中的加号原封不动地搬到噪声预测空间。这里也没有说“噪声向量越大，图像越符合条件”；真正控制采样行为的是预测量经过反向更新公式后的作用。

9.3 Conditional dropout 与 CFG

CFG 不另训分类器，而是让同一个去噪器同时学习条件和无条件预测。训练时，以固定概率 $p_{drop} \in (0, 1)$ 把整个条件替换为空条件 $\emptyset$ ，其余时候保留 c 。这个随机决定独立于数据内容；如果只丢弃某一类别，空分支学到的将是偏置后的分布。丢弃条件也不等于丢弃时间或带噪输入。

$$\tilde{c} = \begin{cases} \emptyset, & \text{概率 } p_{drop}, \\ c, & \text{概率 } 1 - p_{drop}, \end{cases}$$

$$L_{CFG_{train}} = E \|\epsilon - \epsilon_\theta(x_t, t, \tilde{c})\|^2.$$

采样时，对同一个 x_t, t 计算两次预测，并使用本讲义统一的尺度约定：

$$\hat{\epsilon}_g = \epsilon_\theta(x_t, t, \emptyset) + g [\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)].$$

$g=0$ 给出无条件预测， $g=1$ 给出普通条件预测， $0 < g < 1$ 是插值， $g > 1$ 是沿“条件减无条件”的方向继续外推。原始 CFG 论文写作 $(1+w)\epsilon_c - w\epsilon_0$ ，因此其 w 与这里的关系是 $g = 1 + w$ ，比较实现时必须先检查约定。[10]

由于从噪声预测到 score 的变换在固定时间是线性的，上式等价于 $\hat{s}_g = s_0 + g(s_c - s_0)$ 。两分支应使用相同的状态、时间和参数化。若一支输出噪声、一支输出干净样本，直接相减没有意义。空条件也应采用训练时的表示；随意删除输入字段不保证触发学过的无条件行为。




图 9.1 CFG 对预测向量进行插值与外推

图 9.1 是二维噪声预测空间中的教学示意，使用本讲义的 g 约定。虚线连接两次预测， $g=2$ 时沿同一方向再走一段；这幅图不表示图像像素或语义一定沿相同方向变化。

9.4 引导强度的概率解释及其边界

假设两个分支都给出精确 score。在一个固定噪声级别，利用梯度的线性性可得

$$\begin{aligned}\hat{s}_g(x, t) &= \nabla_x \log [p_t(x|c)^g p_t(x)^{1-g}] \\ &= \nabla_x \log [p_t(x) p_t(c|x)^g].\end{aligned}$$

若该表达式可归一化，它是一个瞬时幂密度的 score：与条件关联更强的位置会被放大。这有助于理解条件一致性与多样性之间的取舍，但不能直接推出最终样本严格服从 $p_0(x|c)^g p_0(x)^{1-g}$ 。原因是把每个时刻的密度分别做幂运算后，所得密度族一般不再满足原扩散过程的同一个前向方程；将这些 score 填入反向采样器，并未自动建立新的全程一致性。实际网络的向量场也未必是某个精确密度的梯度。

因此， $g > 1$ 是有用的采样控制手段，而不是“条件概率更正确”的证明。很大尺度会同时放大两分支误差，并可能降低多样性或产生过强的颜色、纹理。选择尺度应结合条件遵循程度和样本覆盖范围，而不是只看单张图像是否醒目。反过来，在理想 score、正确先验和精确积分等条件成立时， $g=1$ 才对应普通条件生成。

也要分清训练和采样各自增加了什么。普通条件扩散已经能响应条件，CFG 是在此基础上重组预测方向；它不是让无条件网络第一次理解文本的通用开关。其标准实现每步需要条件和空条件两次前向计算，可以把两份输入拼成一个批次，但这主要改变执行方式，并未消除两分支的计算量。另一方面，分类器引导通常需要对分类器的输入求梯度；CFG 用去噪器的两次预测替代这一操作。

9.5 例题 一次 CFG 计算

在一个二维位置, 设 $a_t=0.8, b_t=0.6$, $x_t=(0.2, 0.1)$, 无条件噪声预测分别为 $(0.2, -0.1)$ 与 $(0.1, 0.3)$ 。当 $g=2$ 时, 求引导预测、score 及对应的干净样本估计。

解。两分支的差为 $(-0.1, 0.4)$, 所以

$$\begin{aligned}\hat{\epsilon}_2 &= (0.2, -0.1) + 2(-0.1, 0.4) = (0, 0.7), \\ \hat{s}_2 &= -\hat{\epsilon}_2 / 0.6 = (0, -7/6), \\ \hat{x}_0 &= \frac{x_t - b_t \hat{\epsilon}_2}{a_t} = (0.25, -0.4).\end{aligned}$$

第二个噪声分量超过了两次原始预测, 体现外推; 干净样本估计的第二个分量却下降。这也说明噪声预测方向不能直接当成图像变化方向。 $\hat{x}_0$ 是供采样器使用的估计, 不是宣称此时已恢复真实训练样本。

9.6 易错点

易错点集中在三个层次: 把 $g=1$ 误认为“无引导”的无条件模型; 忘记噪声与 score 的负比例关系; 把固定时间的代数恒等式误当成最终分布定理。另一个常见遗漏是训练时没有条件丢弃, 却在采样时凭空加入空条件分支。

9.7 章末推导练习

先完成三组问题, 再查后面的提示。先把 x 当成实数; 推广到向量时, 梯度 ∇_x 就是各坐标偏导数组成的列向量。

题组 A 从 Bayes 公式得到条件 score

已知正密度 $p(x)$ 、正似然 $L(x)=p(c|x)$, 且 $p_c(x)=p(x)L(x)/Z$, 其中 Z 与 x 无关。目标是求 $s_c=(\log p_c)'$ 。可用 $\log(ab)=\log a+\log b$ 和 $(\log f)'=f'/f$ 。

A1. 写出 $\log p_c$, 保留归一化项。

A2. 逐项求导, 说明为什么 Z 消失, 并用 $s_0=(\log p)'$ 表示结果。

A3. 令 $p=N(0,1)$ 、 $L(x)=1/(1+e^{-2x})$ 。已知 $L'=2L(1-L)$, 求 $s_c(0)$ 。

A4. 令向量 $x \in \mathbb{R}^d$ 、 $p=N(0,I)$ 、 $L=1/(1+e^{-k^\top x})$ 。逐坐标推广 A2, 求条件 score。

A5. 在带噪状态 x_t 上使用 A2, 应当取 $p_t(c|x_t)$ 还是只在干净数据上得到的 $p(c|x_0)$? 说明理由。

题组 B 从 score 组合得到 CFG 系数

已知同一状态、同一时间的噪声预测 ϵ_0, ϵ_c , 并有 $s_0=-\epsilon_0/b_t$ 、 $s_c=-\epsilon_c/b_t$, $b_t>0$ 。目标是理解 $\hat{\epsilon}_g=\epsilon_0+g(\epsilon_c-\epsilon_0)$ 。

B1. 展开括号, 分别求两个分支前的系数。

B2. 代入 $g=0,1,2$, 判断哪一种是外推。

B3. 将 $\hat{\epsilon}_g$ 除以 $-b_t$, 逐项得到引导 score。

B4. 代入 A2, 并把结果与 $(1+w)\epsilon_c - w\epsilon_0$ 比较, 求 g, w 的关系。

B5. 若 $\epsilon_0=0.4, \epsilon_c=-0.2, b_t=0.5, g=1.5$, 分别通过噪声组合和 score 组合计算结果, 核对两条路线一致。

题组 C 配方得到局部高斯引导

已知一步候选变量 r 的密度为 $N(\mu, \sigma^2)$, 并在 μ 附近近似 $\log L(r) \approx K + \ell(r - \mu)$ 。引导后密度正比于原密度乘以 $L(r)^g$ 。目标是找出新均值; 可用 $(a-b)^2 = a^2 - 2ab + b^2$ 。

C1. 写出引导后对数密度, 丢弃与 r 无关的项。

C2. 令 $d=r-\mu$, 把含 d 的二次式配成一个平方。

C3. 从配方结果读出均值和方差, 说明梯度为什么乘以方差。

C4. 推广到正定、可逆的协方差矩阵 Σ 。已知原对数密度为 $-\frac{1}{2}d^T \Sigma^{-1}d$, 局部引导项为 $gh^T d$; 展开 $(d - g\Sigma h)^T \Sigma^{-1}(d - g\Sigma h)$, 求均值移动量。

C5. 取 $\mu=0.2, \sigma^2=0.04, \ell=3, g=2$, 求新均值。这个局部近似是否证明了整个多步采样的最终幂密度公式?

9.8 分层提示与参考解答

A 组提示。 先取对数, 再求导; 标准正态的对数密度只保留 $-x^2/2$ 。

A1. $\log p_c = \log p + \log L - \log Z$ 。

A2. Z 是常数, 导数为零, 因此 $s_c = p'/p + L'/L = s_0 + (\log L)'$ 。注意, 密度本身不能随意删掉归一化常数; 只有在这一步对位置求对数导数时, 常数才不影响结果。这个区分是使用 score 的关键。

A3. $s_0 = -x$, $L'/L = 2(1-L)$ 。零点处 $L=1/2$, 故 $s_c(0)=1$ 。也可用 $L(0)=L'(0)=1/2$ 核对。导数为正, 表示向右小幅移动会增加条件对数密度。

A4. 对第 i 个坐标, $\partial_i \log p = -x_i$, $\partial_i \log L = (1-L)k_i$ 。合并得 $s_c = -x + (1-L)k$ 。这里没有新算法: 先固定其余坐标, 对一个坐标应用一元链式法则, 再把得到的标量结果排成列向量。

A5. 由带噪联合分布的 Bayes 公式, 应使用 $p_t(c|x_t)$ 。干净分类器未必适用该噪声级别。

B 组提示。 同一时间的 b_t 是公共因子, 先处理线性组合, 不要猜符号。

B1. $\hat{\epsilon}_g = (1-g)\epsilon_0 + g\epsilon_c$, 系数和为一。

B2. 三种结果依次是 $\epsilon_0, \epsilon_c, 2\epsilon_c - \epsilon_0$; 最后一种超出两分支之间的线段。外推时系数虽然仍相加为一, 却有一个系数为负, 因而不是两个预测的普通加权平均。

B3. $\hat{s}_g = (1-g)s_0 + g s_c = s_0 + g(s_c - s_0)$ 。

B4. A2 给出 $\hat{s}_g = s_0 + g \nabla \log L$ 。比较噪声系数得 $g = 1+w$ 、 $1-g = -w$ 。

B5. 噪声差为 -0.6 ，所以 $\hat{e} = -0.5$ 、 $\hat{s} = 1$ 。另一路先算 $s_0 = -0.8, s_c = 0.4$ ，再得 $-0.8 + 1.5(1.2) = 1$ 。若两条路线符号不同，应先检查是否忘记了除以负的噪声尺度，而不是修改引导公式。

C 组提示。 先找平方中心，再把多出来的常数吸收进归一化项。

C1. 对数密度为 $-(r-\mu)^2/(2\sigma^2) + g\ell(r-\mu) + \text{常数}$ 。

C2. 配方的中间步骤是

$$-\frac{d^2 - 2g\sigma^2\ell d}{2\sigma^2} = -\frac{(d - g\sigma^2\ell)^2}{2\sigma^2} + \frac{g^2\sigma^2\ell^2}{2}.$$

C3. 新均值为 $\mu + g\sigma^2\ell$ ，方差仍为 σ^2 。原二次项决定了方差；方差越小，偏离原均值的代价越高。

C4. 展开得 $d^\top \Sigma^{-1}d - 2gh^\top d + g^2 h^\top \Sigma h$ 。最后一项与 r 无关，所以新均值是 $\mu + g\Sigma h$ 。协方差矩阵把不同方向的尺度也考虑进去；若各方向方差相同，取 $\Sigma = \sigma^2 I$ 就回到一维公式。

C5. 新均值为 $0.2 + 2(0.04)(3) = 0.44$ 。这里仅使用一个位置附近的对数似然线性近似；没有证明各时间幂密度满足同一演化方程，故不能推出全程终点结论。

Part 10 连续时间 ODE 与概率流

10 1 从离散噪声链到连续时间

先修桥梁。 本章的学习主线是“给定密度演化方程，推导一个确定性 ODE”，只需微积分。布朗运动可先理解为累计随机扰动：一段时间内的增量服从均值为零、方差等于时间长度的高斯分布，不相交时段的增量独立。它的路径不能按普通可微函数处理。反向 SDE 定理及 Fokker-Planck 方程在这里作为工具结论使用，随机过程层面的证明属进阶选读；章节末习题不依赖这些证明。

本章用 $\tau \in [0, 1]$ 表示扩散时间： $\tau = 0$ 是数据端， $\tau = 1$ 是噪声端。离散 DDPM 的 t 与连续 τ 方向相同。当每步噪声很小、时间网格很密时，可以用随机微分方程描述样本的连续演化：

$$dX_\tau = f(X_\tau, \tau)d\tau + g(\tau)dW_\tau.$$

f 是确定性漂移， W_τ 是标准布朗运动。本章的 $g(\tau)$ 表示扩散幅度，与 Part 9 的 CFG 引导常数 g 不同。假设它是不依赖状态的标量，噪声作用在所有坐标上；因此单位时间的噪声协方差为 $g(\tau)^2 I$ 。在正向步长 $h > 0$ 内，随机增量近似为 $g(\tau)\sqrt{h}\xi$ ，其中 $\xi \sim N(0, I)$ 。出现的是 $\sqrt{h}$ 而不是 h ，因为布朗增量的方差等于时间长度。

DDPM 对应的一个连续极限是方差保持型 VP SDE:

$$dX_\tau = -1/2\beta(\tau)X_\tau d\tau + \sqrt{\beta(\tau)}dW_\tau.$$

它在给定 $X_0=x_0$ 时仍有高斯形式, 均值系数为 $\exp[-\frac{1}{2}\int_0^\tau \beta(r)dr]$, 噪声方差为一减去该系数的平方。这解释了离散 $\bar{\alpha}_t$ 的连续对应物。有限时间的终端分布通常只是接近所选噪声先验, 不能把近似符号自动改成严格相等。[9]

10.2 反向 SDE 先确定时间方向 再写符号

记 $p_\tau(x)$ 为正向 SDE 的边缘密度, 并令 $s_\tau(x) = \nabla_x \log p_\tau(x)$ 。在所需光滑性、可积性以及时间反演条件成立时, 从 $\tau=1$ 向 0 运行的反向 SDE 为

$$dX_\tau = [f(X_\tau, \tau) - g(\tau)^2 s_\tau(X_\tau)]d\tau + g(\tau)d\bar{W}_\tau, d\tau < 0.$$

$\bar{W}$ 是按反向时间定义的布朗运动。这个表达式中的负号必须与 $d\tau < 0$ 一起读。实际程序若从 τ 走到 $\tau-h$, 可写成

$$X_{\tau-h} \approx X_\tau - h[f(X_\tau, \tau) - g(\tau)^2 s_\theta(X_\tau, \tau)] + g(\tau)\sqrt{h}\xi.$$

改用递增时间 $s=1-\tau$, 令 $Y_s = X_{1-s}$ 。此时漂移为 $-f+g^2 s_{1-s}$, 扩散项为 $g(1-s)dB_s$ 。时间反转同时改变漂移符号。

10.3 概率流 ODE 从哪里来

反向生成不一定需要每步加随机噪声。关键问题是: 能否找到确定性运动, 使大量样本在每个时刻的分布与扩散过程相同? 先从密度守恒推导。

上述正向 SDE 对应 Fokker-Planck 方程。利用 $\nabla p_\tau = p_\tau \nabla \log p_\tau$, 得到

$$\begin{aligned} \partial_\tau p_\tau &= -\nabla \cdot (f p_\tau) + 1/2 g^2 \Delta p_\tau \\ &= -\nabla \cdot [f - 1/2 g^2 \nabla \log p_\tau] p_\tau. \end{aligned}$$

而由速度场 $F(x, \tau)$ 驱动的 ODE 满足连续性方程 $\partial_\tau p_\tau = -\nabla \cdot (F p_\tau)$ 。对照两式, 得到概率流 ODE:

$$\frac{dX_\tau}{d\tau} = F(X_\tau, \tau), F(x, \tau) = f(x, \tau) - 1/2 g(\tau)^2 s_\tau(x).$$

它的 score 系数是 $1/2$ 。直接删除反向 SDE 的噪声项, 会留下系数 1, 并不等于这个 ODE。概率流构造的依据是密度方程一致, 而不是把随机路径“抹平”。在精确 score、相同起始边缘及适当解的唯一性条件下, SDE 和概率流 ODE 的每个时间边缘相同, 但它们的样本路径、跨时间联合分布和端点配对一般不同。[9]

对于 ODE，给定初始点就确定整条轨迹；生成结果仍然随机，因为初始噪声是随机的。如果从噪声向数据积分而采用 $s=1-\tau$ ，生成速度应为

$$\frac{dY_s}{ds} = U(Y_s, s), U(x, s) = -f(x, 1-s) + 1/2 g(1-s)^2 s_{1-s}(x).$$

这就是下一章 FM 学习速度场时的直接接口：FM 可以回归 U ，不必把网络输出解释为 score。

展开连续性方程，再沿轨迹使用链式法则，得到对数密度的变化：

$$\frac{d}{d\tau} \log p_\tau(X_\tau) = -\nabla \cdot F(X_\tau, \tau).$$

当速度场向外发散时，一小团概率质量占据的体积增大，密度降低；向内汇聚时则相反。散度是速度雅可比矩阵的迹，不是速度的大小。这为连续归一化流计算密度提供了入口：把状态与累积散度一起积分。不过，模型上这个等式针对模型自身的流密度；只有速度精确匹配目标时才等于真实数据密度。实际求解还可能涉及数值积分和迹估计误差，因此“理论上可计算似然”也需要与实现中的精度区分。

10 4 数值积分 模型正确也不等于一步采样正确

设生成方向 ODE 为 $dY_s/ds = U(Y_s, s)$ ，步长 $h>0$ 。Euler 法使用当前位置的切线；Heun 法先预测下一点，再平均两端斜率：

$$\begin{aligned} \text{Euler: } Y_{k+1} &= Y_k + h U(Y_k, s_k), \\ k_1 &= U(Y_k, s_k), \tilde{Y} = Y_k + h k_1, \\ k_2 &= U(\tilde{Y}, s_k + h), \\ \text{Heun: } Y_{k+1} &= Y_k + h/2 (k_1 + k_2). \end{aligned}$$

在速度场足够光滑、步长处于稳定范围的通常条件下，Euler 的单步局部误差为 $O(h^2)$ 、固定区间全局误差为 $O(h)$ ；Heun 分别是 $O(h^3)$ 和 $O(h^2)$ 。这里的阶数针对 ODE，不应直接套用到含布朗噪声的 SDE。Heun 每步通常需要两次网络求值，比较效率时应看总网络调用次数，而不只看“步数”。

生成误差至少有三个来源：终端先验与真实 p_1 不完全匹配，网络预测有误差，积分存在离散误差。增加步数主要减少第三项；如果 score 学错了，更精确地积分仍会得到错误流。靠近端点时，涉及除以很小噪声尺度的参数化还可能放大数值误差，需要匹配的时间网格、端点处理或更稳定参数化。

误差还会随动力系统传播。若相邻位置的速度差不超过距离的某个固定倍数，局部状态误差就可标准稳定性分析控制；但这个倍数很大时，早期的小偏差仍可能被放大。因此，高阶方法的误差阶数不是任何大步长下的质量保证。自适应求解器通常比较两个近似结果来估计局部误差，据此调整步长；它控制的是当前网络定义的微分方程的积分精度，而不是直接评估生成内容是否正确。学习目标和数值目标服务于不同层面。

10 5 例题 同一分布可以有完全不同的路径

设 $X_0 \sim N(0,1)$ ，正向过程为 $dX_\tau = dW_\tau$ 。求边缘密度及概率流 ODE，并解释两者为何路径不同。


解。独立高斯方差相加，所以 $p_\tau = N(0, 1+\tau)$ ，score 为 $-x/(1+\tau)$ 。这里 $f=0, g=1$ ，因而

$$\frac{dX_\tau}{d\tau} = \frac{X_\tau}{2(1+\tau)}, X_\tau = \sqrt{1+\tau} X_0.$$

ODE 只按确定比例放大初始点，其方差也是 $1+\tau$ 。布朗 SDE 则沿途不断加入新的随机量。两者任意时刻的直方图相同，但 ODE 的两个时刻完全由同一个初始变量关联，SDE 则还包含后续噪声。反向 ODE 从方差 2 的分布起步，在 $\tau=0$ 恢复方差 1；这个例子应使用 $N(0,2)$ 作为精确终端分布，不能随手换成标准正态。

同一时间边缘，不同样本路径

教学例： $X_0 \sim \mathcal{N}(0, 1)$ ；扩散时间 τ 从数据走向噪声。



两者的解析边缘均为 $p_\tau = \mathcal{N}(0, 1+\tau)$ 。

图中仅画 8 条示意路径；边缘相同不表示逐条路径或有限样本相同。

图 10.1 同一初始分布下的随机扩散与确定性概率流

图 10.1 教学例从 $X_0 \sim N(0,1)$ 出发。左侧在 500 个时间小段上生成独立高斯增量，展示 $dX_\tau = dW_\tau$ 的八条示意路径；右侧从同样的八个初始值出发，绘制精确 ODE 解 $X_\tau = \sqrt{1+\tau} X_0$ 。两者的解析边缘分布均为 $N(0, 1+\tau)$ ，这一结论不是由八条轨迹的经验直方图估计得到的，也不要求同色轨迹逐点相同。此例终端分布为 $N(0,2)$ 。

若用一个 Euler 大步直接从噪声端积分回数据端，初始斜率为 $X_1/4$ ，因此结果为 $3X_1/4$ ，而精确答案是 $X_1/\sqrt{2}$ 。一步近似的方差为 $9/8$ ，并非目标方差 1。这里 score 完全正确，误差仍然存在；它单独来自积分离散化，正好说明解析概率流与有限步采样器需要分别验证。

10 6 易错点

最需要避免的是同时混淆时间方向、score 系数和噪声增量尺度。此外，标量且不依赖状态的 g 是本章公式的明确假设；一般矩阵或状态相关扩散会出现额外结构，不能机械照抄简式。

10 7 章末推导练习

本组只需一元求导、定积分和链式法则。Fokker-Planck 方程及反向 SDE 是本讲义提供的工具结论，不要求从随机过程理论独立证明；以下推导也不构成这些定理的证明。

题组 A 从小区间守恒得到连续性方程

已知一维光滑密度 $p(x, \tau)$ 、速度 $F(x, \tau)$ ，概率通量定义为 $J = pF$ ，表示单位时间向右通过某点的概率质量。目标是求密度演化方程。可用微积分基本定理，并假设能交换时间微分与积分。

A1. 用积分写出区间 $[a, b]$ 内的概率 $M(\tau)$ 。

A2. 左边流入、右边流出，写出 $M'(\tau)$ 与 $J(a, \tau), J(b, \tau)$ 的关系。

A3. 用微积分基本定理把通量差改成区间积分，再与 A1 的导数合并。

A4. 假设连续函数在所有区间上的积分都为零，为什么它处处为零？由此写出点态连续性方程。

A5. 向量情况下定义 $\nabla \cdot J = \sum_i \partial J_i / \partial x_i$ 。把每个坐标的流出相加，写出向量版本。

题组 B 从给定密度方程找到半系数

给定工具公式

$$\partial_\tau p = -\partial_x(f p) + 1/2 g(\tau)^2 \partial_{xx} p.$$

假设 $p > 0$ ，记 $r = \partial_x \log p$ 。目标是将它写成 A4 的形式；可用乘积求导。

B1. 用 p, r 表示 $\partial_x p$ 。

B2. 再求一次空间导数，改写 $\partial_{xx} p$ 。

B3. 将两项合进同一个 $-\partial_x$ ，读出概率流速度 F 。

B4. 若误取 $\tilde{F} = f - g^2 r$ ，代入连续性方程后扩散项系数是多少？与给定工具公式比较。

B5. 对 $p_\tau = N(0, 1 + \tau)$ 、 $f = 0, g = 1$ ，先写对数密度中与 x 有关的项，再求 r 和 F 。

题组 C 时间反转与两种积分方法

沿用 B5。生成时间取 $s = 1 - \tau$ ， $Y_s = X_{1-s}$ 。目标是从 $s = 0$ 走到 1；可用链式法则。Euler 更新为 $y + hU(y, s)$ ；Heun 先算 $k_1 = U(y, s)$ 、 $\tilde{y} = y + hk_1$ ，再返回 $y + \frac{h}{2}[k_1 + U(\tilde{y}, s + h)]$ 。

C1. 根据 $d\tau/ds = -1$ ，求生成速度 $U(y, s)$ 。

C2. 对 $Y_s = \sqrt{(2-s)/2} Y_0$ 求导，验证它满足 C1 和初值；写出精确终点。

C3. 取一步 $h=1$, 由 Y_0 计算 Euler 终点。

C4. 写出 Heun 的两次斜率和一步终点, 与精确缩放系数 $1/\sqrt{2}$ 比较。

C5. 给定反向 SDE 的漂移项为 $(f - g^2 r) d\tau$, 其中 $d\tau < 0$ 。改用增加的 s 后漂移系数是什么? 这一步是否证明了随机过程的时间反演定理?

10.8 分层提示与参考解答

A 组提示。 质量变化等于流入减流出; 把每项都写成同一个区间上的积分。

A1. $M(\tau) = \int_a^b p(x, \tau) dx$ 。

A2. $M' = J(a, \tau) - J(b, \tau)$, 右端符号由向右流动的约定确定。先想象没有右端流出, 则左端正通量会增加区间质量; 再想象没有左端流入, 则右端正通量会减少质量。这能独立检查两个符号。

A3. 通量差为 $-\int_a^b \partial_x J dx$, 所以

$$\int_a^b [\partial_\tau p + \partial_x(pF)] dx = 0.$$

A4. 若某点的函数值为正, 连续性保证附近一小段仍为正, 该段积分就不可能为零; 负值同理。因此 $\partial_\tau p = -\partial_x(pF)$ 。必须要求所有小区间都满足守恒; 仅知道整个实线上的总积分不变, 还不足以确定局部概率怎样搬运。

A5. 各坐标净流出相加给出 $\partial_\tau p = -\sum_i \partial_i(pF_i) = -\nabla \cdot (pF)$ 。二维时可先看小长方形的左右两边, 再看上下两边; 两组净流出相加, 正好对应两个偏导项。

B 组提示。 g 不依赖 x , 可以移入空间导数; 不要把它误当成状态函数。

B1. $r = (\partial_x p)/p$, 所以 $\partial_x p = pr$ 。

B2. $\partial_{xx} p = \partial_x(pr)$ 。

B3. 因而

$$\partial_\tau p = -\partial_x [fp - 1/2 g^2 pr], F = f - 1/2 g^2 r.$$

B4. 错误速度给出 $-\partial_x(fp) + g^2 \partial_{xx} p$, 系数加倍。删除反向 SDE 的噪声项并不能保持原来的密度方程。半系数来自这次逐项对照; 无需通过猜测随机轨迹的形状来决定。

B5. $\log p_\tau = -x^2/[2(1+\tau)] +$ 与 x 无关的项, 故 $r = -x/(1+\tau)$ 、 $F = x/[2(1+\tau)]$ 。

C 组提示。 只对 ODE 使用普通链式法则; 两次 Heun 斜率必须在不同位置、不同时间计算。

C1. $U(y, s) = -F(y, 1-s) = -y/[2(2-s)]$ 。

C2. 设 $c(s) = \sqrt{(2-s)/2}$, 则 $c' = -c/[2(2-s)]$, 且 $c(0) = 1$ 。终点为 $Y_1 = Y_0/\sqrt{2}$ 。

C3. 初始斜率 $k_1 = -Y_0/4$ ，因此 Euler 返回 $3Y_0/4$ 。虽然真实轨迹的斜率随时间变化，Euler 在整个大步中只使用起点斜率；所以即使速度模型完全正确，仍会有离散误差。

C4. 预测点为 $3Y_0/4$ ，第二斜率是 $-3Y_0/8$ ，故

$$Y_1^{Heun} = Y_0 + 1/2(-Y_0/4 - 3Y_0/8) = 11Y_0/16.$$

缩放系数分别为 0.75, 0.6875，精确值约 0.7071；此例 Heun 更接近，但不代表任何大步长都准确。检查第二次斜率时，要同时把位置换成预测点、时间换成终点。只更新其中一个输入，便不是这里定义的 Heun 法。

C5. 因为 $d\tau = -ds$ ，漂移变为 $-f + g^2 r$ ，所有时间参数同时换成 $1-s$ 。这只是给定漂移的符号变换；布朗运动如何反演仍属于所给工具定理，不能把布朗路径当普通可微函数求导。

Part 11 Flow Matching 核心理论

11.1 先设计分布怎样变化 再学习搬运速度

先修桥梁。“分布路径”表示每个时间各有一份概率分布；“边缘”表示不再追踪端点配对标签。“正则性”概括足够光滑、可积等保证操作合法的条件。初学者可先完成有限加权平均和一维导数习题；关于奇异分布、流的全程存在与唯一性的讨论作为进阶选读，不能省略其条件后推广结论。

FM 采用生成时间 $s \in [0, 1]$ ： $s=0$ 是噪声， $s=1$ 是数据，与上一章的扩散时间 τ 方向相反。设 $z \sim p_{noise}$ 、 $y \sim p_{data}$ 。希望学习速度网络 $u_\theta(x, s)$ ，使

$$\frac{dY_s}{ds} = u_\theta(Y_s, s), Y_0 \sim p_{noise}, Y_1 \sim p_{data}.$$

问题不在于“给一个点预测另一个点”这么简单。每个时刻都有一群样本，速度必须同时安排概率质量的汇入和流出。设人为选定的中间密度为 p_s ，理想速度 u_s 应满足连续性方程

$$\partial_s p_s(x) + \nabla \cdot (p_s(x) u_s(x)) = 0.$$

在一个小区域内，概率增加量等于边界净流入量，这就是该式的直觉。给定密度路径并不总能唯一确定速度场：某些循环运动可以改变轨迹而不改变密度。因此 FM 还需要选择一个便于监督的速度构造，然后用回归拟合它。[12]

严格地把速度积分成可逆流，需要存在性和唯一性等条件；例如局部光滑性可以防止同一初始点出现互不相容的后续轨迹。对于终点集中在低维集合或离散经验点的数据分布，完全无噪声的极限可能使端点速度变得不规则。因此，理论推导常在内部时刻讨论光滑密度，再处理终点极限或保留很小平滑噪声。这不是额外的训练技巧，而是区分有限时间光滑可逆变换与奇异分布极限所必需的数学条件。

11.2 为什么单样本的简单路径能组成复杂分布

引入辅助条件变量 C ，它可以是一个数据端点，也可以是一对端点；用 κ 表示其取值，以区别外部语义条件 c 。先考虑对每个 $C=\kappa$ 都有普通条件密度 $p_s(x|\kappa)$ 和生成它的速度 $u_s(x|\kappa)$ 的情形。令 $q(\kappa)$ 是固定的辅助变量分布，则

$$\begin{aligned} p_s(x) &= \int p_s(x|\kappa) q(\kappa) d\kappa, \\ u_s(x) &= E[u_s(X_s|C) | X_s=x]. \end{aligned}$$

第二式是后验平均，权重为 $q(\kappa|x,s)$ ，不是简单地对所有端点等权平均。站在某个位置 x ，只能根据“哪些条件路径可能在此时到达这里”分配权重。若两个条件路径在同一时刻靠近该点，网络得到的是它们局部速度的加权平均，而非知道当前点秘密属于哪条路径。

条件连续性方程可以证明这个构造正确。在允许交换积分和微分，并有合适可积性及边界条件时，

$$\begin{aligned} \partial_s p_s(x) &= \int \partial_s p_s(x|\kappa) q(\kappa) d\kappa \\ &= -\nabla \cdot \int p_s(x|\kappa) u_s(x|\kappa) q(\kappa) d\kappa \\ &= -\nabla \cdot [p_s(x) u_s(x)]. \end{aligned}$$

最后一步利用 Bayes 权重。因此，许多易处理的条件路径可以通过后验速度平均，产生目标边缘路径。在流与连续性方程满足相应存在唯一性条件时，边缘 ODE 保持各时刻的总体分布，不必保持最初用于训练样本的端点配对。若给定端点对后路径完全确定，条件分布是点质量，应改用 Part 12.1 的弱形式论证。

11.3 CFM 与 FM 的损失为什么只差常数

理想 FM 损失为 $L_{FM} = E \|u_\theta(X_s, s) - u_s(X_s)\|^2$ ，但边缘速度的后验平均通常算不出来。CFM 用可计算的条件速度 $V = u_s(X_s|C)$ 替换目标：

$$L_{CFM} = E \|u_\theta(X_s, s) - V\|^2.$$

令 $m = E[V | X_s, s] = u_s(X_s)$ 。加减 m 并展开平方：

$$\begin{aligned} L_{CFM} &= E \|u_\theta - m\|^2 + E \|V - m\|^2 \\ &\quad + 2E[(u_\theta - m)^\top (m - V)] \\ &= L_{FM} + E \|V - m\|^2. \end{aligned}$$

交叉项为零，因为给定 X_s, s 后， $u_\theta - m$ 已确定，而 $E[m - V | X_s, s] = 0$ 。第二项是不能从当前位置确定条件路径所造成的条件方差。只要路径、时间采样分布和条件变量分布不依赖 θ ，它就是与网络参数无关的常数；因而两种损失的期望梯度相同。这是可执行训练目标成立的核心，不是声称每个 minibatch 的梯度完全一样。[12]

如果网络能力充分，最优输出是 m 。即使边缘速度已完全学对，CFM 损失也可能大于零，因为同一输入对应不同的条件速度。若把可训练参数放进路径或配对规则，却忽略它们的分布导数，上述“只差常数”结论不能直接沿用。

11.4 高斯条件路径及线性插值

一种便于实现的构造是固定 y ，令 $z \sim N(0, I)$ 且与 y 独立，并设

$$X_s = \mu_s(y) + \sigma_s(y)z, \sigma_s(y) > 0.$$

其条件密度为 $N(\mu_s(y), \sigma_s(y)^2 I)$ 。保持同一个 z 求时间导数，再用 $z = (x - \mu_s)/\sigma_s$ 消去 z ：

$$u_s(x|y) = \mu'_s(y) + \frac{\sigma'_s(y)}{\sigma_s(y)}(x - \mu_s(y)).$$

这是对应仿射条件流的速度；并不意味着所有产生该高斯密度的速度都唯一。取

$\mu_s(y) = a(s)y, \sigma_s(y) = b(s)$ ，训练样本和标签就成为

$$X_s = a(s)y + b(s)z, V = a'(s)y + b'(s)z.$$

最直观的特例是 $a(s) = s, b(s) = 1 - s$ ：

$$X_s = (1-s)z + sy, V = y - z, L = E \|u_\theta(X_s, s) - (y - z)\|^2.$$

每对端点的插值是匀速直线，所以标签与时间无关。但是网络只看到 X_s, s ，因此它学到的是条件期望 $E[y - z | X_s, s]$ ，实际 ODE 轨迹一般仍会弯曲。 $b(1) = 0$ 时，高斯条件密度退化成点质量；涉及 $1/b$ 的推导适用于内部时刻，端点须用极限或直接标签处理。若保留 $b(1) = \sigma_{\min} > 0$ ，终点变成经过高斯平滑的数据分布，需明确这一近似。




图 11.1 条件直线路径与边缘速度场的生成轨迹

图 11.1 左侧从独立的 $Z \sim N(0, 1)$ 与 $Y \sim N(2, 0.5^2)$ 构造训练路径；右侧积分这些路径对应的边缘速度场。右侧轨迹通常弯曲，却在每个时刻具有同样的总体边缘分布。有限条示意线不构成经验分布相等的验证；解析证明见附录 B2。

11 5 训练不积分 生成仍要积分

一次训练迭代只需抽取数据 y 、噪声 z 和时间 s ，直接计算 X_s 与标签 V ，再完成普通平方误差反向传播。无需先求解 ODE 才得到训练输入，也无需对求解器反向传播。这是 FM 所说的 simulation-free training。[12]

生成时却没有真实数据端点 y 。只能从新噪声出发，反复调用 u_θ 并数值积分直到 $s=1$ 。不能拿训练时的 $y-z$ 直接完成生成，因为那等于提前知道答案。“无需模拟训练”与“无需迭代采样”是两回事，后者需要路径、网络 and 求解器共同支持。

实践中还要区分形状相同但含义不同的预测量：本讲义始终把 FM 速度写作 u_θ ；Part 7 的扩散 v -prediction 是另外定义的线性组合。两者可在特定路径下换算，但不能仅凭都叫 velocity 就直接复用标签。

11 6 例题 完全学对仍有正损失

设在某个固定位置和时间，有两条条件路径以相等后验概率给出一维速度 $V=+2$ 和 $V=-2$ 。求最优网络输出、最小 CFM 损失和对应 FM 损失。

解。若输出为 r ，局部 CFM 风险为

$$1/2(r-2)^2 + 1/2(r+2)^2 = r^2 + 4.$$

最优输出为 $r=0$ ，即后验平均速度；最小 CFM 损失为 4。此时边缘目标也是 0，所以局部 FM 损失为零。差值 4 正是条件速度的方差。该例不是说概率不再移动，而是说明此位置两类条件流的净速度抵消；其他位置和时刻仍可有非零流动。

这也提供了判断训练曲线的方法：不同路径的条件速度方差可以不同，因而不能仅凭原始平方损失更低，就判定模型的最终分布更准确。要比较可学习程度和生成误差，需要结合目标尺度、边缘速度近似程度以及实际采样结果。

11 7 易错点

容易混淆的对象是：训练配对的随机插值路径、它们在各时刻的边缘分布，以及拟合边缘速度后产生的确定性 ODE 轨迹。理论连接三者的分布，却没有宣称三者逐条相同。

11 8 章末推导练习

先在一维计算。条件期望 $E[V|X=x]$ 可以理解为“已知当前位置后，仍可能出现的标签的加权平均”；不需要提前掌握测度论。

题组 A 由插值路径求速度标签

已知固定端点 z, y , $X_s = a(s)y + b(s)z$, 且 $a(0)=0, b(0)=1, a(1)=1, b(1)=0$ 。目标是求沿路径的速度。可用常数倍和求导法则。

A1. 分别代入 $s=0, 1$, 核对起点与终点。

A2. 求 $V = dX_s/ds$, 说明求导时哪些量保持不变。

A3. 在 $b(s)>0$ 处由 $x = a(s)y + b(s)z$ 解出 z , 代入 A2, 求给定 y 的速度 $u_s(x|y)$ 。

A4. 令 $a=s, b=1-s, z=-1, y=3$, 计算 $s=1/4, 1/2$ 时的位置和速度。

A5. 对向量逐坐标重复 A2。写出输入、标签的维度, 说明标签公式不含时间是否足以删除网络的时间输入。

题组 B 从加权平方误差求条件均值

在固定位置和时间, 标签 V 以概率 $3/4$ 等于 2 , 以概率 $1/4$ 等于 -2 。网络输出实数 r 。目标是最小化 $L(r) = E(r - V)^2$; 可用二次函数求导。

B1. 求标签均值 m 。

B2. 把两种标签分别代入损失, 展开并合并同类项。

B3. 对 r 求导, 找出极小点和最小损失。

B4. 直接计算 $E(V - m)^2$, 将 B2 改写为“到均值的平方距离加常数”。

B5. 把输出推广为向量 r , 令 $m = E[V|X_s, s]$, 展开 $\|r - V\|^2$ 。给定 X_s, s 后, 交叉项的条件期望为什么为零? 可用 $\|v\|^2 = \sum_i v_i^2 = v^\top v$ 。

题组 C 从条件回归到 FM 与弱守恒

已知路径及标签分布固定, 不依赖 θ , 各期望有限且允许对参数求导, $V = dX_s/ds$, $u_s(x) = E[V|X_s=x, s]$ 。目标是联系损失与概率守恒。可用“先条件平均, 再总体平均”等于原期望; 微分与期望可交换。另给一维分部积分 $\int \phi' q = -\int \phi q'$, 其中测试函数 ϕ 在某个有限区间外为零, 故边界项消失。

C1. 对 B5 再作总体平均, 写出 CFM 损失与 FM 损失的差。

C2. 为什么这个差对 θ 的导数为零? 如果配对分布也依赖 θ , 还可以直接这样说吗?

C3. 用链式法则求 $dE[\phi(X_s)]/ds$ 。

C4. 先给定 X_s 求条件期望, 把 C3 中的 V 换成 $u_s(X_s)$ 。若 X_s 有光滑密度 p_s , 把期望改成积分, 再作分部积分。

C5. 比较 C4 与 $\frac{d}{ds} \int \phi p_s = \int \phi \partial_s p_s$, 识别连续性方程。若条件路径是一个确定点而没有普通密度, C3 的期望等式还能使用吗?

11.9 分层提示与参考解答

A 组提示。 端点固定，时间变化只来自 a, b ；先求导，再消去未知噪声端点。

A1. $X_0 = z, X_1 = y$ 。

A2. $V = a'y + b'z$ ； y, z 的时间导数均为零。

A3. $z = (x - ay)/b$ ，所以 $u_s(x|y) = a'y + (b'/b)(x - ay)$ 。这一步将“依赖初始噪声的导数”改写成“当前位置上的速度”；除法要求噪声系数非零，不能在退化端点直接使用。

A4. $X_s = -1 + 4s$ ，两个位置依次是 0, 1，速度始终为 4。从第一个时刻到第二个时刻，位置增加一，时间增加四分之一，二者相除仍为四，与求导结果一致。

A5. 若端点属于 $\mathbb{R}^d$ ，则 $X_s, V \in \mathbb{R}^d$ ，且 $V_i = a'y_i + b'z_i$ 。网络学的是已知位置后的平均标签；不同时间的位置后验不同，仍需输入时间。

B 组提示。 展开后检查一次项；不可把不同标签的误差先平均再平方。

B1. $m = (3/4)2 + (1/4)(-2) = 1$ 。

B2. $L = (3/4)(r-2)^2 + (1/4)(r+2)^2 = r^2 - 2r + 4$ 。

B3. $L' = 2r - 2 = 0$ 给出 $r = 1$ ， $L'' = 2 > 0$ ；最小损失为 3。最优预测既不是始终猜较常见的标签二，也不是在两个标签之间随机猜，而是输出它们的概率加权均值。

B4. 方差为 $(3/4)(2-1)^2 + (1/4)(-2-1)^2 = 3$ ，故 $L = (r-1)^2 + 3$ 。

B5. 分解 $r - V = (r - m) + (m - V)$ ，得到

$$\|r - V\|^2 = \|r - m\|^2 + \|m - V\|^2 + 2(r - m)^\top (m - V).$$

给定当前位置后 $r - m$ 固定，且 $E[m - V | X_s, s] = 0$ ，所以交叉项平均为零。也可以逐坐标使用一维配方后相加，得到同一向量恒等式。

C 组提示。 前两问是平方误差分解，后三问是用测试函数观察整体概率质量。

C1. 取 $r = u_\theta(X_s, s)$ ，总体平均给出

$$L_{CFM} - L_{FM} = E\|V - u_s(X_s)\|^2.$$

C2. 右端仅由固定路径和真实条件均值决定，所以两损失期望梯度相同。若采样分布依赖参数，右端可能随参数变化，还会出现分布导数，不能直接忽略。

C3. 先逐条路径求导，再平均，得 $\frac{d}{ds} E\varphi(X_s) = E[\varphi'(X_s)V]$ 。这里测试函数可以理解为观察当前位置的一个光滑读数；我们追踪的是这项读数在样本群体中的平均怎样变化。

C4. 给定 X_s 时 φ' 固定, 因此

$$\begin{aligned} E[\varphi'(X_s)V] &= E[\varphi'(X_s)u_s(X_s)] \\ &= \int \varphi'(x)p_s(x)u_s(x)dx \\ &= -\int \varphi(x)\partial_x(p_s u_s)dx. \end{aligned}$$

C5. 对所有上述测试函数, $\int \varphi[\partial_s p_s + \partial_x(p_s u_s)] = 0$, 在光滑情形得到连续性方程。若括号内在某个小区间始终为正, 选择仅在该区间为正的测试函数, 就会得到矛盾; 负值同理。确定点仍可计算 $\varphi(X_s)$, 所以期望形式有效; 不能把点质量当普通密度求导。由弱守恒进一步得到唯一 ODE 流, 还需正文所述正则性条件。

Part 12 条件 FM OT 与 Rectified Flow

12.1 两种条件与端点配对

先修桥梁。 Coupling 在有限例子中就是一张总和为一的配对概率表; OT 是在保持行列概率不变时, 让平均运输代价最小。理解本章主线只需解下面的二乘二问题。Wasserstein 测地线指分布空间中相应距离下的最短路径, 它与全局运输理论的关系作为进阶选读, 不是完成基础习题的先修要求。

CFM 的 conditional 首先指为了构造易监督路径而引入的辅助变量, 例如给定数据端点 y , 或给定端点对 (z, y) 。它不要求用户提供提示词, 也不等于“条件图像生成”。如果还要按文本或类别 c 生成, 则让网络读取 c , 在给定 c 的样本分布上训练 $u_\theta(x, s, c)$ 。辅助路径条件和外部语义条件可以同时存在, 应当分开命名。

至今我们常常独立采样 z 与 y 。更一般地, 指定联合分布 $\pi(z, y)$, 只要求边缘分别是 p_{noise} 与 p_{data} 。这个联合分布称为 coupling, 即端点配对规则。在线性插值下,

$$(z, y) \sim \pi, X_s = (1-s)z + sy, u_s(x) = E_\pi[y - z | X_s = x].$$

相同的两个端点分布可以有很多配对方式; 配对改变中间分布、局部监督速度的冲突程度, 以及需要拟合的向量场。CFM 的条件期望证明仍适用, 因为它依赖的是固定联合采样规则, 而非端点必须独立。[14]

给定端点对的直线在每个时刻都是确定点, 条件分布是 Dirac 点质量, 不能直接当普通密度求导。对光滑且有紧支撑的测试函数 φ , 在可交换微分与期望时, 改用

$$\begin{aligned} \frac{d}{ds} E[\varphi(X_s)] &= E[\nabla \varphi(X_s) \cdot (y - z)] \\ &= E[\nabla \varphi(X_s) \cdot u_s(X_s)]. \end{aligned}$$

这就是弱形式的连续性方程。任意 coupling 也可能使中间分布退化，例如 $y = -z$ 时所有插值在 $s=1/2$ 聚到零。条件期望回归仍可定义，但要由它得到全程唯一、保持边缘的 ODE 流，还需检查 Part 11.1 所述正则性与存在唯一性条件，不能只看两端边缘正确。

12.2 独立配对 全局 OT 与 minibatch OT

独立配对取 $\pi = p_{noise} \otimes p_{data}$ ，简单且便于大规模训练，但某些配对距离较远。二次代价的最优传输选择

$$\pi^* \in \arg \min_{\pi \in \Pi(p_{noise}, p_{data})} E_{(z,y) \sim \pi} \|y - z\|^2.$$

Π 表示具有规定边缘的所有联合分布，约束很关键；把所有噪声都送给最近的一张图片通常破坏数据边缘，不是有效 OT。具有有限二阶矩的分布上，该问题有标准理论；在进一步条件下，二次 OT 可由确定性映射表达。对真正的全局最优 coupling 做线性位移插值，可得到相应的 Wasserstein 测地线结构。

全数据级别的 OT 往往代价高。minibatch OT 在两个小批量之间求一个有限运输计划，再据此采样配对。批内完整运输计划保持该批次的经验边缘；跨批平均定义某个合法总体 coupling，但有限批量的期望结果一般不等于全局最优 coupling。批量大小、代价定义及熵正则化都会影响结果。[14] 还需区分“条件 OT 路径”和“噪声到整个数据分布的全局 OT”。原始 FM 论文对单个数据端点构造的高斯条件路径具有简单运输结构，并不自动证明其边缘流实现全局最优传输。[12] 同理，训练样本逐对走直线不意味着生成 ODE 逐条走直线。后者沿着后验平均速度走，端点间隐藏的配对标签已经被边缘化了。




图 12.1 同一组端点的两种配对

图 12.1 中两边各有两个等权端点。交叉配对的平均平方距离为 $[(2 - (-1))^2 + (0 - 1)^2] / 2 = 5$ ；排序配对为 $[(0 - (-1))^2 + (2 - 1)^2] / 2 = 1$ 。两种配对保持同样的端点分布，却改变中间路径与训练速度标签。这个两点例子不能代替一般高维的 OT 求解。

12 3 Rectified Flow reflow 与蒸馏

Rectified Flow 的基本回归目标也是：为端点对构造直线插值，回归位移 $y - z$ ，再积分边缘速度。它在直线插值、条件期望与确定性流的关系上，和 FM 的相应特例密切相连。其“rectify”不能被理解为只要写下直线标签，第一轮学到的所有生成轨迹就已经直了。[13]

reflow 是进一步改变配对的训练过程：先用已有 ODE 从 z 生成 $\hat{y}$ ，把 $(z, \hat{y})$ 当成新的端点对，再以这批配对的直线插值训练下一轮流。新 coupling 来自旧流的实际端点关系，不再是原来的独立配对。在精确回归、可整流及所需矩存在等条件下，整流使端点位移的凸代价不增加，反复整流还具有相应直度指标的收敛性质；这不保证每条轨迹逐轮单调变直，也不普遍保证得到指定代价下的全局 OT。[13]

实际 reflow 的新数据端边缘是教师生成分布；教师不精确时，它不会自动修正教师与真实数据之间的差距。有限网络与有限积分精度还会带来额外近似误差，应与上述理想理论分别评估。

蒸馏关注另一个问题：让学生用更少计算逼近教师的映射或采样行为。例如监督单步学生把 z 映射到教师产生的 $\hat{y}$ 。reflow 改变配对并重新学习流；蒸馏压缩生成计算；二者可以结合，但概念不同。一次 RF 训练、一次 reflow、一次蒸馏不能都笼统称为“把流拉直”。轨迹更直通常有利于少步积分，却不单独保证样本质量或全局最优性。

12 4 一般高斯路径下 速度如何连接 score

为了与扩散统一，重新采用独立 $z \sim N(0, I)$ 与 $y \sim p_{data}$ ，并设 $X_s = a(s)y + b(s)z$ 。本节只在 $a(s) \neq 0, b(s) > 0$ 的内部时刻推导，记 $r_s(x) = \nabla_x \log p_s(x)$ 。这里 $r_s(x)$ 是 score 向量，与 Part 5 至 Part 7 表示模型逆标准差的标量 r_t 不同。条件高斯 score 的后验平均给出

$$\begin{aligned} r_s(x) &= -\frac{x - a E[y | X_s = x]}{b^2}, \\ E[y | X_s = x] &= \frac{x + b^2 r_s(x)}{a}, \\ E[z | X_s = x] &= -b r_s(x). \end{aligned}$$

再对插值求导，并取条件期望：

$$\begin{aligned} u_s(x) &= a' E[y | X_s = x] + b' E[z | X_s = x] \\ &= \frac{a'}{a} x + \left(\frac{a'}{a} b^2 - b b' \right) r_s(x). \end{aligned}$$

这揭示了同一高斯概率路径上的速度与 score 可以通过已知系数联系。若括号内的系数非零，内部时刻还能反向换算 score；零系数或端点处不能直接相除。若端点采用一般相关 coupling， $X_s | y$ 未必是这里的高斯分布，以上 score 换算不能原样使用。

若 a, b 来自时间反转后的扩散路径，上式对应其生成方向的概率流速度。反过来，任意选择的 FM 路径并不自动给出一个合法的正向扩散 SDE：还要检查扩散方差非负等条件。这个连接说明

模型家族在概率路径上可以重叠，区别往往在于如何选路径、训练什么量，以及怎样采样，而非网络必须长成完全不同的样子。

12 5 用同一组问题比较模型

阅读新论文时，先确定“网络结构、概率路径、监督目标、求解方法”四件事。Transformer 是参数化工具，可以当自回归网络，也可以作为扩散或 FM 的骨干；仅凭使用 Transformer 不能判断其生成机制。

对象	训练时主要学习什么	生成如何进行	本讲义中的关键区别
自回归 Transformer / LLM	下一个 token 的条件分布	按 token 顺序采样	序列概率的链式分解
VAE	编码器后验近似与解码器	采样潜变量，再解码	用 ELBO 处理潜变量积分
DDPM / score 模型	噪声、干净样本、扩散 v 或 score	反向随机过程或相应确定性采样器	预设加噪过程与去噪监督
概率流 ODE	通常使用已学 score 构造速度	从噪声反向积分 ODE	与对应 SDE 同边缘，路径不同
FM / CFM	预设路径的条件速度	从噪声正向积分 ODE	用条件回归学习边缘速度
RF / reflow	直线插值位移；可更新端点配对	ODE，或结合少步蒸馏	关注配对、轨迹直度与采样成本

表中这些项不互斥。例如一个文本条件 Transformer 可以输出 FM 速度，采用独立 coupling 训练，再经过 reflow 和蒸馏；每个词描述系统的不同层面。比较优劣还应固定数据、模型容量与网络调用预算，不能从某个目标名字直接推断谁必然更快或质量更高。

12 6 例题 批内 OT 到底优化了什么

一维噪声批次为 $\{-1, 1\}$ ，数据批次为 $\{-2, 2\}$ ，各点质量均为 $1/2$ 。比较交叉配对和同序配对的平均平方距离。

解。 交叉配对为 $(-1, 2), (1, -2)$ ，两段距离均为 3，平均平方代价为 9。同序配对为 $(-1, -2), (1, 2)$ ，两段距离均为 1，平均代价为 1。这个批次的二次 OT 选择同序配对。若每个噪声点独立、等概率配任一数据点，期望代价是 $(1+9+9+1)/4=5$ 。

三种方案都可以写直线插值，但代价明显不同。所以“直线”与“最优配对”不是同一条件。该计算只解决这两个经验分布；实际总体分布更复杂时，不能据此宣称一个批次已经找到了总体 OT。

12.7 易错点

本章应带走的判断标准是：先检查端点边缘是否正确，再检查配对是否独立或优化过；先区分条件插值和边缘轨迹，再讨论直度；最后分清训练改变了什么与采样加速改变了什么。省略这些限定，容易把一个特殊情形扩展成所有流模型的结论。

12.8 章末推导练习

题组 A 用一个参数解二乘二 OT

已知噪声点 $z=(-1,1)$ 、数据点 $y=(-2,2)$ ，各点概率均为 $1/2$ 。 π_{ij} 表示配对 (z_i, y_j) 的概率，行和、列和都为 $1/2$ 。目标是最小化平均平方距离；只需矩阵和一次函数。

A1. 计算代价矩阵 $C_{ij}=(y_j - z_i)^2$ 。

A2. 独立配对的四个概率各是多少？计算平均代价。

A3. 令 $\pi_{11}=q$ ，用行列和约束求其余三项及 q 的范围。

A4. 写出 $\sum_{ij} \pi_{ij} C_{ij}$ 关于 q 的表达式，找出最优配对与代价。

A5. 分别列出独立配对和最优配对在 $s=1/2$ 的插值位置及概率。端点边缘相同是否意味着中间分布相同？

题组 B 从高斯密度导出 score 与速度关系

已知独立的 $z \sim N(0,1)$ 、数据 y ，且 $X_s = ay + bz$ ， $a \neq 0, b > 0$ 。设 $r = \partial_x \log p_s(x)$ 。可用高斯对数密度和 Bayes 权重，并允许积分内求导；目标是消去后验均值。

B1. 给定 y 后，写出条件高斯对数密度中与 x 有关的项，再求导。

B2. 从 $p_s(x) = \int p_s(x|y) p_{data}(y) dy$ 求 p'_s/p_s ，识别后验平均，得到 r 与 $E[y|x]$ 的关系。

B3. 解出 $E[y|x]$ ，再由 $x = aE[y|x] + bE[z|x]$ 解出噪声均值。

B4. 对插值求导后作条件平均，代入 B3，合并 x 与 r 的系数。

B5. 逐坐标推广到独立标准高斯向量；再取 $a=s, b=1-s$ ，写出速度。哪些端点不能直接代入除法？

题组 C 观察弯曲的边缘流并做一轮 reflow

已知二维独立高斯端点：噪声各坐标方差为 1，数据方差为 $q_1=4, q_2=1$ ，均值均为零，坐标间也独立。条件插值仍是 $X_s = (1-s)z + sy$ 。给出工具：对零均值联合高斯 H, K ， $E[H|K=x] = \text{Cov}(H, K)x / \text{Var}(K)$ ；协方差为 $E[HK]$ 。该工具见附录 A4，以下直接代入使用，不要求另证多元高斯定理。目标是比较条件直线与实际 ODE。

C1. 用独立变量方差相加，求每个坐标的方差 $D_j(s)$ 。

C2. 计算 $\text{Cov}(y_j - z_j, X_{s,j})$ ，代入给定工具求边缘速度 $u_{s,j}(x)$ 。

C3. 对 $Y_{s,j} = \sqrt{D_j(s)} z_j$ 求导, 验证它是边缘 ODE 解。取初始点 $(1,1)$, 求起点、中点和终点; 中点在端点连线上吗?

C4. 旧流给出的端点对为 $(z, \hat{y})$, 其中 $\hat{y} = (2z_1, z_2)$ 。重新线性插值, 求新的路径、标签, 并消去 z_1 写出新边缘速度。

C5. 验证新轨迹是直线, 用一个 Euler 步计算终点。这个例子是否说明任意 reflow 都能精确单步生成?

12.9 分层提示与参考解答

A 组提示。 先守住行列和; 这里四个未知量最终只剩一个自由参数。

A1. $C = \begin{pmatrix} 1 & 9 \\ 9 & 1 \end{pmatrix}$ 。

A2. 各概率为 $1/4$, 平均代价 $(1+9+9+1)/4=5$ 。

A3. $\pi = \begin{pmatrix} q & 1/2-q \\ 1/2-q & q \end{pmatrix}$, 非负性要求 $0 \leq q \leq 1/2$ 。第一行决定右上角, 第一列决定左下角, 剩下的行和再决定右下角; 最后应逐行逐列核对一次。

A4. 代价为 $2q+18(1/2-q)=9-16q$, 故 $q=1/2$ 最优, 代价为 1。这个一次函数随参数增加而降低, 所以最小值在允许区间的右端。优化时不能越过该端点, 否则会产生负的配对概率。

A5. 独立配对在 $-3/2, 1/2, -1/2, 3/2$ 各有概率 $1/4$; 最优配对只在 $\pm 3/2$ 各有概率 $1/2$ 。中间分布不同。

B 组提示。 先计算已知单个端点时的导数, 再用后验概率平均; 不可先猜边缘密度也是高斯。

B1. 对数密度的相关项为 $-(x-ay)^2/(2b^2)$, 导数为 $-(x-ay)/b^2$ 。

B2. 积分求导后除以 $p_s(x)$, 用 Bayes 公式识别后验权重:

$$\begin{aligned} r &= \frac{1}{p_s(x)} \int \partial_x p_s(x|y) p_{data}(y) dy \\ &= \int \frac{\partial_x p_s(x|y)}{p_s(x|y)} p_s(y|x) dy \\ &= -\frac{x - a E[y|x]}{b^2}. \end{aligned}$$

平均中的位置固定, 只有可能的数据端点在变化。因此把位置项提到期望外, 端点项则变成后验均值。

B3. 移项得 $E[y|x] = (x + b^2 r)/a$; 代回线性关系得 $E[z|x] = -br$ 。这不是恢复某个训练噪声的精确值; 同一带噪状态可能对应多个端点组合, 这里只求它们的平均。

B4. 因为 $V = a'y + b'z$,

$$u_s(x) = a' \frac{x + b^2 r}{a} - b' b r = \frac{a'}{a} x + \left(\frac{a'}{a} b^2 - b b' \right) r.$$

B5. 将 r 换成梯度向量即可逐坐标成立；线性路径给出 $u_s = x/s + (1-s)r/s$ 。通用推导在 $a=0$ 或 $b=0$ 处不可直接除法，线性路径两端须另取极限。

C 组提示。标签固定不等于后验平均速度固定；验证解时只需对平方根求导，无需预先会解一般 ODE。

C1. $D_j = (1-s)^2 + q_j s^2$ 。

C2. 展开协方差，独立交叉项为零，剩下 $s q_j - (1-s)$ 。所以

$$u_{s,j}(x) = \frac{s q_j - (1-s)}{D_j(s)} x_j = \frac{D'_j(s)}{2 D_j(s)} x_j.$$

C3. $\frac{d}{ds}(\sqrt{D_j} z_j) = D'_j Y_{s,j} / (2 D_j)$ ，且 $D_j(0) = 1$ 。先把平方根的导数写成 $D'_j / (2\sqrt{D_j})$ ，再用 $Y_{s,j} = \sqrt{D_j} z_j$ 换元，就得到速度公式。三点依次为 $(1,1)$ 、 $(\sqrt{5}/2, 1/\sqrt{2})$ 、 $(2,1)$ 。端点连线的第二坐标恒为 1，中点不在其上，因此实际流弯曲。

C4. 新插值为 $\tilde{X}_s = ((1+s)z_1, z_2)$ ，标签为 $(z_1, 0)$ 。由 $z_1 = x_1/(1+s)$ 得新速度 $(x_1/(1+s), 0)$ 。此时在给定位置后可以唯一反推出起点，标签没有剩余不确定性，所以后验平均就是这个标签本身。

C5. 新 ODE 解就是 $((1+s)z_1, z_2)$ ，沿每条轨迹速度恒为 $(z_1, 0)$ 。一步 Euler 返回 $(2z_1, z_2)$ ，恰等于教师终点；这来自本例的特殊可解析配对，不是任意 reflow 的单步精确性定理。

Part 13 从统一视角重读扩散模型

精读论文：Calvin Luo, Understanding Diffusion Models: A Unified Perspective, 2022, arXiv:2208.11970v1。以下页码均指原论文印刷页码，不是本讲义页码。[15]

13.1 用三个问题串起全文

Part 3–9 已分别介绍潜变量、扩散与 score；本章把它们接成一条可以来回检查的推理链。先问“为什么能用回归训练生成模型”，再问“回归究竟学到什么”，最后问“学到的函数怎样参与采样”。学完后，你应能亲手推导 Tweedie 公式，解释 SNR 差分权重，并在看到一条采样公式时检查漂移、噪声和条件引导各自的作用。

论文的阅读路线可分为四段：第 2–6 页建立 ELBO 与层次 VAE；第 7–14 页把固定高斯前向过程化为去噪回归；第 15–17 页连接数据、噪声与 score；第 18–22 页连接多噪声尺度采样和

guidance。精读时以第 10 页式 (58) 的“重建、先验匹配、后验拟合”三项分解为主线。处理相邻状态时必须保留正确的条件依赖，不能仅凭马尔可夫性质，把固定两端后的中间状态条件删掉。

这里的“三种等价解释”是预测 x_0 、预测噪声 ϵ 、预测 score。它不是 Part 7 的 x_0, ϵ, v 三种参数化： $v = a_t \epsilon - b_t x_0$ 是另一种输出坐标，score 则是噪声边缘密度的对数梯度。两张分类表有联系，但第三项不同。

13.2 先分清样本标签与最优预测

固定一个内部时刻 t ，沿用全书记号：

$$x_t = a_t x_0 + b_t \epsilon, a_t = \sqrt{\bar{\alpha}_t}, b_t = \sqrt{1 - \bar{\alpha}_t}.$$

本节假设 $a_t, b_t > 0$ ， $\epsilon \sim N(0, I)$ 且独立于数据。 $q_t(x)$ 表示把全部干净样本加噪后得到的边缘密度。网络只收到 x_t, t ，不知道生成这个输入的那次 x_0, ϵ 。

为什么噪声预测仍能训练？训练过程自己采过 x_0, ϵ ，所以拥有标签；推理时则通过统计规律估计它们。对于标量标签 U 、观察值 $X = x$ ，记 $m(x) = E[U | X = x]$ 。把平方展开：

$$E[(U - g(x))^2 | X = x] = E[(U - m(x))^2 | X = x] + (m(x) - g(x))^2.$$

交叉项为零，因为给定 $X = x$ 后， $E[U - m(x) | X = x] = 0$ 。因此平方损失的最优答案是条件均值。向量情形对各坐标相加即可。定义理想预测：


$$m_t(x) = E[x_0 | x_t = x], e_t(x) = E[\epsilon | x_t = x].$$

对前向式取条件期望，便有 $x = a_t m_t(x) + b_t e_t(x)$ 。数据预测与噪声预测的最优函数可以互换，并不意味着它们能从一个混合后的输入唯一恢复每次真实标签。

同一噪声层级：三种可换算的预测视角

$$x_t = ax_0 + b\varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I)$$

$$a = \sqrt{\bar{\alpha}_t} > 0, \quad b = \sqrt{1 - \bar{\alpha}_t} > 0$$



$$m = \frac{x_t - b\varepsilon^*}{a}, \quad \varepsilon^* = \frac{x_t - am}{b}$$

$$s_t^* = -\frac{\varepsilon^*}{b} = \frac{am - x_t}{b^2}, \quad m = \frac{x_t + b^2 s_t^*}{a}$$

网络预测同样可换算： $\hat{x}_0 = (x_t - b\hat{\varepsilon})/a$, $\hat{s} = -\hat{\varepsilon}/b$ 。

理想输出是条件均值或边缘 score，不是每次潜在样本的还原。

同一时刻的代数等价，不自动使不同时间加权的训练目标等价。

图 13.1 固定噪声层级的数据 噪声与 score 三视角 理想条件均值之间可以换算

图中的 m, ε^* 分别对应正文的 m_t, e_t ，关系在同一 x, t 下成立。把理想函数换成网络输出，也可以据公式定义彼此对应的输出；若分别训练三个有限网络，则它们未必恰好满足这些关系。还要同时换算损失的时间权重，才能声称训练的是同一目标。

13.3 从高斯积分亲手推出 Tweedie 公式

先在一维证明。暂省略下标 t ，用 u 表示干净数据的积分变量。令 $f(u)$ 为数据密度，加噪核为

$$k(x|u) = \frac{1}{\sqrt{2\pi b^2}} \exp\left[-\frac{(x - au)^2}{2b^2}\right].$$

对数据分布平均，得到噪声边缘密度：

$$q(x) = \int f(u) k(x|u) du.$$

假设相关一阶矩存在，并可交换积分与求导。先固定 u ，对高斯指数中的平方求导：

$$\frac{\partial k(x|u)}{\partial x} = -\frac{x - au}{b^2} k(x|u).$$

再对全部可能的 u 平均，拆开含 x 与含 u 的项：

$$q'(x) = -\frac{x}{b^2} q(x) + \frac{a}{b^2} \int u f(u) k(x|u) du.$$

高斯平滑使 $q(x) > 0$ 。两边除以 $q(x)$ ，再用 Bayes 公式 $f(u|x) = f(u)k(x|u)/q(x)$ ，得

$$\frac{d}{dx} \log q(x) = \frac{a E[x_0|x_t=x] - x}{b^2}.$$

这就是一阶高斯 Tweedie 关系。回到 d 维、逐坐标求导，令 $s_t^*(x) = \nabla_x \log q_t(x)$ ，便得到

$$m_t(x) = \frac{x + b_t^2 s_t^*(x)}{a_t}, e_t(x) = -b_t s_t^*(x).$$

这里不需要计算未知的归一化常数：对数梯度把与 x 无关的常数消掉。若数据是离散点质量，上面的积分换成求和，推导同样成立。这也说明即使原数据没有连续密度，加正高斯噪声后的 score 仍可定义。

论文第 16 页式 (131) 保留了条件期望，而式 (132)–(133) 将估计对象简写成 x_0 。阅读时应把它理解为上面的 $m_t(x)$ 。同理，第 17 页式 (151) 的边缘 score 关系应读作 $-E[\epsilon|x_t]/b_t$ ；单次标签 $-\epsilon/b_t$ 对应的是条件核 $q(x_t|x_0)$ 的 score。[15]

训练为何可以用条件核标签代替未知边缘 score？令 $D = -\epsilon/b_t$ ，则 $E[D|x_t] = s_t^*(x_t)$ 。使用刚才的平方展开，有

$$E\|s_\theta(x_t, t) - D\|^2 = E\|s_\theta(x_t, t) - s_t^*(x_t)\|^2 + C_t,$$

其中 $C_t = E\|D - s_t^*(x_t)\|^2$ 在固定噪声日程时与 score 网络参数 θ 无关。这是“去噪监督学到边缘 score”的准确含义：损失一般不相等，但只差一个不影响该网络优化的常数；若同时学习日程，该项可能依赖日程参数。

这层条件期望也必须带进逆过程。把 Part 5 的线性高斯后验均值对 $x_0|x_t=x$ 平均后，可以得到

$$E[x_{t-1}|x_t=x] = \frac{x + \beta_t s_t^*(x)}{\sqrt{\alpha_t}}.$$

它对应论文第 16–17 页式 (142)–(143) 的边缘均值解释，不是每个给定 x_0 的后验均值。得到均值也没有证明整个反向条件分布为高斯；混合不同 x_0 后，反向分布通常更复杂。

13.4 一个去噪结果不属于数据集的例子

为看清“均值”二字，取教学数据 $x_0 = -2$ 或 $+2$ ，概率各一半，令 $a=0.8, b=0.6$ 。噪声边缘是

$$q_t(x) = 1/2 N(x; -1.6, 0.36) + 1/2 N(x; 1.6, 0.36).$$

设 $r(x) = P(x_0=2|x_t=x)$ 。两类先验相同，后验概率之比等于高斯似然之比：

$$\frac{r(x)}{1-r(x)} = \exp\left[\frac{(x+2a)^2 - (x-2a)^2}{2b^2}\right] = \exp\left(\frac{4ax}{b^2}\right).$$


因而 $r(x) = 1/[1 + \exp(-4ax/b^2)]$ ，后验均值为

$$m_t(x) = 2r(x) - 2(1-r(x)) = 2 \tanh\left(\frac{2ax}{b^2}\right).$$

这里 $\tanh z = (e^{2z} - 1)/(e^{2z} + 1)$ ，只是缩写指数比，不要求先学双曲函数。再代入 Tweedie，得到 $s_t^*(x) = (am_t(x) - x)/b^2$ 。

Tweedie：后验均值不等于潜在样本

教学例： $x_0 \in \{-2, +2\}$ 等概率， $a = 0.8$ ， $b = 0.6$ 。



$$m(x) = 2 \tanh\left(\frac{2ax}{b^2}\right), \quad s_t^*(x) = \frac{am(x) - x}{b^2}$$

观察 $x_t = 0$ 后，潜在值 -2 与 $+2$ 仍各有 $1/2$ 后验概率。

均值 $m(0) = 0$ 使平方误差最小，却不是任一可能的 x_0 。

图 13.2 双点数据的高斯平滑 后验均值与 score 中心的均值零并非原始样本

在 $x=0$ ，两种解释同样可能，所以 $m_t(0)=0$ 、 $s_t^*(0)=0$ 。可是数据只有 ± 2 ，一次确定的均方误差最优去噪会落在两者中间。不能据此断言模型失败，也不能把这个均值直接当作从后验抽到的样本。完整生成仍需沿噪声层级运行相应采样过程。

13 5 ELBO 为什么给出 SNR 的差分

对论文第 10 页式 (58) 取负后，负 ELBO 的内部项是条件后验与模型逆转移的 KL。以下仅讨论 $t=2, \dots, T$ ，并采用论文第 12 页式 (85) 的方差匹配设定：

$$\tilde{\beta}_t = \frac{\beta_t(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}, \quad p_\theta(x_{t-1}|x_t) = N(\mu_\theta, \tilde{\beta}_t I).$$

两个高斯协方差相同时，KL 为均值差的平方除以 $2\tilde{\beta}_t$ 。由第 13 页式 (93)–(99)，用 $\hat{x}_{0,\theta}$ 代替真实 x_0 后，均值误差是

$$\mu_\theta - \tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}(\hat{x}_{0,\theta} - x_0).$$

记内部 KL 的数据预测权重为 $w_t^{(x_0)}$ 。把平方系数除以方差，约去一个 β_t 和一个 $1 - \bar{\alpha}_t$ ：

$$w_t^{(x_0)} = \frac{\bar{\alpha}_{t-1} \beta_t}{2(1 - \bar{\alpha}_{t-1})(1 - \bar{\alpha}_t)}.$$

又因 $\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}$ ，分子为 $\bar{\alpha}_{t-1} - \bar{\alpha}_t$ 。把两个分数通分，正好得到

$$w_t^{(x_0)} = \frac{1}{2} \left[\frac{\bar{\alpha}_{t-1}}{1 - \bar{\alpha}_{t-1}} - \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t} \right].$$


按 SNR 的定义，这就是

$$w_t^{(x_0)} = \frac{1}{2} (SNR_{t-1} - SNR_t).$$

这对应原文第 14 页式 (101)–(110)。这里 $SNR_t = a_t^2 / b_t^2$ 是日程的信号系数平方与噪声系数平方之比；若数据方差不是单位阵，它不等于所有实际数据坐标的物理信噪比。

SNR 差分决定各噪声层级的权重

有限教学例： $SNR_{1:5} = (16, 8, 4, 2, 1)$ 。



$$w_t^{(x_0)} = \frac{1}{2} (SNR_{t-1} - SNR_t), \quad t = 2, \dots, 5$$

各时刻数据预测 MSE 均设为 1；柱高就是该项的加权贡献。

匹配后验方差的内部 KL 项；未画 $t = 0$ 的无限 SNR 或重建边界项。

图 13.3 同样的数据预测误差在不同 SNR 区间贡献不同 教学权重来自方差匹配的内部 KL 项

图中取有限噪声级别 $SNR_{1:5} = (16, 8, 4, 2, 1)$ ，内部四项权重是 $(4, 2, 1, 0.5)$ 。同样大小为一的平方误差，ELBO 贡献并不相等。数据端 $t=0$ 的 SNR 为无穷，不能把它塞进这张表； $t=1$ 的重建项要按观察模型单独处理。

数据预测换成噪声预测时，若定义 $\hat{x}_0 = (x_t - b_t \hat{e}) / a_t$ ，逐样本有

$$\|\hat{x}_0 - x_0\|^2 = \frac{b_t^2}{a_t^2} \|\hat{e} - \epsilon\|^2.$$

因此保持同一内部 KL，噪声 MSE 权重应为 $w_t^{(x_0)}/SNR_t$ 。改用 score 输出 $\hat{\epsilon} = -b_t s_\theta$ ，去噪 score 损失权重则是 $w_t^{(x_0)} b_t^4 / a_t^2$ 。直接把三种 MSE 的权重都设成一，会改变各噪声层级的重要性；共享有限网络时，最优折中也可能改变。

这仍只是完整目标中的内部项。均匀抽 $t \in \{2, \dots, T\}$ 时，乘 $T-1$ 才无偏估计内部总和；省略该常数只是不改变单独内部目标的最优点。

原文第 14 页式 (111)–(114) 还给出可学习日程：令 $\omega_\eta(t)$ 随 t 单调增加，用 η 表示日程网络参数，并定义

$$SNR_t = \exp[-\omega_\eta(t)].$$

SNR 随 t 递减且为正。由 $S = \bar{\alpha} / (1 - \bar{\alpha})$ 得 $\bar{\alpha} = S / (1 + S)$ 。代入即得

$$\bar{\alpha}_t = \frac{1}{1 + \exp[\omega_\eta(t)]} = \text{sigmoid}[-\omega_\eta(t)],$$

$$1 - \bar{\alpha}_t = \text{sigmoid}[\omega_\eta(t)].$$

其中 $\text{sigmoid}(u) = 1 / (1 + e^{-u})$ 。只要函数单调且端点适当，就能直接产生累计保留率，不必把所有单步保留率逐项相乘。有限 ω_η 只给出严格介于零与一的保留率，精确端点需另作极限或边界处理。端点也要有约束：起点应接近干净数据，终点应接近所选噪声先验。固定 SNR_1, SNR_T 时，内部权重总和由二者之差决定，不能通过统一缩小权重“免费”降低同一个问题的难度。若训练日程，重建、终端先验和输入噪声分布也可能依赖日程，应检查完整损失，而非只观察权重数值下降。

13.6 从 score 到采样 再到条件引导

score 给出对数密度局部上升方向，但沿该方向做确定性爬坡并不是按密度抽样。论文第 19 页式 (158) 的 Langevin 更新，改用 $z^{(k)}$ 表示迭代状态，可写成

$$z^{(k+1)} = z^{(k)} + h s(z^{(k)}) + \sqrt{2h} \xi_k, \xi_k \sim N(0, I).$$

$h > 0$ 是数值步长， ξ_k 每步独立。这里暂固定同一个目标密度， k 不是 DDPM 噪声层级。漂移依 score 移动，新增噪声防止算法只是寻找一个峰。

经典 NCSN 是“以噪声级别为条件的 score 网络”。其 Langevin 记法常把漂移写成 $\delta s / 2$ 、噪声写成 $\sqrt{\delta} \xi$ ，与上式完全一致的换算是 $\delta = 2h$ ，不是仅删去一个二。这里 δ 是采样步长，不是上节的日程参数 η 。按论文第 20 页的描述，每个噪声级别进行多次更新，再从大噪声逐级降到小噪声，并减小步长；每级的最终状态用作下一级的初始状态。[15]

原文第 20 页式 (160) 使用加性扰动 $Y = x_0 + \sigma \epsilon$ ，与本讲义的 VP 形式 $x_t = a_t x_0 + b_t \epsilon$ 不同。在 $a_t > 0$ 时，除以 a_t 可得 $\sigma = b_t / a_t$ ，但输入坐标和 score 尺度也要一起变。两种方法因此有相通的高斯平滑解释，却不意味着它们的有限步采样更新逐项相同。

即使 score 完全准确，有限步长、未充分运行的 Langevin 仍一般有偏差。跨越低密度区域需要时间；混合权重并不会在一般重叠混合分布的 score 中自动消失。第 10 章的逆 SDE 与概率流 ODE 则把整条边缘路径的演化写出来，也不能直接与固定密度上的 Langevin 混用。

最后，把条件记为 c 。在同一噪声级别，Bayes 公式给出

$$\nabla_x \log q_t(x|c) = \nabla_x \log q_t(x) + \nabla_x \log p_t(c|x).$$

这对应原文第 21 页式 (163)–(165)。分类器必须处理该噪声级别的输入。引导时改变的是采样所用的场；令 s_u, s_c 分别表示无条件条件和条件 score，有

$$s_\gamma = s_u + \gamma(s_c - s_u).$$

这是原文式 (167)–(170) 的 CFG 形式；这里的 γ 对应 Part 9 的引导系数 g 。若采用另一种写法 $s_c + w(s_c - s_u)$ ，则 $\gamma = g = 1 + w$ 。 $\gamma = 0$ 无条件， $\gamma = 1$ 普通条件， $\gamma > 1$ 向条件方向外推。对精确 score，在固定 t 且可归一化时，它是 $q_t(x)^{1-\gamma} q_t(x|c)^\gamma$ 的对数梯度。这个固定时刻恒等式并不保证沿所有时刻采样后，终端恰好是同样幂次的数据分布。

13.7 章末推导练习

以下三组分别检查“估计什么、优化什么、怎样采样”。所有题先列出，之后给提示和逐问答案。正文三幅图都是教学构造，不是原论文的实验结果。

题组 A 从高斯核到后验均值

已知一维 $x = ax_0 + b\epsilon$ ， $a, b > 0$ ，噪声标准正态且独立。可用链式法则、Bayes 公式、期望线性性；假设积分与求导可交换。目标是不用现成 Tweedie 定理完成推导。

A1. 写出 $k(x|u)$ ，固定 u 对 x 求导。说明为何分子为 $-(x - au)$ ，而不是 $-u$ 。

A2. 对 $q(x) = \int f(u)k(x|u)du$ 求导；除以 $q(x)$ ，将积分识别为条件均值，解出 $m(x)$ 。

A3. 改取 $x_0 = \pm 2$ 等概率， $a = 0.8, b = 0.6$ 。先算后验赔率 $r/(1-r)$ ，再解 r 和 $m(x)$ ；用指数比定义 $\tanh$ 。

A4. 在 $x = 0$ 求 m, e, s^* 。分别假设真实 $x_0 = 2, -2$ ，求对应噪声标签和条件 score；说明它们为什么不同于边缘 score。

A5. 对任意标量预测 $g(x)$ 展开条件均方误差，证明最优预测为 $m(x)$ 。再对 $x = ax_0 + b\epsilon$ 取条件期望，推出 $e = -bs^*$ 。

题组 B 从一个高斯 KL 到时间权重

设 $2 \leq t \leq T$ ， $0 < \bar{\alpha}_t < \bar{\alpha}_{t-1} < 1$ ， $\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}$ ， $\beta_t = 1 - \alpha_t$ 。逆方差与后验方差同为 $\tilde{\beta}_t$ ；均值差为 $\kappa_t(\hat{x}_0 - x_0)$ ，其中 $\kappa_t = \sqrt{\bar{\alpha}_{t-1}}\beta_t/(1 - \bar{\alpha}_t)$ 。可用正态对数密度、平方展开和分数通分。

B1. 先对同方差标量高斯 $q = N(\mu_q, \nu)$ 、 $p = N(\mu_p, \nu)$ ，取 q 下的对数密度差期望，证明 KL 等于 $(\mu_q - \mu_p)^2/(2\nu)$ 。再推广到协方差 νI 。

B2. 把 κ_t 和正文中的 $\tilde{\beta}_t$ 代入 $w_t^{(x_0)} = \kappa_t^2 / (2\tilde{\beta}_t)$, 逐项约分。

B3. 利用 $\bar{\alpha}_{t-1}\beta_t = \bar{\alpha}_{t-1} - \bar{\alpha}_t$, 将 B2 改写为 SNR 差分, 说明权重为何非负。

B4. 取图 13.3 的五个 SNR, 算四项权重与总和。当四项平方误差均为一, 均匀抽一个内部时刻时, 怎样无偏估计内部总损失? 为什么不能把 $t=0$ 直接加入?

B5. 由 $\hat{x}_0 = (x_t - b_t \hat{\epsilon}) / a_t$ 推出噪声损失权重; 继续令 $\hat{\epsilon} = -b_t s_\theta$, 求去噪 score 损失权重。指出统一设为一改变了什么。

题组 C 从 Langevin 的方差到 CFG

本组先固定一维目标密度, 使用独立 $\xi_k \sim N(0, 1)$ 。可用方差相加、概率密度变量代换和对数求导。后两问都在同一噪声级别讨论, 条件 c 固定。

C1. 比较 $z' = z + h s(z) + \sqrt{2h} \xi$ 与 $z' = z + \delta s(z) / 2 + \sqrt{\delta} \xi$ 。匹配条件均值和方差, 求 h, δ 的关系。

C2. 取目标 $N(0, v)$, 求 score 并把第一种更新写成线性递推。假设 $0 < h < 2v$, 求稳定方差 V , 比较它与目标方差 v ; 再说明删除随机项会怎样。

C3. 在 $a_t > 0$ 时令 $Y = x_t / a_t$ 。写出 Y 的加性噪声形式。一维密度满足 $q_Y(y) = a_t q_t(a_t y)$, 据此求 Y 的 score 与 x_t 的 score 的关系。

C4. 从 Bayes 公式推导条件 score 与无条件 score 的差, 再写 s_γ 。分别解释 $\gamma=0, 1, 2$, 说明这是调整训练标签还是采样场。

C5. 给定 $q_u = N(0, 1)$ 、 $q_c = N(1, 1)$, 算 s_γ 。将 $q_u^{1-\gamma} q_c^\gamma$ 配方, 识别其归一化分布; 说明这一计算没有证明哪个跨时刻结论。

13.8 分层提示与参考解答

A 组提示。 高斯核先单独求导, 最后才平均数据。后验均值不必落在数据的取值集合中。

A1. 核为 $k = (2\pi b^2)^{-1/2} \exp[-(x - au)^2 / (2b^2)]$ 。指数导数为 $-2(x - au) / (2b^2)$, 所以 $\partial_x k = -(x - au)k / b^2$ 。求导变量是 x , 此时 au 固定。

A2. 把导数移入积分, 得到

$$q'(x) = \frac{1}{b^2} [a \int u f(u) k(x|u) du - x q(x)].$$

除以 $q(x)$ 后, 积分中的权重变成 $f(u|x)$, 所以 $q'/q = (am - x) / b^2$ 。移项得 $m = (x + b^2 s^*) / a$ 。

A3. 相除时高斯常数消掉; 两平方之差是 $8ax$, 所以赔率为 $\exp(4ax/b^2)$ 。解 $r = R / (1 + R)$, 得到 $m = 4r - 2 = 2(R - 1) / (R + 1)$ 。取 $R = \exp(2z)$ 、 $z = 2ax/b^2$, 便是 $2 \tanh z$ 。

A4. 对称性给出 $m(0) = 0$, 进而 $e(0) = 0, s^*(0) = 0$ 。真实 $x_0 = 2$ 时 $\epsilon = -1.6 / 0.6 = -8/3$, 条件 score 为 $40/9$; 真实 $x_0 = -2$ 时两者符号反转。边缘 score 是这些条件 score 的后验平均, 等于零, 而非任意一项。

A5. 写 $x_0 - g = (x_0 - m) + (m - g)$ 。交叉项期望为零，故条件 MSE 等于 $\text{Var}(x_0|x) + (m - g)^2$ ，在 $g = m$ 处最小。条件平均前向式给 $e = (x - am)/b$ ，再代入 A2，得到 $e = -bs^*$ 。向量版本逐坐标重复。

B 组提示。 先算一个标量高斯，避免一开始就处理矩阵。总和改成均匀期望时，别忘记项数。

B1. 对数密度相减得 $[(Z - \mu_p)^2 - (Z - \mu_q)^2]/(2v)$ 。第一项期望为 $v + (\mu_q - \mu_p)^2$ ，第二项为 v ，差即所求。协方差为 vI 时各坐标独立，对数密度相加，得到 $\|\mu_q - \mu_p\|^2/(2v)$ 。

B2. 平方系数为 $\bar{\alpha}_{t-1}\beta_t^2/(1 - \bar{\alpha}_t)^2$ ，除以方差等于再乘 $(1 - \bar{\alpha}_t)/[\beta_t(1 - \bar{\alpha}_{t-1})]$ ，故

$$w_t^{(x_0)} = \frac{\bar{\alpha}_{t-1}\beta_t}{2(1 - \bar{\alpha}_{t-1})(1 - \bar{\alpha}_t)}.$$

B3. 通分 $\bar{\alpha}_{t-1}/(1 - \bar{\alpha}_{t-1}) - \bar{\alpha}_t/(1 - \bar{\alpha}_t)$ ，分子为 $\bar{\alpha}_{t-1} - \bar{\alpha}_t$ ，与 B2 的分子相同。B2 的分母还含因子二，所以差分再乘 $1/2$ 就是 $w_t^{(x_0)}$ 。日程使 $\bar{\alpha}_t$ 递减，SNR 也递减，所以差分非负。

B4. 权重为 $(4, 2, 1, 0.5)$ ，总和 7.5，也等于 $(16 - 1)/2$ 。均匀抽四项之一，估计量取 $4w_t^{(x_0)}\|\hat{x}_0 - x_0\|^2$ ；其期望为总和。 $t=0$ 无噪声、SNR 无穷，内部非退化高斯 KL 的假设不适用；重建项单独处理。

B5. 两数据表达式相减，得 $\hat{x}_0 - x_0 = -(b_t/a_t)(\hat{\epsilon} - \epsilon)$ 。噪声权重为 $w_t^{(x_0)}b_t^2/a_t^2$ 。再因 $\hat{\epsilon} - \epsilon = -b_t(s_\theta + \epsilon/b_t)$ ，score 权重为 $w_t^{(x_0)}b_t^4/a_t^2$ 。统一无权重改变各噪声层级的相对代价，不再保证有限网络下优化同一折中。

C 组提示。 用一个高斯目标就能检查随机项的系数；引导后的密度解释只先固定一个噪声级别。

C1. 两者条件均值增量为 hs 与 $\delta s/2$ ，条件方差为 $2h$ 与 δ 。两项同时相等都要求 $\delta = 2h$ 。

C2. $s(z) = -z/v$ ，所以 $z' = (1 - h/v)z + \sqrt{2h}\xi$ 。设稳定方差为 V ，独立性给

$$V = (1 - h/v)^2 V + 2h, V = \frac{v}{1 - h/(2v)}.$$

$0 < h < 2v$ 保证线性系数绝对值小于一；有限 h 时 $V > v$ ，只有 $h \rightarrow 0$ 才趋近目标方差。删除随机项后，反复乘绝对值小于一的系数会使状态趋向零，不能生成具有方差 v 的样本。

C3. $Y = x_0 + (b_t/a_t)\epsilon$ ，所以加性噪声标准差为 $\sigma = b_t/a_t$ 。对 $\log q_Y(y) = \log a_t + \log q_t(a_t y)$ 求导，常数消失、链式法则给

$$\frac{d}{dy} \log q_Y(y) = a_t s_t^*(a_t y).$$

因此比较 VP 与加性噪声坐标时，不能只改噪声标准差而保留原 score 数值。

C4. Bayes 给 $\log q_t(x|c) = \log q_t(x) + \log p_t(c|x) - \log p(c)$ 。对 x 求导，最后一项为零，因此分类器梯度是 $s_c - s_u$ 。乘 γ 后得到 s_γ ；三种值分别给 $s_u, s_c, 2s_c - s_u$ 。这是采样时组合场，不是把训练标签乘同一个数。

C5. 两个 score 为 $-x$ 与 $1-x$, 故 $s_y = y - x$ 。幂次乘积的对数中, 随 x 变化的部分先写为

$$-\frac{1}{2}[(1-y)x^2 + y(x-1)^2] = -\frac{1}{2}(x^2 - 2yx + y).$$

配方后为

$$-\frac{1}{2}(x-y)^2 + \text{与 } x \text{ 无关的常数}.$$

归一化后是 $N(y, 1)$; $y=2$ 已把均值推过条件分布的均值一。此例只验证固定时刻的密度与梯度关系, 没有证明沿一整条引导采样轨迹的最终分布仍等于数据端的同样幂次组合。

附录 A 必要的数学工具

A0 起步工具卡 需要时再查

1. 先分清变量、样本与函数。大写 X 表示还没抽取的随机变量，小写 x 表示一个具体取值；

$p(x)$ 是密度函数。连续变量落在区间 $[a, b]$ 的概率是 $\int_a^b p(x) dx$ ，并不是 $p(a)$ 。 p_θ 中的下标表示函数依赖参数；对 x 求导时把 θ 当常数，对 θ 求导时则把输入 x 当常数。正文中 x_t 也常表示随机状态，含义由采样或期望的上下文确定。

2. 期望是按概率加权的平均。离散时 $E[h(X)] = \sum_x p(x)h(x)$ ，连续时把求和换成积分。均值 $\mu = E[X]$ ，方差 $\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - \mu^2$ 。对常数 a, b ,

$$E[aX + b] = aE[X] + b, \text{Var}(aX + b) = a^2 \text{Var}(X).$$

展开平方可得

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

这里 $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$ 。独立时协方差为零；没有独立或不相关条件时，不可直接删掉交叉项。向量协方差是把平方换成外积后得到的矩阵。

3. 条件期望是筛选信息后的平均。已知 $X=x$ 时，用条件分布重新加权：

$$E[Y|X=x] = \int y p(y|x) dy, p(y|x) = \frac{p(x, y)}{p(x)}.$$

上述密度表达要求 $p(x) > 0$ 。例如某输入对应标签 -1 和 3 的条件概率分别为 1/4 和 3/4，最佳平方误差预测是 2，即使任何一次标签都不等于 2。先按 x 求条件平均，再对 x 平均，等于直接求总体平均：

$$E_x[E[Y|X]] = E[Y].$$

把条件期望的积分代入，使用 $p(y|x)p(x) = p(x, y)$ 就能验证。这里的规则称为“全期望公式”。A1 会用它解释为什么网络学到平均标签。

4. 对数把乘积变成和，常数的导数为零。本书的 $\log$ 指自然对数， $\log(ab) = \log a + \log b$ ， $(\log f)' = f'/f$ 。最常用的一维高斯写法为

$$\log N(x; \mu, \sigma^2) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x - \mu)^2}{2\sigma^2}.$$

对 x 求导时，前一项是常数；对 σ 求导时，前一项却不能丢掉。“忽略常数”必须说明相对于哪个待优化变量而言。

5. Jensen 所需的不等式可从导数得到。 令 $h(r)=r-1-\log r$, $r>0$ 。由 $h'(r)=1-1/r$, 知它在 $r=1$ 处取得最小值 0, 所以 $\log r \leq r-1$ 。对正随机变量 R , 设 $m=E[R]>0$ 。将 $r=R/m$ 代入并取平均:

$$E[\log R] - \log m \leq E[R/m - 1] = 0.$$

这就得到本书需要的 $E[\log R] \leq \log E[R]$ 。假设相关期望存在。Part 3 与 Part 5 只需这个对数版本, 无需先学一般凸分析。

6. 梯度只是把偏导数排成向量。 对多变量标量函数 $L(\theta_1, \dots, \theta_m)$, 有 $\nabla_{\theta} L = (\partial L / \partial \theta_1, \dots, \partial L / \partial \theta_m)^T$ 。沿方向 v 移动一小步 h 时,

$$L(\theta + hv) \approx L(\theta) + h \nabla L(\theta)^T v.$$

选 $v = -\nabla L$, 一阶变化为 $-h \|\nabla L\|^2$; 这解释了小步梯度下降 $\theta \leftarrow \theta - \eta \nabla L$ 的含义。神经网络可以先看成一个可调参数很多的函数; 本书推导目标函数时, 并不要求先掌握反向传播的全部实现。

7. 读多维公式时先看一维。 $\|x\|^2 = \sum_i x_i^2$; 单位矩阵 I 只保留各坐标自身; 对角矩阵没有非对角项。 $\text{tr}(A)$ 是对角元素之和, $\det A$ 是行列式。遇到 $\nabla \cdot u$ 时, 先把它换成一维的 du/dx , 再看 A3 的多维定义。求和与积分、积分与微分交换时, 需要可积性或光滑性条件; 本书在对应题目中将其列为已知条件, 而不要求先证明分析学定理。

A1 条件期望为什么是平方损失的答案

设训练输入为 X , 标签为具有有限二阶矩的随机向量 Y 。给定 $X=x$, 任何预测 $f(x)$ 的条件风险都可以分解为

$$\begin{aligned} E[\|Y - f(x)\|^2 | X=x] &= \|E[Y | X=x] - f(x)\|^2 \\ &+ E[\|Y - E[Y | X=x]\|^2 | X=x]. \end{aligned}$$

证明只需在误差中加減 $E[Y | X=x]$ 并展开平方; 交叉项为零, 因为条件残差的均值为零。第二项与 f 无关, 所以总体最优预测是条件均值。Part 8 的去噪 score 与 Part 11 的条件速度回归都使用这个结论。标签本身有随机性时, 最优网络的训练损失也未必等于零。

A2 KL 散度与高斯公式

当 q 有概率质量的区域没有被 p 排除时, 可以定义 $D_{KL}(q \| p) = E_q[\log q - \log p]$, 其值非负 (也可能为无穷大)。用 A0 的 $\log r \leq r-1$, 取 $r=p/q$ 并在 $q>0$ 处积分即可得到非负性。KL 一般不对称, 也不满足三角不等式。如果某个区域在 q 下有正概率、在 p 下概率为零, 则 KL 为无穷大。

扩展查阅。 正文的基础推导主要用一维、对角或各向同性高斯；下面的通用矩阵公式可在完成 Part 3 与 Part 6 的习题后再读。对非奇异的 d 维高斯 $q=N(m_q, \Sigma_q)$ 与 $p=N(m_p, \Sigma_p)$,

$$D_{KL}(q\|p)=\frac{1}{2}[tr(\Sigma_p^{-1}\Sigma_q)+(m_p-m_q)^\top \Sigma_p^{-1}(m_p-m_q) - d + \log \frac{\det \Sigma_p}{\det \Sigma_q}].$$

推导时，把两个高斯的对数密度相减，再使用 $E_q[(x-m_q)(x-m_q)^\top]=\Sigma_q$ 。这说明当目标分布 q 与模型 p 的协方差都固定时，与模型均值参数有关的部分就是一个加权的均值平方误差；若协方差也参与学习，相应的其余项不能删去。

A3 梯度 散度与连续性方程

对标量函数 $h(x)$ ，梯度 ∇h 是各坐标偏导数组成的向量。对向量场 $u(x)$ ，散度为 $\nabla \cdot u = \sum_i \partial u_i / \partial x_i$ 。对密度 p ，乘积法则给出

$$\nabla \cdot (pu) = u \cdot \nabla p + p \nabla \cdot u.$$

一维时， $\partial_s p + \partial_x (pu) = 0$ 表示“某区间内概率的减少量，等于流出去的概率减去流进来的概率”。Part 10 的章末练习从区间两端的流量出发推导它。多维时，各方向的流量变化相加，就用散度表达。

进一步应用。 将连续性方程 $\partial_s p + \nabla \cdot (pu) = 0$ 展开，再沿轨迹 $dX_s/ds = u(X_s, s)$ 使用链式法则，可以得到连续归一化流的对数密度变化：

$$\frac{d}{ds} \log p_s(X_s) = -\nabla \cdot u(X_s, s).$$

因此，在模型场足够光滑、流映射可逆并且初始密度已知时，可以联立积分状态与散度来计算模型密度。只训练一个速度回归损失，并不意味着训练过程中已经计算了精确似然；数值密度估计还会受到 ODE 积分与散度估计误差影响。

A4 联合高斯的条件均值 如何读懂图解实验

附录 B 会用到如下结论。若标量 U, V 联合服从高斯分布，且 $\text{Var}(V) > 0$ ，则

$$E[U|V=v] = E[U] + \frac{\text{Cov}(U, V)}{\text{Var}(V)}(v - E[V]).$$

先取 $k = \text{Cov}(U, V) / \text{Var}(V)$ ，构造残差 $R = U - E[U] - k(V - E[V])$ 。第二步，用协方差的线性性质算出 $E[R] = 0$ 、 $\text{Cov}(R, V) = 0$ 。第三步，使用高斯分布的一个特殊性质：联合高斯中的不相关分量相互独立，因此 $E[R|V] = 0$ 。对残差定义取条件期望，就得到上式。

该特殊性质可作为这里给定的高斯工具；它对一般分布不成立。若没有联合高斯条件，这个线性表达仍给出最佳线性预测，却未必等于真实条件均值。附录 B 的所有变量都是两个独立高斯的线性组合，故满足条件。

附录 B 从加噪到速度场的可计算例子

B1 用二维曲线读懂加噪

取连续系数 $a(\tau) = \cos(\pi\tau/2)$ 、 $b(\tau) = \sin(\pi\tau/2)$ ，构造 $X_\tau = a(\tau)X_0 + b(\tau)\epsilon$ 。这里使用便于分析的三角路径，不是 Part 7 带端点偏移和离散裁剪的完整余弦日程实现。它满足 $a^2 + b^2 = 1$ ，且 $SNR = a^2/b^2$ 。图中只画 $0.01 \leq \tau \leq 0.99$ ，避免对数信噪比在端点发散。

系数与对数信噪比的曲线见正文图 7.1。

当 $\tau = 0.5$ 时 $a = b = 1/\sqrt{2}$ ，SNR 等于 1。这个数只比较路径系数；如果数据未归一化，各坐标的实际信号方差还取决于 $\text{Var}(X_0)$ 。

进一步取一个一维双峰数据分布，观察两个峰如何被噪声抹平：

$$p_{data} = 1/2 N(-2, 0.35^2) + 1/2 N(2, 0.35^2).$$

此时 X_τ 仍为两个高斯的等权混合，分量均值为 $\pm 2a$ ，共同方差为 $v_\tau = 0.35^2 a^2 + b^2$ 。若两个分量密度为 $\varphi_-(x), \varphi_+(x)$ ，则

$$\nabla_x \log p_\tau(x) = - \frac{\varphi_-(x)(x+2a) + \varphi_+(x)(x-2a)}{v_\tau[\varphi_-(x) + \varphi_+(x)]}.$$

这是“按当前位置的后验权重平均条件 score”的显式例子。低噪声下，score 会指向附近高密度区域； $\tau = 1$ 时 $p_1 = N(0, 1)$ ，score 恰好等于 $-x$ 。score 是对数密度对空间的导数，不是沿时间的变化率。

以上密度与 score 的曲线见正文图 8.1。

B2 条件直线为何会对应弯曲的生成轨迹

设 FM 的两个端点独立采样， $Z \sim N(0, 1)$ ， $Y \sim N(2, 0.5^2)$ ，采用线性插值 $X_s = (1-s)Z + sY$ 。每一对 (Z, Y) 的条件路径是一条直线，速度标签为 $Y - Z$ 。边缘分布却由所有配对共同决定：

$$p_s = N(2s, R_s), R_s = (1-s)^2 + 0.25s^2.$$

联合高斯的条件期望公式给出边缘速度，其中 $\text{Cov}(Y - Z, X_s) = 1.25s - 1$ ：

$$u_s(x) = 2 + \frac{1.25s - 1}{R_s}(x - 2s).$$

沿这个速度场积分，初始值为 z 的轨迹有闭式解：

$$X_s(z) = 2s + \sqrt{R_s} z.$$

对右式求导，得到 $2 + R'_s z / (2\sqrt{R_s})$ ，而 $R'_s / 2 = 1.25s - 1$ ，因此它确实满足 ODE。终点为 $X_1(z) = 2 + 0.5z$ ，服从要求的数据分布。除 $z=0$ 外，这些轨迹一般弯曲，尽管训练时用的每条配对路径都是直线。

条件路径和边缘流轨迹的对比见正文图 11.1。

在 $s=0.5$ 时， $R_s=0.3125$ ，故 $u_{0.5}(x)=2-1.2(x-1)$ 。代入 $x=1$ 得速度 2；代入 $x=2$ 得速度 0.8。位于均值右侧的粒子需要相对减速，使分布先收缩。方差在 $s=0.8$ 达到 0.2，随后回到终点方差 0.25。这也说明线性配对下的中间方差未必单调。

若改成一维平方距离的单调 OT 配对 $Y=2+0.5Z$ ，则所有粒子沿 $X_s=2s+(1-0.5s)Z$ 运动，路径变直；中间分布的方差变为 $(1-0.5s)^2$ 。端点相同不意味着中间概率路径相同。这个特殊例子可解析求解，不能直接推论高维小批次配对已经实现全局最优输运。

B3 用 Euler 与 Heun 检验采样误差

下面是完整可运行的 NumPy 示例。它直接使用刚推导的真实速度场，目的是隔离求解器误差，不包含神经网络训练。将代码保存为 `gaussian_flow_demo.py`，在安装 NumPy 的 Python 环境运行即可。输出误差是对同一批初始噪声 z ，逐个比较数值终点与对应闭式终点得到的经验均方根误差；它衡量这里的轨迹终点误差，不是图像质量指标。

```
import numpy as np

def velocity(x, s):
    var = (1.0 - s)**2 + 0.25 * s**2
    return 2.0 + (1.25*s - 1.0) / var * (x - 2.0*s)

def solve(z, steps, method):
    x = z.copy()
    h = 1.0 / steps
    for k in range(steps):
        s = k * h
        k1 = velocity(x, s)
        if method == "euler":
            x = x + h * k1
        elif method == "heun":
            predictor = x + h * k1
            k2 = velocity(predictor, s + h)
            x = x + 0.5 * h * (k1 + k2)
        else:
            raise ValueError("unknown method")
    return x

rng = np.random.default_rng(7)
z = rng.normal(size=10000)
exact = 2.0 + 0.5*z
for steps in (10, 20, 40, 80):
    errors = []
    for method in ("euler", "heun"):
        x = solve(z, steps, method)
```

```
errors.append(np.sqrt(np.mean((x - exact)**2)))
print(steps, *["{e:.6f}" for e in errors])
```

在相同步数 N 下，Heun 进行 $2N$ 次速度函数评估，Euler 进行 N 次，因此下面比较的是相同步数下的精度，并非相同计算预算下的速度。若比较相同函数评估次数，可将 Heun 的 10 步结果与 Euler 的 20 步结果配对；实际运行时间还取决于实现。附带程序的实际运行结果如下，最后几位可能随浮点库有微小差异。

步数	Euler 终点 RMSE	Heun 终点 RMSE
10	0.068826	0.001710
20	0.035551	0.000506
40	0.018086	0.000136
80	0.009125	0.000035

对于这里光滑且方差不为零的速度场，误差随步长缩小而下降。真实模型还存在网络误差、分布误差与端点处理误差；增加步数只能改善其中的数值积分部分。

附录 C 综合自测与参考解答

C1 从数据到一次 DDPM 更新

已知 $\alpha_t=0.9$ 、 $\bar{\alpha}_{t-1}=0.8$ ，取一维数据 $x_0=2$ 和总噪声 $\epsilon=-1$ 。依次求 $\bar{\alpha}_t$ 、 x_t 、 $\tilde{\beta}_t$ 与 $\tilde{\mu}_t$ 。这里的 ϵ 是从 x_0 直接构造 x_t 时的总噪声，不是第 t 步新增的噪声。

参考解答。 $\bar{\alpha}_t=0.72$ ， $x_t=2\sqrt{0.72}-\sqrt{0.28}\approx 1.167906$ ； $\tilde{\beta}_t=0.1\times 0.2/0.28\approx 0.071429$ 。使用噪声形式的后验均值值得

$$\tilde{\mu}_t = \frac{1}{\sqrt{0.9}} \left(x_t - \frac{0.1}{\sqrt{0.28}} \epsilon \right) \approx 1.430286.$$

也可以将 x_0, x_t 代入 Part 6 的加权均值公式得到相同结果。给定 x_0 的真实后验带有方差；后验均值本身不是一次随机采样。

C2 三个目标是否在学习相同对象

比较 ϵ_θ 、 s_θ 与 u_θ 。哪些在相同高斯路径的内部时刻可以换算？为什么相同训练数据与相同 MSE 字样不保证相同优化过程？

参考解答。 在已知路径系数且 $b \neq 0$ 时，最优噪声回归与边缘 score 满足 $s^* = -\epsilon^*/b$ 。对于独立标准高斯噪声与数据构成的可微高斯路径，Part 12 给出 score 到边缘速度的公式，要求涉及的分母非零。更换输出参数化会改变误差前的时间系数；若损失权重和时间采样不作对应调整，训练关注的噪声区间就不同。有限容量、有限优化和数值误差还会打破理想层次的等价。

C3 CFM 的条件究竟是什么

一套图像生成系统用 $X_s = (1-s)Z + sY$ 训练 $u_\theta(X_s, s, c)$ 。其中 c 是文本。训练标签能使用 Y ，是否说明推理时也需要把目标图像 Y 交给模型？

参考解答。 不需要。 (Z, Y) 是构造训练路径与速度标签的配对变量；网络输入是中间状态、时间和文本。平方损失使模型学习 $E[Y - Z | X_s = x, s, c]$ 。推理时从噪声采样并积分该条件边缘速度场即可。CFM 中的条件路径变量与外部文本条件 c 有不同作用。

C4 判断并说明理由

1. 逆扩散每一步的真实边缘条件分布都是高斯。
2. CFG 的尺度越大，样本质量一定越好。
3. 训练 FM 时无需解 ODE，所以生成时也无需解 ODE。
4. 固定端点的条件路径是直线，所以学得边缘流一定是直线。
5. 概率流 ODE 和反向 SDE 在精确条件下有相同边缘分布，所以逐条样本轨迹也相同。
6. Transformer 可以充当去噪网络或速度网络。

参考解答。 1 错，给定 x_0 的可计算后验才是精确高斯，边缘通常为混合。2 错，较大尺度可能牺牲多样性并放大误差。3 错，标准 FM 的采样仍需积分速度场。4 错，边缘场平均了多个条件路径的速度，附录 B 给出反例。5 错，边缘分布相同不决定路径耦合。6 对，架构与生成训练目标是不同层面的设计选择。

参考文献与阅读定位

参考文献以原始论文为主。正文的推导与数值例题为教学展开；阅读论文时应先对照本文的时间方向与参数化约定。下列链接可直接打开原文页面。

- [1] Vaswani A 等. Attention Is All You Need. 2017. 对应 Part 1 与 Part 2, 重点阅读注意力、多头结构和位置编码。 <https://arxiv.org/abs/1706.03762>
- [2] Kingma D P, Welling M. Auto-Encoding Variational Bayes. 2013, ICLR 2014. 对应 Part 3, 重点阅读变分下界与重参数化估计。 <https://arxiv.org/abs/1312.6114>
- [3] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models. NeurIPS 2020. 对应 Part 4 至 Part 7, 重点阅读公式 2 至 14、算法 1 与算法 2。 <https://arxiv.org/abs/2006.11239>
- [4] Sohl-Dickstein J 等. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. ICML 2015. 对应 Part 4, 理解扩散概率模型的早期构造。 <https://arxiv.org/abs/1503.03585>
- [5] Nichol A Q, Dhariwal P. Improved Denoising Diffusion Probabilistic Models. ICML 2021. 对应 Part 7, 重点阅读余弦日程与可学习逆方差。 <https://arxiv.org/abs/2102.09672>
- [6] Salimans T, Ho J. Progressive Distillation for Fast Sampling of Diffusion Models. ICLR 2022. 对应 Part 7, 关注参数化与蒸馏部分。 <https://arxiv.org/abs/2202.00512>
- [7] Hyvärinen A. Estimation of Non-Normalized Statistical Models by Score Matching. JMLR 6, 695–709, 2005. 对应 Part 8, 关注分部积分后的目标。 <https://www.jmlr.org/papers/v6/hyvarinen05a.html>
- [8] Vincent P. A Connection Between Score Matching and Denoising Autoencoders. Neural Computation 23, 1661–1674, 2011. 对应 Part 8, 关注去噪目标与 score 的等价关系。 https://doi.org/10.1162/NECO_a_00142
- [9] Song Y 等. Score-Based Generative Modeling through Stochastic Differential Equations. ICLR 2021. 对应 Part 8 与 Part 10, 重点阅读反向时间 SDE 与概率流 ODE。 <https://arxiv.org/abs/2011.13456>
- [10] Ho J, Salimans T. Classifier-Free Diffusion Guidance. 2022. 对应 Part 9, 关注条件与无条件预测的组合。 <https://arxiv.org/abs/2207.12598>
- [11] Dhariwal P, Nichol A. Diffusion Models Beat GANs on Image Synthesis. NeurIPS 2021. 对应 Part 9, 关注噪声级分类器引导。 <https://arxiv.org/abs/2105.05233>
- [12] Lipman Y 等. Flow Matching for Generative Modeling. ICLR 2023. 对应 Part 11 与 Part 12, 重点阅读条件边缘化与梯度等价定理。 <https://arxiv.org/abs/2210.02747>
- [13] Liu X, Gong C, Liu Q. Flow Straight and Fast Learning to Generate and Transfer Data with Rectified Flow. ICLR 2023. 对应 Part 12, 关注整流、凸代价性质和 reflow。 <https://arxiv.org/abs/2209.03003>
- [14] Tong A 等. Improving and Generalizing Flow-Based Generative Models with Minibatch Optimal Transport. 2023, TMLR 2024. 对应 Part 12, 关注一般配对分布与小批次 OT。 <https://arxiv.org/abs/2302.00482>
- [15] Luo C. Understanding Diffusion Models: A Unified Perspective. arXiv:2208.11970v1, 2022。本文使用 23 页版本, 标题页日期为 2022 年 8 月 26 日。对应 Part 3 至 Part 9 与 Part 13, 重点阅读 ELBO 与 HVAE、扩散的变分推导、SNR 权重、三种等价解释、score matching 与 guidance。Part 13 标注的页码与公式编号均对应此版本。 <https://arxiv.org/pdf/2208.11970v1>